

# PŘEHLED VZORCŮ A HLAVNÍCH POJMŮ

## na přednáškách KMA/PSA

### 5. a 6. týdne ZS 2015/16

(následující bude mj. promítnuto během těchto přednášek PSA - volná místa na stránkách jsou úmyslně : po vytištění lze používat k doplnění vlastních poznámek)

**Vysvětlení, použití, grafy, příklady, etc. budou na přednášce.**

---

#### 7. KVANTILY SPOJITÝCH ROZDĚLENÍ

Nechť  $X$  je *spojitá* náhodná veličina,  $p \in (0, 1)$ .

Reálné číslo  $x_p$  se nazývá **100 p%-NÍ KVANTIL**, je-li

$$P(X \leq x_p) = p$$

$x_{0,5}$  ... **medián**

$x_{0,25}$  ... **dolní kvartil**

$x_{0,75}$  ... **horní kvartil**

Pomocí distribuční funkce  $F(x)$  lze definici kvantilu  $x_p$  přepsat takto:

$$F(x_p) = p$$

**Př.:**

### Určení kvantilů normálního rozdělení

Kvantily  $x_p$  rozdělení  $N(\mu, \sigma^2)$  lze vyjádřit pomocí kvantilů  $u_p$  rozdělení  $N(0, 1)$ , neboť pro  $p \in (0, 1)$  platí

$$x_p = \mu + \sigma \cdot u_p$$

K určení  $u_p$  používáme **tabulky**, pro  $p < 0,5$  navíc rovnost

$$u_p = -u_{1-p}$$

[tedy např.  $u_{0,05} = -u_{0,95}$ ]

která platí, neboť hustota  $\varphi(u)$  je sudá funkce.

**Př.:**

## 8. TRANSFORMACE NÁHODNÉ VELIČINY

Dáno:  $X$  ... **spojitá** náh. veličina

$f(x)$  ... hustota  $X$ ,

$F(x)$  ... distrib. fce  $X$

Nechť  $Y = h(X)$  (funkce náh. veličiny  $X$ ).

Pak  $Y$  je náh. veličinou, označme:

$g(y)$  ... hustota  $Y$ ,

$G(y)$  ... distrib. fce  $Y$

$$g(y) = ?$$

$$G(y) = ?$$

**Pozn.:** Je-li fce  $h$  **konvexní** nebo **ryze monotónní**, je hledání  $g(y)$ , resp.  $G(y)$  jednodušší - viz příklady. Některá takto vzniklá rozdělení ppsti mají své názvy a označení - např. normované normální rozdělení, logaritmicko-normální rozdělení,  $\chi^2$ -rozdělení.

**Pozn.:**  $Y$ ... spojitá náhodná veličina

- LOGARITMICKO-NORMÁLNÍ rozdělení (s parametry  $\mu \in R, \sigma > 0$ ),  
píšeme  $Y \sim N(\mu, \sigma^2)$ :

$Y$  má hustotu

$$g(y) = \begin{cases} 0 & \text{pro } y \in (-\infty, 0] \\ \frac{1}{\sigma y} \cdot \varphi\left(\frac{\ln y - \mu}{\sigma}\right) & \text{pro } y \in (0, +\infty), \end{cases}$$

kde  $\varphi$  je hustota pravděpodobnosti rozdělení  $N(0, 1)$ .

- $\chi^2$ -ROZDĚLENÍ [čteme:”chí-kvadrát”] o 1 stupni volnosti, píšeme  $Y \sim \chi^2(1)$ :

$Y$  má hustotu

$$g(y) = \begin{cases} 0 & \text{pro } y \in (-\infty, 0] \\ \frac{1}{\sqrt{2\pi y}} \cdot e^{-\frac{y}{2}} & \text{pro } y \in (0, +\infty), \end{cases}$$

[ Později ve statistice bude  $\chi^2(\nu)$ , kde  $\nu \in N$ .]

## NÁHODNÝ VEKTOR

$\vec{X} = (X, Y)$  ... (dvourozměrný) **náhodný vektor**

$X, Y$  ... náh. veličiny (buď obě diskř. nebo obě spoj.)

$$F(x, y) = P(X \leq x, Y \leq y) \quad \text{kde } x, y \in (-\infty, +\infty)$$
  
... (sdružená) **distribuční funkce** náh. vektoru  $\vec{X}$

$F_1(x) = P(X \leq x)$ , resp.  $F_2(y) = P(Y \leq y)$   
... tzv. **marginální** distrib.funkce  $X$ , resp.  $Y$

$\vec{X} = (X, Y)$  **diskrétní**:

$P(x, y)$  ... (sdružená) **pravděpodobnostní funkce**

$P_1(x), P_2(y)$  ... **marginální** ppstní fce  $X$ , resp.  $Y$

$\vec{X} = (X, Y)$  **spojitý**:

$f(x, y)$  ... (sdružená) **hustota** ppsti

$f_1(x), f_2(y)$  ... **marginální** hustoty  $X$ , resp.  $Y$

$E(\vec{X}) = (E(X), E(Y)) \dots$  vektor středních hodnot

Vztah mezi  $X$  a  $Y$  udává tzv. **KOVARIANCE**, píšeme  $\text{cov}(X, Y)$ :

$$\text{cov}(X, Y) = E([X - E(X)] \cdot [Y - E(Y)])$$

Roznásobením a úpravou dostaneme tzv. **výpočetní tvar kovariance**:

$$\text{cov}(X, Y) = E(X \cdot Y) - E(X) \cdot E(Y)$$

Zřejmě:  $\text{cov}(X, Y) = \text{cov}(Y, X)$

$$\text{cov}(X, X) = D(X)$$

$$\text{cov}(Y, Y) = D(Y)$$

Pro (nekonstantní) náh. veličiny  $X, Y$  definujeme tzv.

**KORELAČNÍ KOEFICIENT**, píšeme  $\varrho(X, Y)$ :

$$\varrho = \varrho(X, Y) = \frac{\text{cov}(X, Y)}{\sigma(X)\sigma(Y)},$$

kde  $\sigma(X)$ ,  $\sigma(Y)$  jsou směrodatné odchylky veličin  $X, Y$ .

Platí : •  $-1 \leq \varrho \leq 1$

- $\varrho(X, Y) = \varrho(Y, X)$
- $\varrho(X, X) = \varrho(Y, Y) = 1$

$\varrho$  je mírou statistické **lineární** závislosti veličin  $X, Y$

$\varrho = +1 \Leftrightarrow Y = aX + b$ , kde  $a > 0$ ,  $b \in R$

$\varrho = -1 \Leftrightarrow Y = aX + b$ , kde  $a < 0$ ,  $b \in R$

Je-li  $\varrho = 0$ , říkáme, že  $X, Y$  jsou **nekorelované**.

$X, Y$  nezávislé  $\Rightarrow X, Y$  jsou nekorelované

(implikace " $\Leftarrow$ " obecně neplatí)

Pro náh. vektor  $\vec{X} = (X_1, X_2, \dots, X_k)$  lze kovariance, resp. korelační koeficienty uspořádat do čtvercových matic  $\Sigma = (\sigma_{ij})$ , resp.  $R = (\varrho_{ij})$ , a to označím

$$\sigma_{ij} = \text{cov}(X_i, X_j), \text{ resp. } \varrho_{ij} = \varrho(X_i, X_j)$$

Pak

$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1k} \\ \sigma_{21} & \sigma_{22} & \dots & \sigma_{2k} \\ \dots & \dots & \dots & \dots \\ \sigma_{k1} & \sigma_{k2} & \dots & \sigma_{kk} \end{bmatrix}$$

resp.

$$R = \begin{bmatrix} \varrho_{11} & \varrho_{12} & \dots & \varrho_{1k} \\ \varrho_{21} & \varrho_{22} & \dots & \varrho_{2k} \\ \dots & \dots & \dots & \dots \\ \varrho_{k1} & \varrho_{k2} & \dots & \varrho_{kk} \end{bmatrix}$$

$\Sigma$  ... **kovarianční matice**, je symetrická, na hlavní diagonále jsou rozptyly  $D(X_i)$

$R$  ... **korelační matice**, je symetrická, na hlavní diagonále jsou 1

**Př.:**



### Dvourozměrné normální rozdělení

s vektorem středních hodnot  $\vec{\mu} = (\mu_1, \mu_2)$  a kovarianční maticí  $\Sigma$  má hustotu

$$f(x, y) = \frac{1}{2\pi\sqrt{\det \Sigma}} \cdot e^{-\frac{1}{2} P(x, y)} ,$$

kde

$$P(x, y) = (x - \mu_1, y - \mu_2) \Sigma^{-1} \begin{pmatrix} x - \mu_1 \\ y - \mu_2 \end{pmatrix} .$$

Píšeme:  $(X, Y) \sim N_2(\vec{\mu}, \Sigma)$ .

Je-li  $(X, Y) \sim N_2(\vec{\mu}, \Sigma)$ , pak platí:

$X, Y$  nezávislé  $\Leftrightarrow X, Y$  nekorelované.  
(tj. nelineární závislost není možná)