



# Strojové učení

## 8 Umělé neuronové sítě

- Historie, biologický předobraz
- Matematické modely neuronu
- Neuronová síť, vrstevnaté sítě
- Klasifikace neuronovou sítí
- Cenová funkce
- Optimalizace cenové funkce
- Učení neuronových sítí
- Algoritmus Backpropagation





# Umělé neuronové sítě

## Úvod

**Umělá neuronová síť** (*Artificial Neural Network*) – matematický simulační model informačního procesoru inspirovaný biologickými neuronovými sítěmi, zejména lidskou nervovou soustavou a mozkem.

Neuronová síť se skládá z množiny **umělých neuronů**, které mohou být uspořádány do **vrstev** (podle účelu) a navzájem propojeny **synapse**mi, jejichž významnost určují **synaptické váhy**.

Neuronová síť je **adaptivní systém**, který mění svoji strukturu během fáze učení. Modeluje komplexní relace mezi vstupy a výstupy, popř. hledá ve vstupních datech vzory...



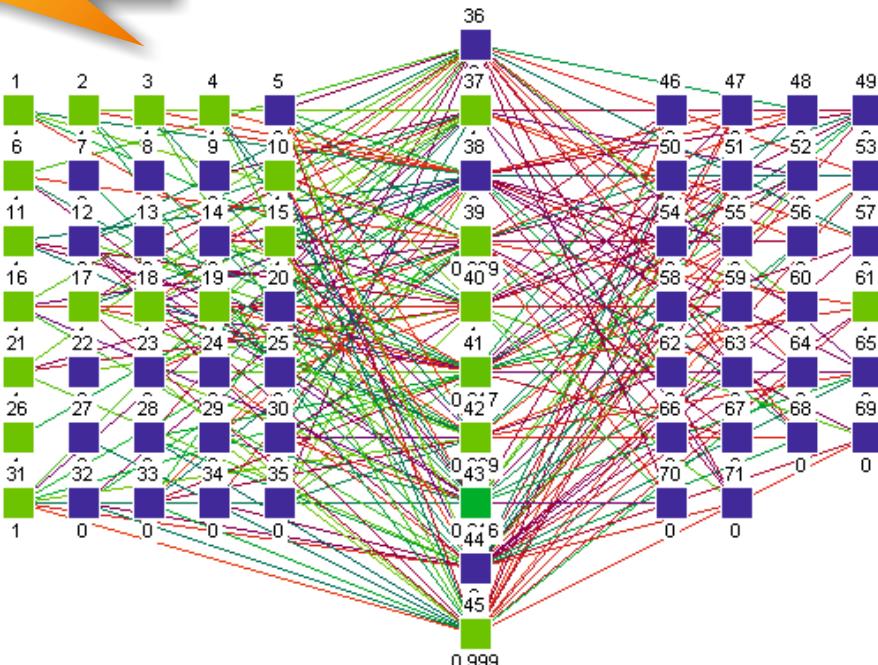


# Umělé neuronové sítě

## Ilustrační příklad

Neuronová síť je matematický model definující funkci

$$f: \mathbf{x} \in \mathbb{R}^n \rightarrow \mathbf{y} \in \mathbb{R}^m$$

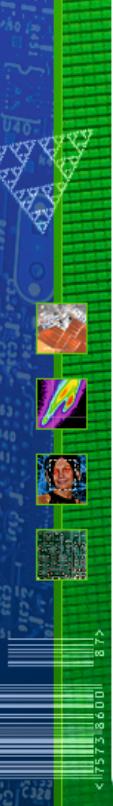




# Umělé neuronové sítě

## Historický vývoj

- biologický předobraz: Jan Evangelista Purkyně, Ramon y Cajal
- vizionářský článek Američana W. S. McCullocha z roku 1921 o umělém napodobování biologických neuronových sítí
- W. S. McCulloch & W. Pitts představili v roce 1943 první reálně použitelný matematický model neuronu
- D. Hebb, 1949: zákon učení sítí neuronů, konstrukce prakticky použitelných učících algoritmů
- B. Widrow: vrstevnaté sítě ADALINE, MADALINE
- F. Rosenblatt: učící algoritmus pro vrstevnaté sítě s dopředným přenosem signálu
- M. Minsky & S. Papert, 1969: kniha *Perceptrons: An Introduction to Computational Geometry* “dokazuje” omezení jednovrstvé lineární neuronové sítě (perceptronu) → útlum zájmu o problematiku až do konce 80. let 20. stol.

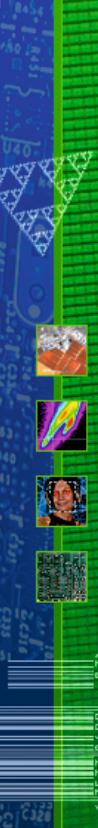




# Umělé neuronové sítě

## Historický vývoj

- v polovině 80. let 20. stol. dochází k masivní renesanci zájmu o ANN (mj. díky DARPA)
- znovaobjevení algoritmu **back-propagation** (1986) urychlilo rozvoj reálně nasaditelných systémů na bázi ANN
- Kunihiko Fukushima (1980): Neocognitron – „standardní architektura pro počítačové vidění“, práce inspirovaná analýzou funkce buněk primárního vizuálního kortextu
- Cybenko (1989), Hornik (1991) a jiní dokazují (tentokrát již korektně) matematické vlastnosti neuronových sítí
- J. Schmidhuber (2009 – 2012): nové architektury neuronových sítí Recurrent NN a Deep Feedforward NN vyhrávají mj. soutěže v rozpoznávání spojitého rukopisu, analýze textu, ap.

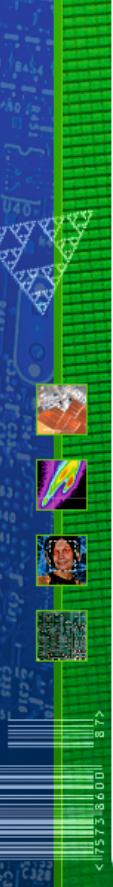




# Umělé neuronové sítě

## Oblasti úspěšných aplikací

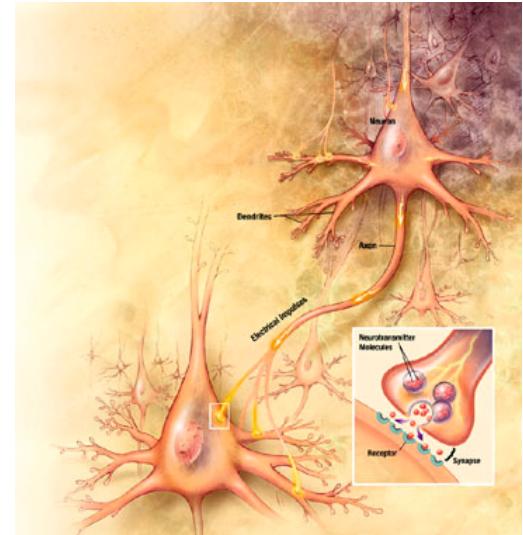
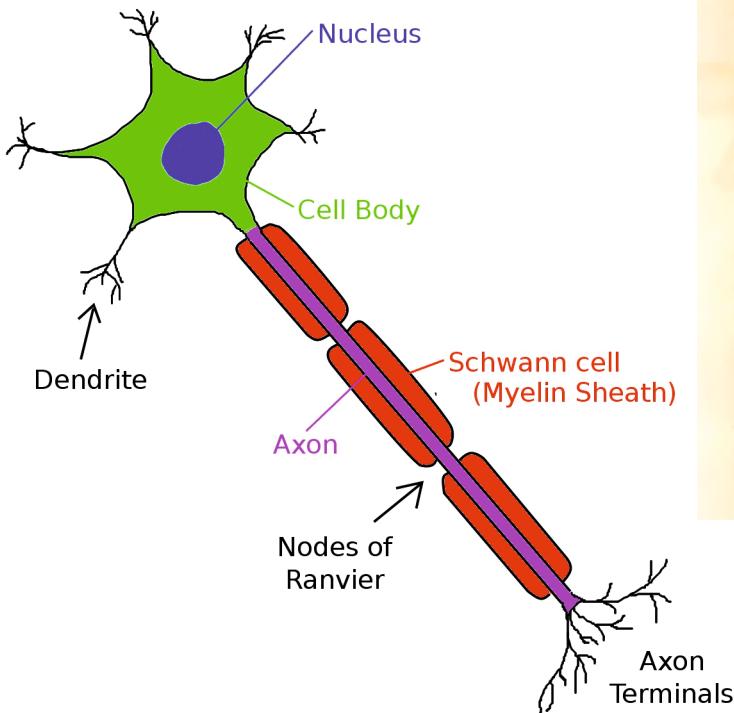
- výzkum v oblasti modelování informačních systémů živých organismů
- výzkum procesů učení, testování, adaptace a generalizace
- predikce časových řad (ekonomie, ekologie, energetika, doprava, meteorologie, logistika)
- analýza signálů (EKG, EEG, akustika, ...)
- de-/komprese a kódování signálů (telekomunikace)
- adaptivní řízení technologických celků
- automatické řízení autonomních systémů
- systémy pro podporu rozhodování a expertní systémy
- modelování komplexních jevů (katastrofy, ekonometrie)
- kontrola kvality a automatické testování
- ...





# Biologický neuron

## Předobraz matematického modelu



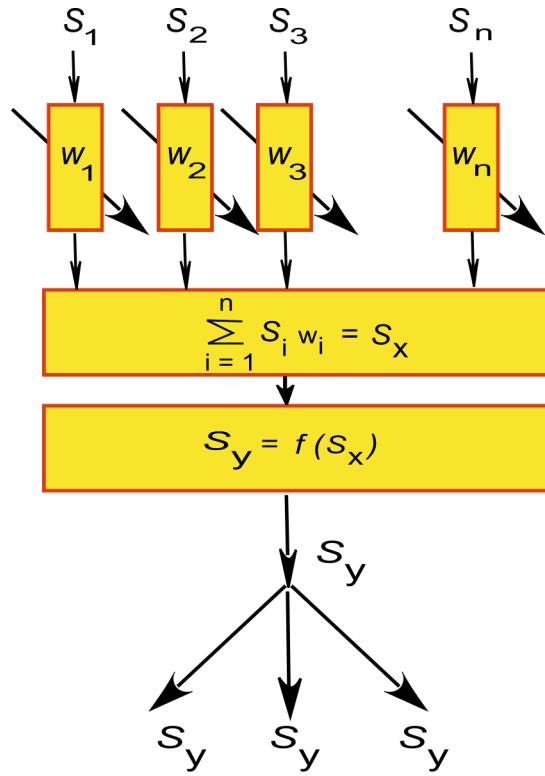
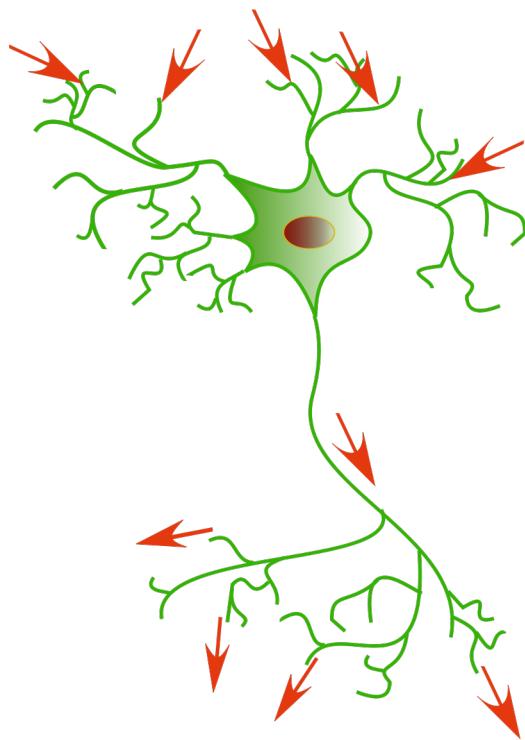
(Obrázek © Wikimedia Commons, Nick Gorton, 2005)

(Obrázek © US National Institutes of Health, National Institute on Aging)



# Biologický neuron

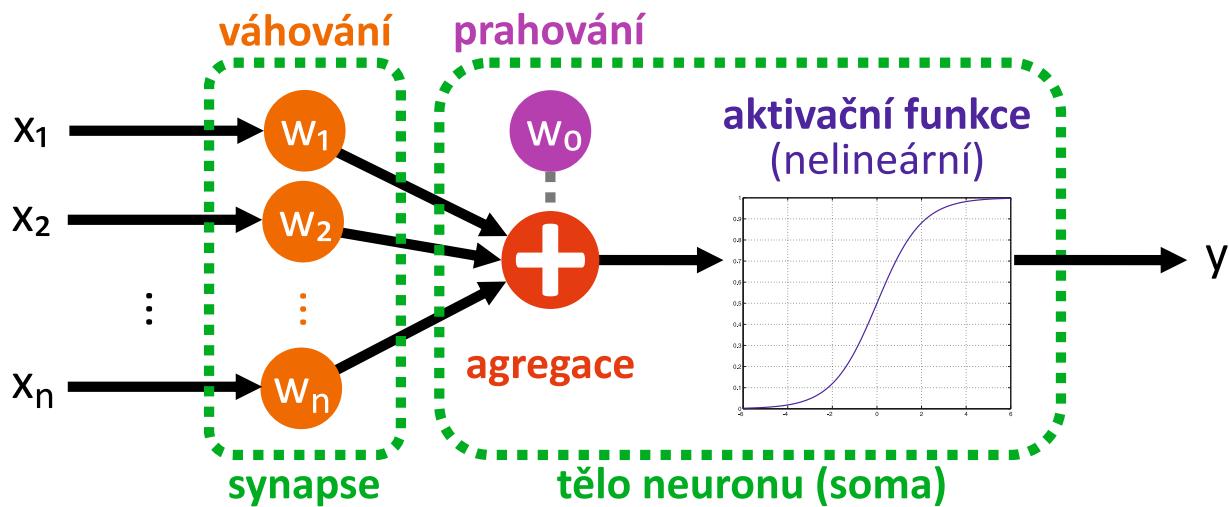
## Matematický model





# McCulloch-Pittsův neuron

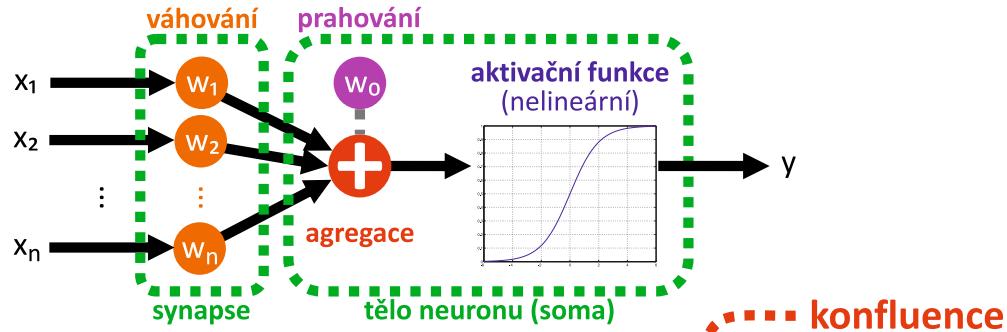
## Matematický model umělého neuronu





# McCulloch-Pittsův neuron

## Matematický model umělého neuronu



**Synaptické operace:**  $\mathbf{z}(t) = \mathbf{x}(t) \oplus \mathbf{w}(t) = (x_i(t) \cdot w_i(t))_{i=1}^n$

**Somatické operace:**  
 $g(\mathbf{z})$

$$\left\{ \begin{array}{l} u(t) = \sum_{i=1}^n z_i(t) \\ v(t) = u(t) - w_0 \\ y(t) = \frac{1}{1 + e^{-v(t)}} \end{array} \right.$$



# RBF neuron

## Aktivační funkce s radiální bází

### LBF (*Linear Basis Function*)

- dělí vstupní prostor lineárně prostřednictvím n-rozměrných nadrovin

$$u(t) = \sum_{i=1}^n x_i(t)w_i(t)$$

→ standardní McCulloch-Pittsův neuron

### Modifikace:

### RBF (*Radial Basis Function*)

- dělí vstupní prostor prostřednictvím hyperkoulí

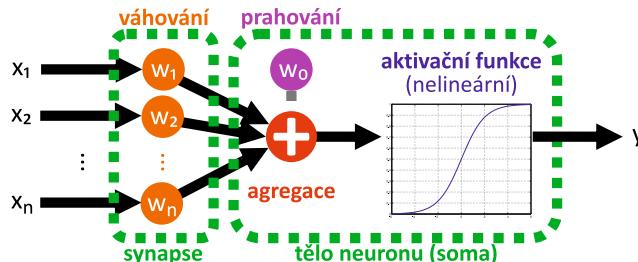
$$u(t) = \sqrt{\sum_{i=1}^n (x_i(t) - w_i(t))^2}$$





# Umělý neuron

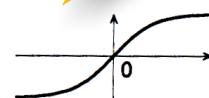
## Používané typy aktivačních funkcí



**sigmoida je vhodná volba, protože je spojitá, a tedy diferencovatelná v celém R**

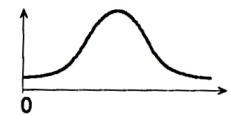
některé jsou sice výpočetně jednodušší, ale mají jiné nevýhody

Výběr vhodné aktivační funkce závisí na charakteru řešené úlohy...



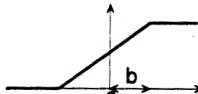
$$y(t) = \tanh v(t)$$

b)



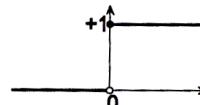
$$y(t) = e^{-v^2(t)}$$

c)



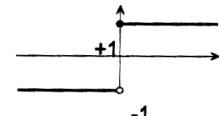
$$\begin{aligned} y(t) &= 0 & v(t) &\leq -b \\ y(t) &= c \cdot v(t) & -b < v(t) < b \\ y(t) &= 1 & v(t) &\geq b \end{aligned}$$

d)



$$\begin{aligned} y(t) &= 0 & v(t) &< 0 \\ y(t) &= 1 & v(t) &\geq 1 \end{aligned}$$

e)



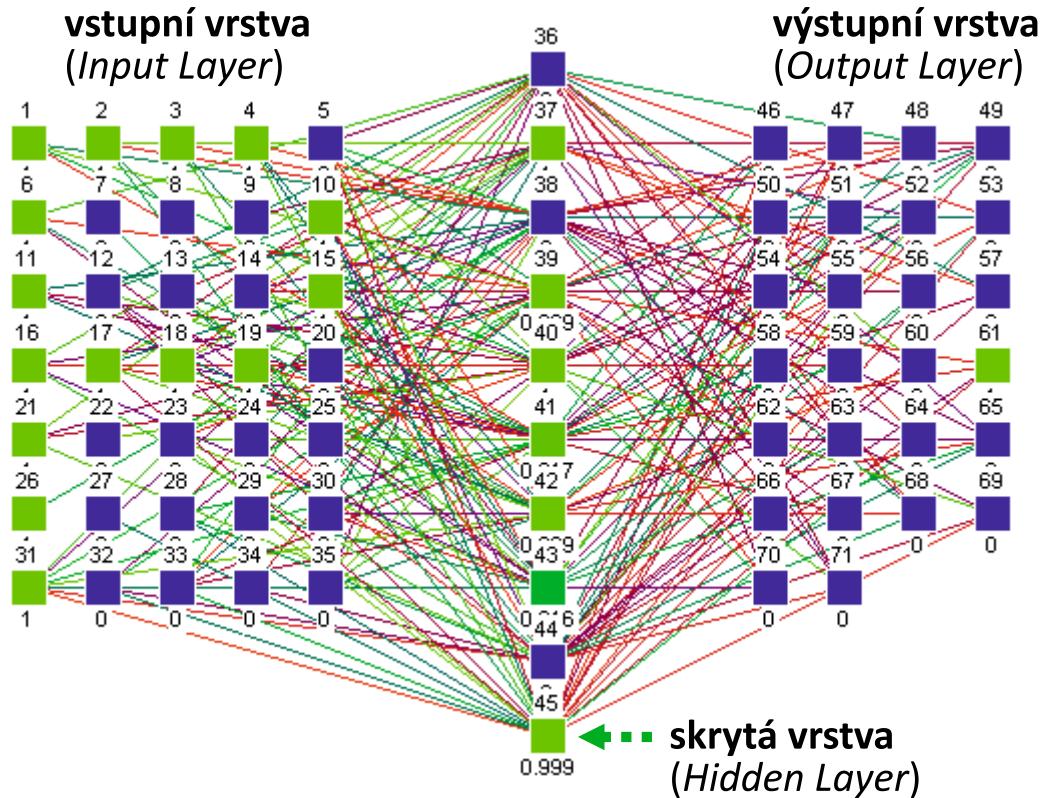
$$\begin{aligned} y(t) &= -1 & v(t) &< 0 \\ y(t) &= 1 & v(t) &\geq 1 \end{aligned}$$

f)



# Neuronová síť (Vrstevnatá) struktura z umělých neuronů

Vícevrstvý perceptron (*Multi-Layer Perceptron, MLP*)

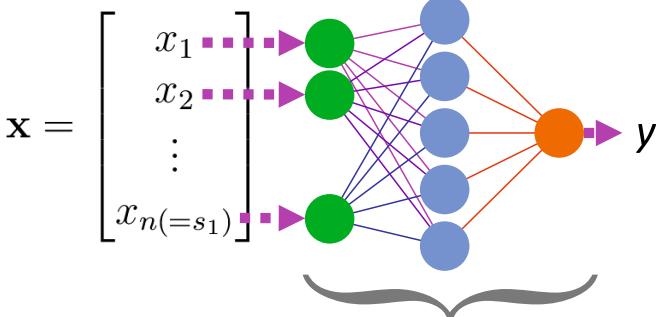




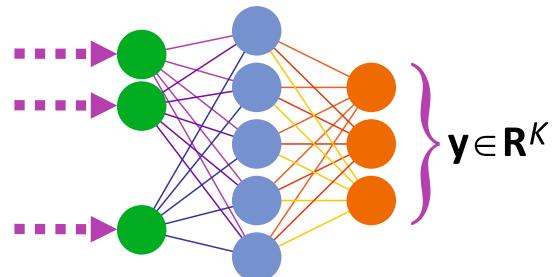
# Klasifikace neuronovou sítí

## Binární vs multi-class klasifikace

### Binární klasifikace



### Multi-class klasifikace



$L$  – celkový počet vrstev sítě  
(více než 3 nemá smysl  $\leftarrow$  Cybenko)

1 neuron ve výstupní vrstvě,  
tj.  $y = \{0, 1\}$ ;  $h_\Theta(x) \in \mathbb{R}$ ; počet  
neuronů v  $L$ -té vrstvě  $s_L = 1$ ,  
počet tříd  $K = 1$  (aktivace vý-  
stupního neuronu indikuje,  
zda vzorek do třídy ne-/patří)

$K$  neuronů ve výstupní vrstvě,  
tj.  $y = \mathbb{R}^K$ ;  $h_\Theta(x) \in \mathbb{R}^K$ ;  $s_L = K$ ;

$y = \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}$  indikova-  
ná třída  
(max)  $y = \begin{bmatrix} 0 \\ 1 \\ 0 \\ 0 \end{bmatrix}$



# Cenová funkce pro neuronovou síť

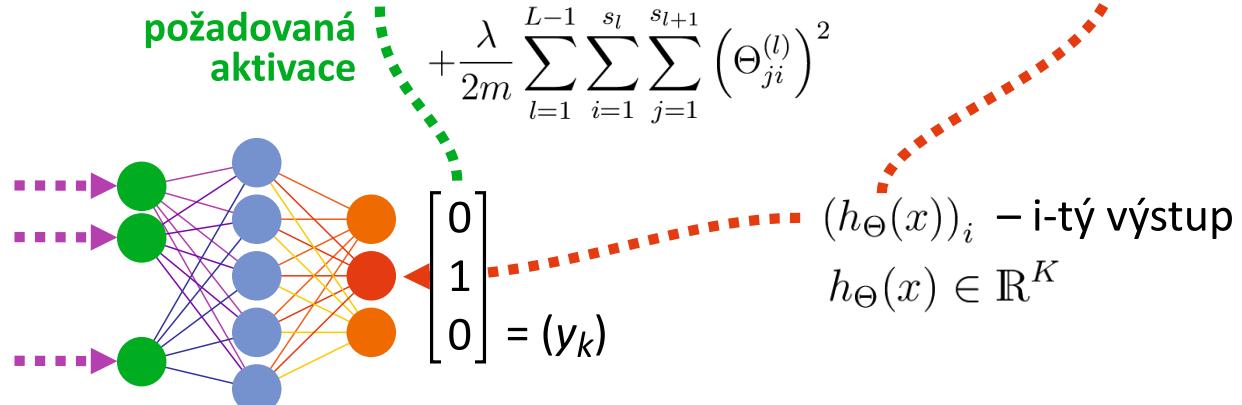
## Generalizace cenové funkce logistické regrese

Cenová funkce logistické regrese:

$$J(\Theta) = - \left[ \frac{1}{m} \sum_{i=1}^m y^{(i)} \log h_\Theta(\mathbf{x}^{(i)}) + (1-y^{(i)}) \log (1-h_\Theta(\mathbf{x}^{(i)})) \right] + \frac{\lambda}{2m} \sum_{j=1}^n \Theta_j^2$$

Cenová funkce neuronové sítě:

$$J(\Theta) = -\frac{1}{m} \left[ \sum_{i=1}^m \sum_{k=1}^K y_k^{(i)} \log (h_\Theta(\mathbf{x}^{(i)}))_k + (1-y_k^{(i)}) \log (1 - (h_\Theta(\mathbf{x}^{(i)}))_k) \right]$$





# Výpočet gradientu

## Minimalizace cenové funkce

Cenová funkce neuronové sítě:

$$J(\Theta) = -\frac{1}{m} \left[ \sum_{i=1}^m \sum_{k=1}^K y_k^{(i)} \log (h_\Theta(\mathbf{x}^{(i)}))_k + \left(1 - y_k^{(i)}\right) \log \left(1 - (h_\Theta(\mathbf{x}^{(i)}))_k\right) \right] \\ + \frac{\lambda}{2m} \sum_{l=1}^{L-1} \sum_{i=1}^{s_l} \sum_{j=1}^{s_{l+1}} \left(\Theta_{ji}^{(l)}\right)^2$$

Cílem optimalizace je:  $\min_{\Theta} J(\Theta)$  – minimalizace cenové funkce...

Potřebujeme umět spočítat:

- $J(\Theta)$
  - $\frac{\partial J(\Theta)}{\partial \Theta_{ij}^{(l)}}$
- } pro potřeby formalizace a uvedení do souvislosti s předchozími optimalizačemi jsou váhy  $w_{ij}$  přeznačeny na  $\Theta_{ij}^{(l)}$
- „přímý“ analytický výpočet – problém



# Výpočet parciální derivace $J(\Theta)$

## Dopředné šíření (Forward Propagation)

Je-li dán jeden trénovací vzorek  $(x, y)$ , pak vektorizovaná verze výpočtu dopředného šíření aktivace sítí vypadá:

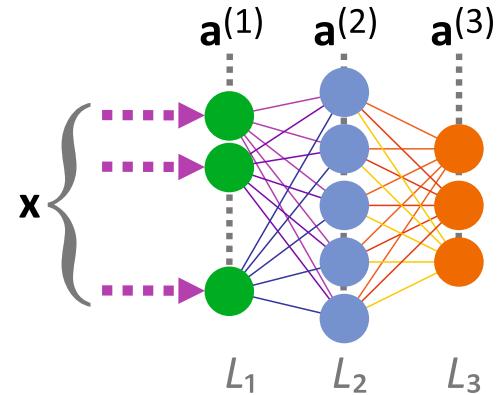
$$\mathbf{a}^{(1)} = \mathbf{x}$$

$$\mathbf{z}^{(2)} = \Theta^{(1)} \mathbf{a}^{(1)}$$

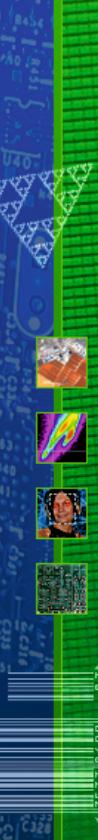
$$\mathbf{a}^{(2)} = g(\mathbf{z}^{(2)}) \quad \text{odečteme práh } a_0^{(2)}$$

$$\mathbf{z}^{(3)} = \Theta^{(2)} \mathbf{a}^{(2)}$$

$$\mathbf{a}^{(3)} = g(\mathbf{z}^{(3)}) = h_{\Theta}(\mathbf{x})$$



→ vypočítá aktivaci všech neuronů v celé síti





# Výpočet parciální derivace $J(\Theta)$

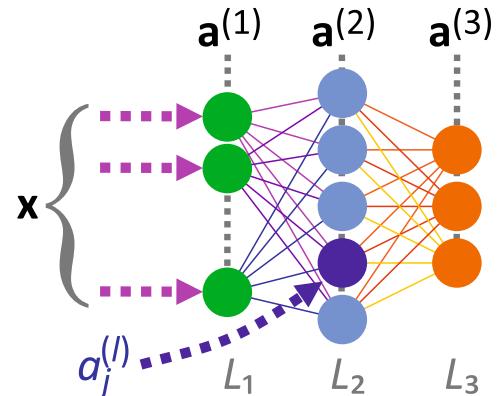
## Zpětné šíření (Back-Propagation)

Učící algoritmus **Backpropagation** vlastně provádí numerický výpočet derivace  $J(\Theta)$ :

$$\delta_j^{(l)} = \text{„chyba“ } j\text{-tého neuronu v } l\text{-té vrstvě}$$

$$\left. \begin{array}{l} \delta_j^{(3)} = a_j^{(3)} - y_j \\ a_j^{(3)} = (h_\Theta(\mathbf{x}))_j \end{array} \right\} \text{pro vstupní vrstvu}$$

$$\delta^{(2)} = (\Theta^{(2)})^\top \delta^{(3)} \cdot * \frac{dg(\mathbf{z}^{(2)})}{d\mathbf{z}^{(2)}} \quad \left\{ \text{pro skrytou vrstvu} \right.$$



Vektor chyb  $\delta^{(1)}$  neexistuje – jsou to přímo vstupy do sítě, tj. nelze mluvit o chybě...



# Výpočet parciální derivace $J(\Theta)$

## Souvislost zpětného šíření s par. deriv. $J(\Theta)$

**Derivace aktivační funkce:**

$$\frac{dg(\mathbf{z}^{(l)})}{d\mathbf{z}^{(l)}} = \mathbf{a}^{(l)} * (1 - \mathbf{a}^{(l)}) \equiv \frac{d\sigma(x)}{dx} = \sigma(x)(1 - \sigma(x))$$

protože

$$s(x) = \frac{1}{\sigma(x)} = 1 + e^{-x} \quad s'(x) = \frac{-\sigma'(x)}{\sigma(x)^2}$$

$$s'(x) = -e^{-x} = 1 - s(x) = 1 - \frac{1}{\sigma(x)} = \frac{(\sigma(x) - 1)}{\sigma(x)}$$

Použitím poměrně komplikované matematiky lze ukázat, že

$$\boxed{\frac{\partial J(\Theta)}{\partial \Theta_{ij}^{(l)}} = a_j^{(l)} \delta_i^{l+1}}$$

za předpokladu ignorování regularizačního parametru, tj.  $\lambda = 0$ .



# Algoritmus Backpropagation

## Optimalizace $L$ -vrstvé neuronové sítě

Trénovací množina  $\{(\mathbf{x}^{(1)}, \mathbf{y}^{(1)}), (\mathbf{x}^{(2)}, \mathbf{y}^{(2)}), \dots, (\mathbf{x}^{(m)}, \mathbf{y}^{(m)})\}$

Nastavíme  $\Delta_{ij}^{(l)} \leftarrow 0, \forall i, j, l$

**for**  $i \leftarrow 1 \dots m \{$

$\mathbf{a}^{(1)} \leftarrow \mathbf{x}^{(i)}$

    výpočet dopředného šíření, abychom získali  $\mathbf{a}^{(l)}$  pro  $l = 2, \dots, L$

    výpočet chyby ve výstupní vrstvě  $\delta^{(L)} \leftarrow \mathbf{a}^{(L)} - \mathbf{y}^{(i)}$

    výpočet zpětného šíření chyby  $\delta^{(L-1)}, \delta^{(L-2)}, \dots, \delta^{(2)}$

$\Delta_{ij}^{(l)} \leftarrow \Delta_{ij}^{(l)} + a_j^{(l)} \delta_i^{(l+1)}$

}

$$D_{ij}^{(l)} \leftarrow \frac{1}{m} \Delta_{ij}^{(l)} + \lambda \Theta_{ij}^{(l)} \quad \text{jestliže } j \neq 0 \quad \Bigg\}$$

$$D_{ij}^{(l)} \leftarrow \frac{1}{m} \Delta_{ij}^{(l)} \quad \text{jestliže } j = 0 \quad \Bigg\}$$

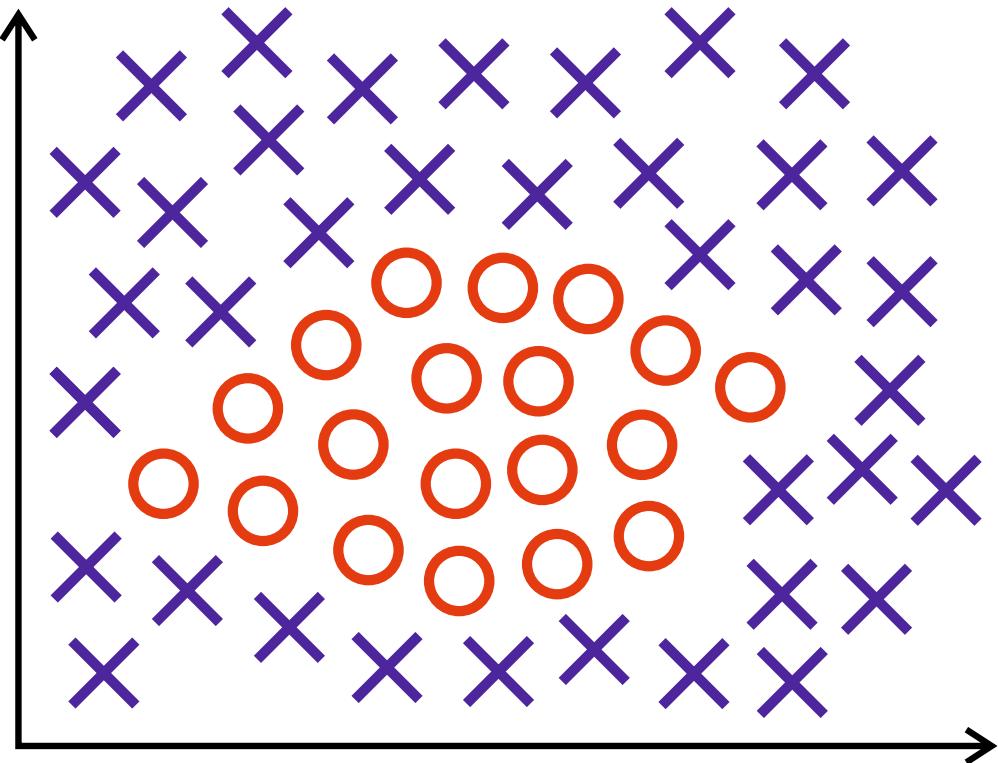
$$\frac{\partial J(\Theta)}{\partial \Theta_{ij}^{(l)}} = D_{ij}^{(l)}$$





# Použití neuronových sítí

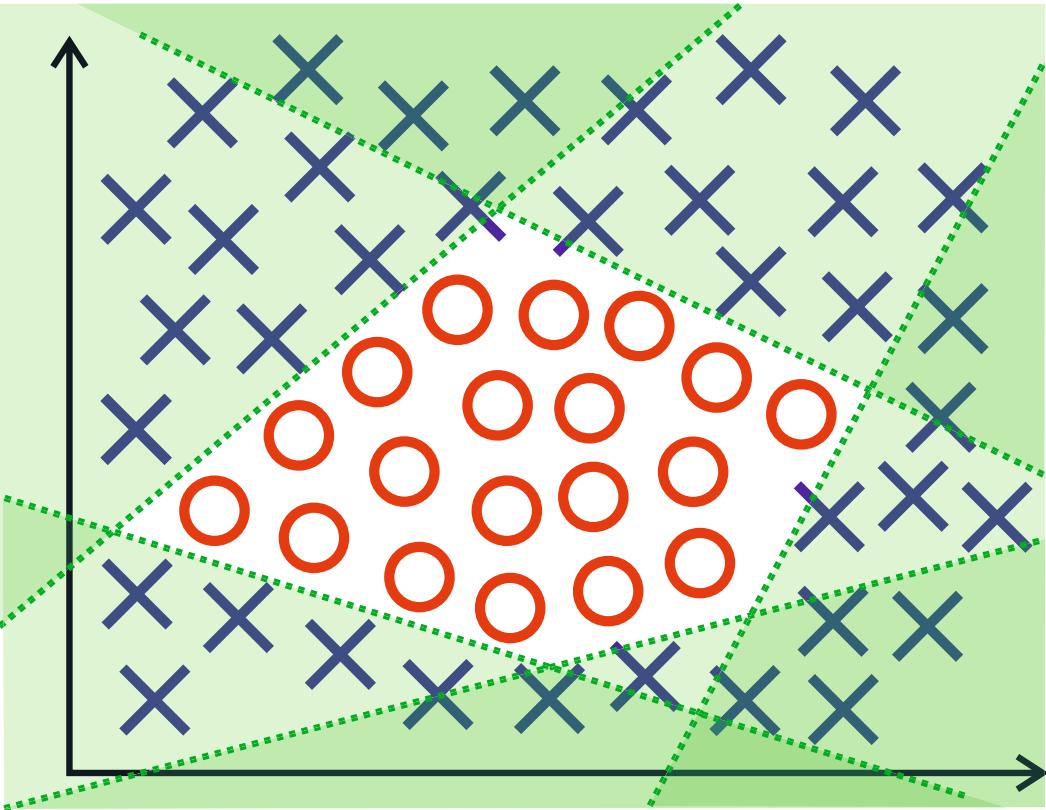
## Motivace – nelineární klasifikace





# Použití neuronových sítí

## Motivace – nelineární klasifikace





# Další typy neuronových sítí

## Náměty k samostudiu

- **SOM** (*Self-Organizing Map*), též **Kohonenova síť**
- **LAM** (*Linear Associative Memory*)
- **ART** (*Adaptive Resonance Theory*)  
ART 1, 2, 2-A, 3, Fuzzy ART, ARTMAP
- **Cognitron** a **Neocognitron**
- **Hopfieldova síť**
- **ADALINE/MADALINE**

