



# Strojové učení

## 12 Slepá separace zdrojů

- Motivace k separaci zdrojů
- Definice problému separace
- Přehled metod slepé separace
- Independent Component Analysis
- Princip činnosti ICA
- Algoritmus ICA
- Vlastnosti ICA
- Použití ICA





# Slepá separace zdrojů informace (signálů)

## Učení bez učitele

**Slepá separace zdrojů (BSS, *Blind Signal/Source Separation*)** je problém učení bez učitele (*Unsupervised Learning*). Je to:

- rodina výpočetních postupů, užívaných zejm. v DSP, statistice, klasifikaci a rozpoznávání, atp.
- cílem je výpočet **odhadu** původních signálů, jejichž směsi jsou vstupem algoritmu (tj. nejedná se o kouzelné postupy, které ze zašuměného signálu udělají samy čistý)
- BSS separuje signály ze směsí bez (nebo s minimálním) užití informace o původu či charakteru signálů nebo způsobu, jakým byly smíchány
- separované signály musí splňovat určité omezující požadavky
- existuje řada (více či méně účinných) metod slepé separace zdrojů, některé jsou vhodné jen pro určité konkrétní situace





# Slepá separace zdrojů informace (signálů)

## Základní vlastnosti

BSS lze úspěšně provádět pouze tehdy, jsou-li zdroje (tj. pův. signály, ze kterých vznikly zpracovávané směsi):

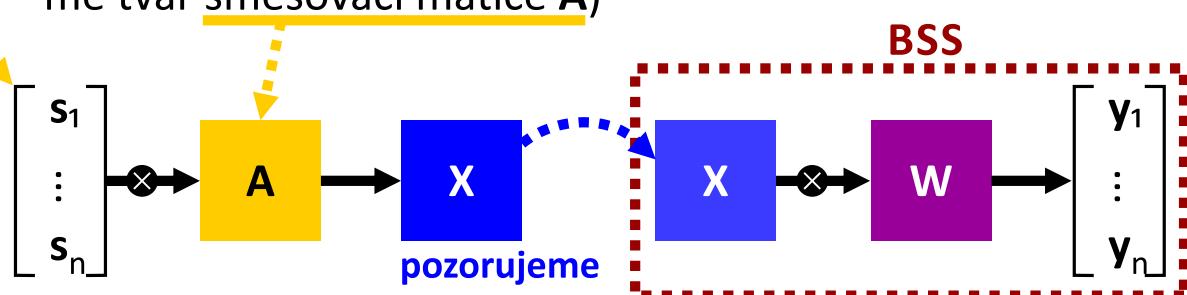
- **nekorelované** (nejdůležitější požadavek)
- statisticky nezávislé



BSS využívá pouze předpoklad vzájemné nezávislosti signálů

Proč slepá?

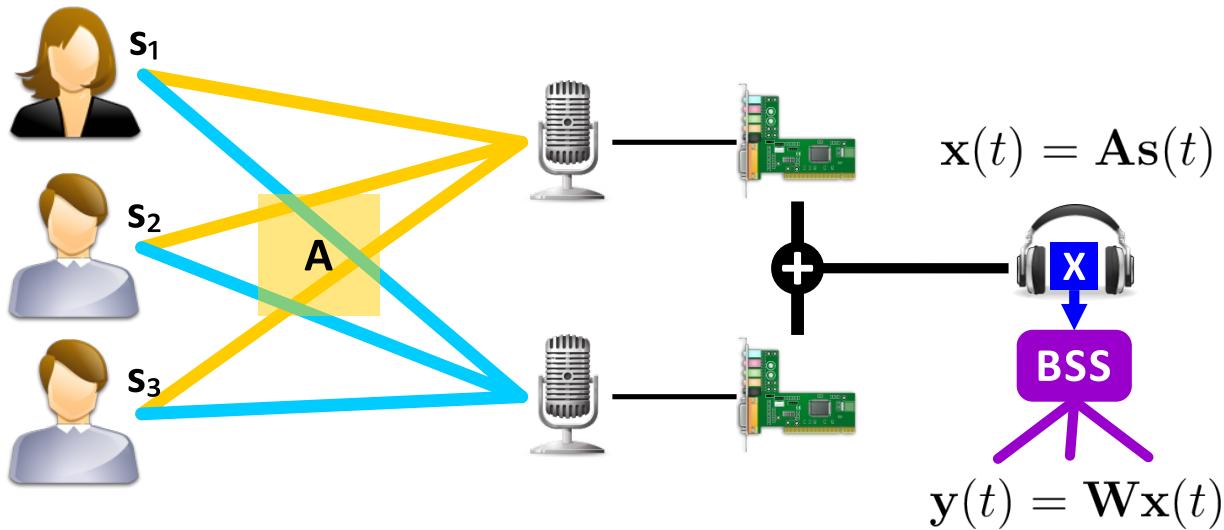
- zdrojové (pův.) signály **nepozorujeme** (nejsou k dispozici)
- není k dispozici informace o původu jejich směsi (tj. neznáme tvar směšovací matice **A**)





# Slepá separace zdrojů informace (signálů) Aplikace

**Problém koktejlového večírku (Cocktail Party Problem)** – velmi jednoduchá klasická ukázka aplikace BSS, poprvé poopsaná Edwardem Colinem Cherrym roku 1957:

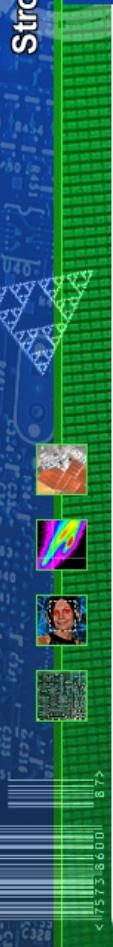




# Slepá separace zdrojů informace (signálů)

## Praktické aplikace – DSP

- **magnetoencefalografie (MEG)** – separace signálů za účelem odstranění *artefaktů*, tj. následků rušení vnějšími zdroji elmg polí (např. kovové hodinky pacienta)
- **echo cancellation & dereverberation** – odečítání zpožděných (odrazem či přenosem) signálů, používá se u mobilních telefonů, Skype, apod.
- **potlačení šumu (Denoising)** – akustických signálů (1D) i obr. snímků (2D), také u multispektrálních (nD) snímků při dálkovém průzkumu Země
- **analýza komplexních systémů** – např. chemických provozů, jaderných elektráren, apod. na základě množství signálů z fyzikálně různých senzorů (mechanických, chemických, elmg), mezi senzory existují tzv. přeslechy, smyslem BSS je získat čisté signály bez přeslechů





# Slepá separace zdrojů informace (signálů)

## Přehled metod

- Independent Component Analysis (ICA) ★★
- Principal Component Analysis (PCA) ★★
- Singular Value Decomposition (SVD) ★★
- Dependent Component Analysis
- Non-negative Matrix Factorization (NMF)
- Low-complexity Coding & Decoding
- Stationary Subspace Analysis (SSA)
- Common Spatial Pattern (CSP)
- a další...

Řada z nich vychází z relativně starých metod a postupů aplikovaných v ekonometrii, statistice, chemii, apod.



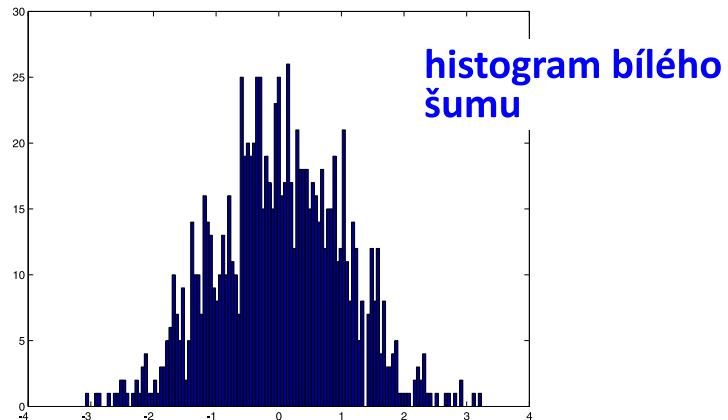
# Independent Component Analysis (ICA)

## Definice

**Analýza nezávislých komponent (ICA)** – výpočetní postup pro separaci vícerozměrného signálu, resp. směsi signálů, na aditivní komponenty za předpokladu statistické nezávislosti **ne-gaussovských** zdrojových signálů...



→ **POZOR:** Přímo z definice vyplývá, že ICA **nedokáže** ze směsi separovat např. **bílý šum** (je gaussovský)





# Independent Component Analysis (ICA)

## Definice z matematického pohledu

ICA je postup nalezení směšovací matice  $\mathbf{A}$ , resp. jejího odhadu, tj. „rozmíchávací“ matice  $\mathbf{W}$ ,  $\mathbf{W} = \mathbf{A}^{-1}$ , v daných vztazích

$$\mathbf{x}(t) = \mathbf{As}(t)$$
$$\mathbf{y}(t) = \mathbf{Wx}(t)$$

tak, aby statistická **nezávislost** separovaných komponent byla **nejvyšší možná**.

Míru statistické nezávislosti komponent je možné stanovit na základě řady různých metrik, např.:

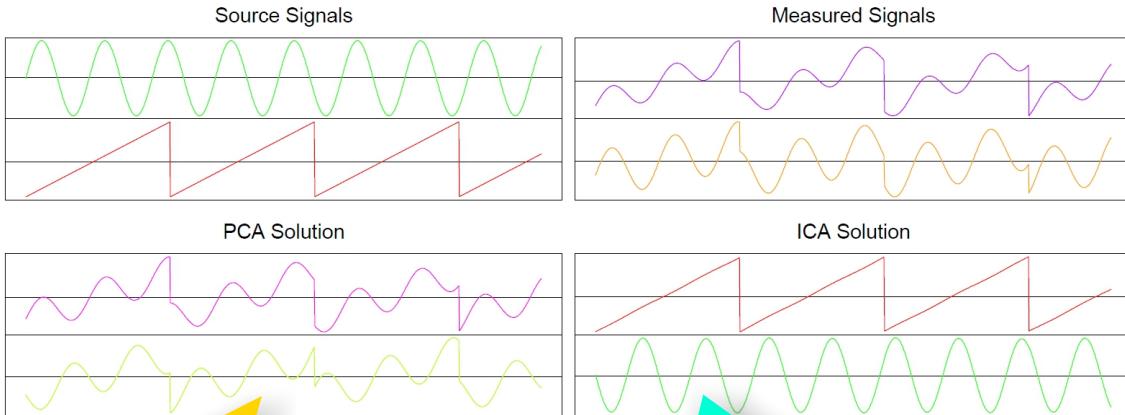
- entropie, příp. negentropie
- vzájemné informace (*Mutual Information*)
- koeficientu špičatosti (*Kurtosis*)
- apod.





# Independent Component Analysis (ICA)

## ICA není PCA



PCA maximalizuje **rozptyl dat**, tj. zajišťuje mezi komponentami v cílovém prostoru maximální vzdálenost

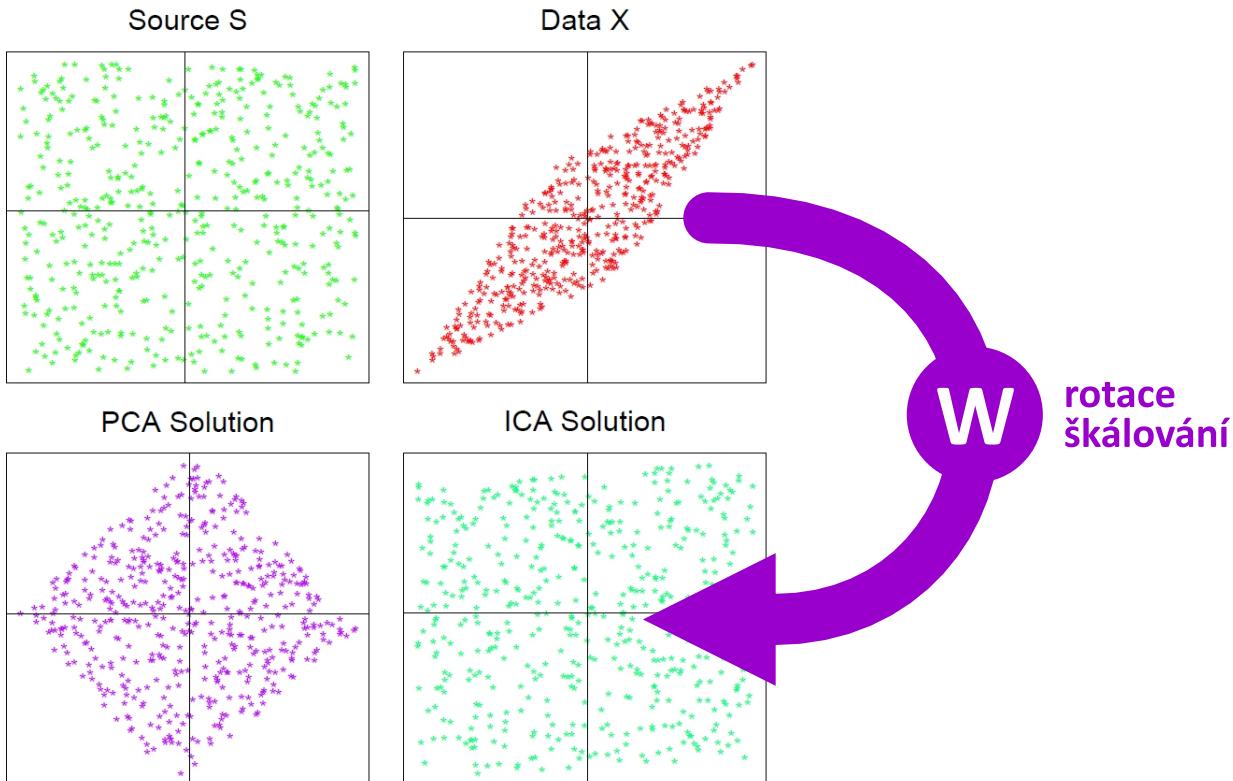
ICA maximalizuje **nezávislost komponent**, tj. hledá takovou transformaci, aby se od sebe komponenty co nejvíce lišily

(obrázek z knihy Hastie, Tibshirani, Friedman: The Elements of Statistical Learning)



# Independent Component Analysis (ICA)

## ICA není PCA



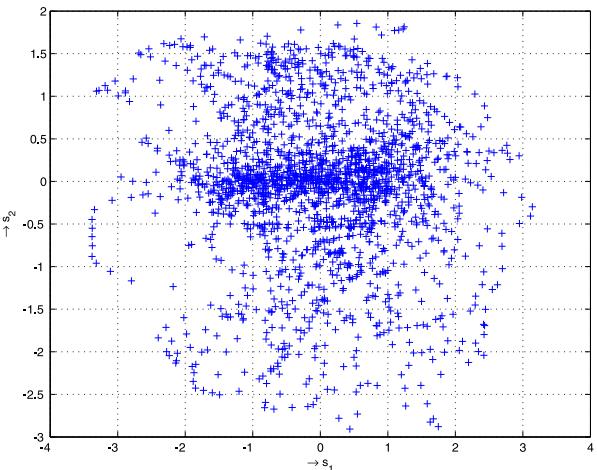
(obrázek z knihy Hastie, Tibshirani, Friedman: The Elements of Statistical Learning)



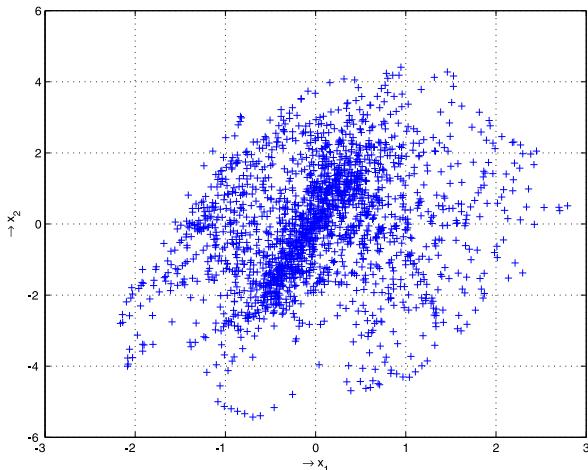
# Independent Component Analysis (ICA)

## Odvození algoritmu

Pův. signály  $s(t) = [s_1(t), s_2(t)]$



Směs  $x(t) = As(t)$



**Matematický model ICA:**

pozorujeme

$$x(t) = As(t)$$

chceme znát

$$y(t) = Wx(t)$$

vypočítá ICA

**JAK?**

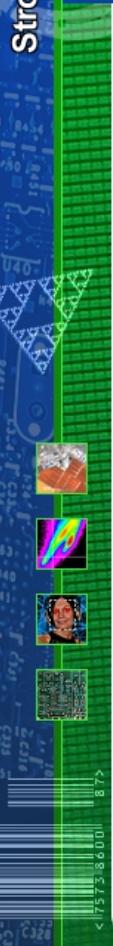
dostaneme odhad



# Independent Component Analysis (ICA)

## Nejednoznačnosti při ICA

- nelze určit rozptyl (energií) nezávislých komponent – z mat. modelu ICA je zřejmé, že neznáme-li ani  $s_i$ , ani  $A$ , pak libovolný skalár násobící některý ze zdrojů  $s_i$  může být kompenzován vydelením sloupce  $a_i$  matice  $A$  tímtož skálarem → tj. abs. hodnota energie signálu je volitelná...
  - nelze určit pořadí nezávislých komponent – jelikož neznáme ani  $s_i$ , ani  $A$ , můžeme pořadí sčítanců při směšování signálů maticí  $A$  chápat jako libovolné → tj. nelze říci, která z nezávislých komponent je první, druhá, atd.
-  Např. při odstraňování šumu apriori nevíme, který z výsledných odhadů signálů je šum (a jaká je jeho celková energie) a který je užitečný signál...





# Independent Component Analysis (ICA)

## Co je nezávislost?

Má-li ICA vypočítat odhad pův. signálů takový, aby jejich **vzájemná nezávislost byla co nejvyšší**, je třeba definovat nezávislost. To lze např.:

- pomocí **hustoty pravděpodobnosti**:

$p(y_1, y_2)$  je sdružená hustota pravděpodobnosti (*Probability Density Function, PDF*) náhodných proměnných  $y_1$  a  $y_2$ ,  $p_1(y_1)$  je pak marginální hustota p-sti daná takto:

$$p_1(y_1) = \int p(y_1, y_2) dy_2$$

a analogicky pro  $y_2$ . Potom  $y_1$  a  $y_2$  jsou nezávislé tehdy a jen tehdy, je-li sdružená hustota p-sti rozložitelná takto:

$$p(y_1, y_2) = p_1(y_1) p_2(y_2)$$

tj. známá hodnota  $y_1$  naprosto nic neříká o hodnotě  $y_2$ .



# Independent Component Analysis (ICA)

## Co je nezávislost?

Tento výraz lze zobecnit pro n náhodných proměnných, pak sdružená hustota musí být součinem n marginálních hustot.

Z uvedené definice lze odvodit jednu z **nejdůležitějších vlastností nezávislých náhodných proměnných**:

Mějme dvě funkce  $h_1$  a  $h_2$ , potom platí

$$E\{h_1(y_1)h_2(y_2)\} = E\{h_1(y_1)\}E\{h_2(y_2)\}$$

Náznak důkazu:

$$\begin{aligned} E\{h_1(y_1)h_2(y_2)\} &= \int \int h_1(y_1)h_2(y_2) p(y_1, y_2) dy_1 dy_2 \\ &= \int \int h_1(y_1) p_1(y_1) h_2(y_2) p_2(y_2) dy_1 dy_2 = \\ &= \int h_1(y_1) p_1(y_1) dy_1 \int h_2(y_2) p_2(y_2) dy_2 = \\ &= E\{h_1(y_1)\}E\{h_2(y_2)\} \end{aligned}$$

očekávaná/střední hodnota náh. prom.



# Nezávislost náhodných proměnných

## Jsou nekorelované proměnné nezávislé?

**Nekorelovanost** je slabší forma nezávislosti: Dvě náhodné proměnné jsou nekorelované tehdy, je-li jejich **kovariance** nulová:

$$E\{y_1 y_2\} - E\{y_1\} E\{y_2\} = 0$$

Jsou-li proměnné nezávislé, pak jsou nekorelované (to vyplývá z výrazu na předchozím snímku, dosadíme-li za  $h_1(y_1) = y_1$  a  $h_2(y_2) = y_2$ ). **Obrácená implikace však neplatí!**

Důkaz: Mějme diskrétní proměnné  $y_1, y_2$  takové, že pár  $(y_1, y_2)$  nabývá s pravděpodobností 0.25 kteroukoliv z hodnot  $(0, 1), (0, -1), (1, 0)$  a  $(-1, 0)$ . Pak lze snadno spočítat, že  $y_1$  a  $y_2$  jsou nekorelované, ale nejsou nezávislé, protože

$$E\{y_1^2 y_2^2\} = 0 \neq \frac{1}{4} = E\{y_1^2\} E\{y_2^2\}$$



# Omezení ICA

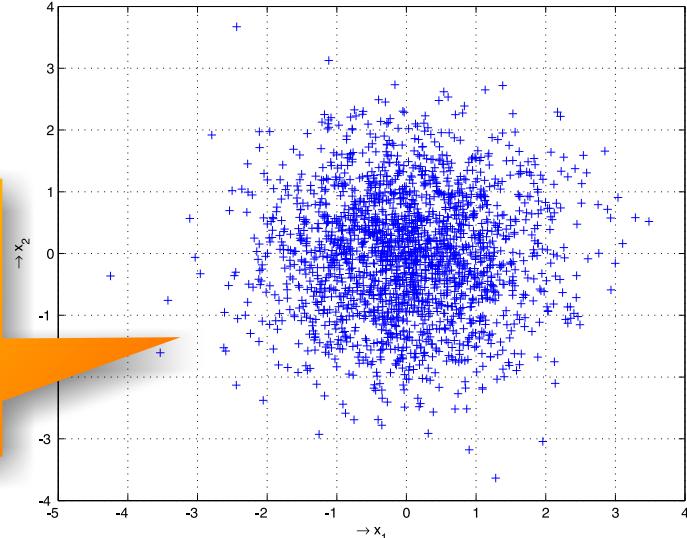
## Proč nelze separovat gaussovské proměnné?

Jsou-li směšované signály  $s_i$  gaussovské a směšovací matice  $\mathbf{A}$  ortogonální, pak směsi  $x_i$  jsou gaussovské, nekorelované, s jednotkovým rozptylem. Jejich sdružená hustota p-sti je

$$p(x_1, x_2) = \frac{1}{2\pi} \exp\left(-\frac{x_1^2 + x_2^2}{2}\right)$$

což vypadá takto:

Distribuuje je zcela symetrická, a tudíž neobsahuje žádnou informaci o směru vektorů/sloupců matice  $\mathbf{A}$ .  
Proto nelze  $\mathbf{A}$  odhadnout!





# Princip ICA

## Negaussovské je nezávislé...

**Centrální limitní věta (CLV):** Rozdělení pravosti součtu nezávislých náhodných proměnných (za určitých podmínek) konverguje k normálnímu, tj. gaussovskému rozdělení.

Odtud plyne, že součet dvou nezávislých náhodných proměnných má rozdělení blíže normálnímu, než obě sčítané náhodné proměnné.

Hledáme vektor  $w$  – řádek matice  $W$  inverzní k  $A$ : označíme  $z = A^T w$ , pak  $y = w^T x = w^T A s = z^T s$ , tj.  $y$  je lineární kombinací zdrojových signálů  $s_i$  váhovaných hodnotou  $z_i$ .

Jelikož platí CLV, pak lineární kombinace signálů  $z^T s$  je více gaussovská, než kterýkoliv ze zdrojových signálů samotných.



# Princip ICA

## Negaussovské je nezávislé...

Nejméně gaussovská je pak směs  $\mathbf{z}^T \mathbf{s}$  tehdy, rovná-li se právě jednomu ze zdrojových signálů – tehdy je zřejmě pouze jedna složka  $z_i$  vektoru  $\mathbf{z}$  nenulová...

Hledáme tedy vektor  $\mathbf{w}$  takový, aby součin  $\mathbf{w}^T \mathbf{x}$  byl co nejméně gaussovský.

Takový vektor  $\mathbf{w}$  nutně odpovídá (v transformovaném souřadnicovém systému) vektoru  $\mathbf{z}$  s jedinou nenulovou složkou.

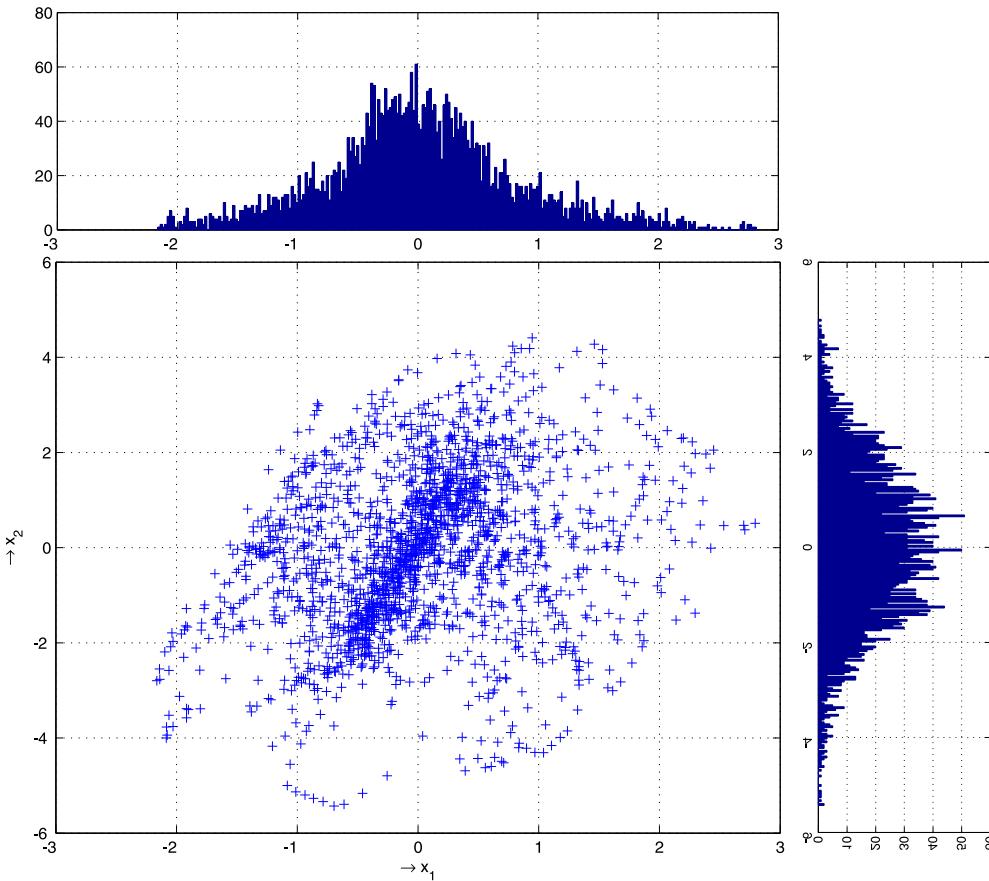
To znamená, že  $\mathbf{w}^T \mathbf{x} = \mathbf{z}^T \mathbf{s}$ , což je pak právě jedna z nezávislých komponent směsi... stačí najít

→ potřebujeme míru „negaussovskosti“ a alg. optimalizace



# Princip ICA

## Negaussovské je nezávislé...





# Míry „negaussovskosti”

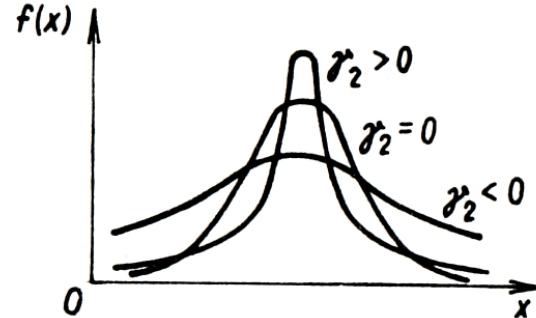
## Koeficient špičatosti čili exces (*Kurtosis*)

Klasická míra „negaussovskosti“ je tzv. **koeficient špičatosti** neboli **exces (kurtosis)**:

$$\text{kurt}(y) = E\{y^4\} - 3(E\{y^2\})^2$$

Protože jsme přepokládali, že  $y$  má jednotkový rozptyl, pravá strana se redukuje na  $E(y^4) - 3$ , tj. exces je vlastně normalizovaný centrální moment 4. řádu  $E(y^4)$ .

**Gaussovská náhodná  
proměnná má exces  
nulový.**



Obr. 430. Druhy excesu  $\gamma_2$  při symetrickém rozdělení s týmž průměrem (pro  $\gamma_2 = 0$  jde o normální rozložení)

(obrázek z knihy H.-J. Bartsch:  
Matematické vzorce)



# Míry „negaussovskosti”

## Koeficient špičatosti čili exces (*Kurtosis*)

Exces teoreticky může být použit jako optimalizační kritérium při výpočtu ICA, ale **v praxi** (když exces počítáme z naměřených hodnot či navzorkovaného signálu) **to není rozumné**:

- je bohužel velmi citlivý na marginální hodnoty – jedený např. chybně zaznamenaný vzorek může hodnotu excesu značně pozměnit
- nejdá se o dostatečně robustní míru „negaussovskosti”
- existují jiné míry, lépe přizpůsobené reálnému nasazení





# Míry „negaussovskosti”

## Negentropie

**Entropie náhodné proměnné** je množství informace, kterou tato náh. proměnná nese. Čím je „více náhodná“, tj. méně predikovatelná a uspořádaná, tím je vyšší její entropie.

Přesněji (za určitých zjednodušujících předpokladů) je entropie náhodné proměnné délka kódování takové proměnné.

Entropie  $H$  náhodné proměnné  $Y$  je definovaná takto:

$$H(Y) = - \sum_i P(Y = a_i) \log P(Y = a_i)$$

kde  $a_i$  jsou hodnoty, jichž může  $Y$  nabývat.

**Zásadní poznatek z teorie informace:** Gaussovská náhodná proměnná má nejvyšší entropii ze všech náh. proměnných se stejným rozptylem.



# Míry „negaussovskosti”

## Negentropie

→ entropii lze využít jako míru „negaussovskosti”, **gaussovské rozdělení p-sti je nejnáhodnější ze všech**, zatímco u rozdělení, u nichž hustota p-sti roste kolem nějakých specifických hodnot, je entropie malá...

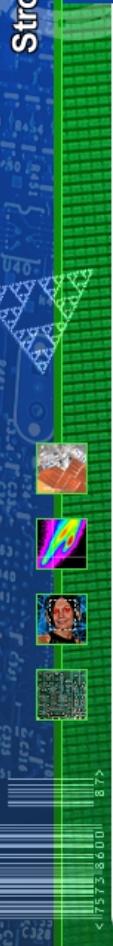
Jelikož chceme míru „negaussovskosti”, která je nulová pro gaussovskou proměnnou a vždy nezáporná, definujeme tzv. **negentropii J** (vlastně přizpůsobenou diferenciální entropii):

$$J(\mathbf{y}) = H(\mathbf{y}_{gauss}) - H(\mathbf{y})$$

$\mathbf{y}_{gauss}$  je gaussovská náhodná proměnná se stejnou kovarianční maticí jako  $\mathbf{y}$ .



Negentropie je ze statistického hlediska optimálním odhadem „negaussovskosti“ náhodné proměnné.





# Míry „negaussovskosti”

## Aproximace negentropie



**Negentropii je velmi obtížné získat výpočetně – je třeba využít pro výpočet ICA její jednodušší approximace:**

$$J(y) \approx \frac{1}{12} E\{y^3\}^2 + \frac{1}{48} \text{kurt}(y)^2$$

$$J(y) \approx \sum_{i=1}^p k_i [E\{G_i(y)\} - E\{G_i(v)\}]^2$$

kde  $k_i$  jsou kladné konstanty,  $v$  je gaussovská náh. proměnná se stř. hodnotou 0 a jednotkovým rozptylem; proměnná  $y$  by měla mít  $\mu = 0$  a  $\sigma^2 = 1$  (předpoklad). Funkce  $G_i$  jsou nějaké nekvadratické funkce, např. se osvědčila volba

$$G_1(u) = \frac{1}{a_1} \log \cosh a_1 u, \quad G_2(u) = -\exp(-u^2/2)$$

kde  $1 \leq a_1 \leq 2$ . (Hyvärinen, Oja, 2000)



# Další možnosti ICA

## Minimalizace vzájemné informace

**Vzájemná informace (Mutual Information)** – přirozená míra vzájemné závislosti dvou (nebo více) náhodných (skalárních) proměnných, nejběžnějším vyjádřením míry je **bit**.

### Definice vzájemné informace:

Mějme diskrétní náhodné proměnné X a Y. Pak

$$I(X, Y) = \sum_{y \in Y} \sum_{x \in X} p(x, y) \log \left( \frac{p(x, y)}{p(x)p(y)} \right)$$

kde  $p(x, y)$  je sdružená hustota p-sti X a Y, a  $p(x)$  a  $p(y)$  jsou marginální hustoty X a Y.

**I(X, Y) = 0 tehdy a jen tehdy, jsou-li X a Y nezávislé.**

D: Jsou-li nezávislé, pak  $p(x, y) = p(x)p(y)$ , atd.



# Další možnosti ICA

## Vztah vzájemné informace a (neg)entropie

$$\begin{aligned}
 I(X, Y) &= H(X) - H(X|Y) \xleftarrow{\text{podmíněná entropie}} \\
 &= H(Y) - H(Y|X) \\
 &= H(X) + H(Y) - H(X, Y) \xleftarrow{\text{sduřená entropie}} \\
 &= H(X, Y) - H(X|Y) - H(Y|X)
 \end{aligned}$$

marginální entropie

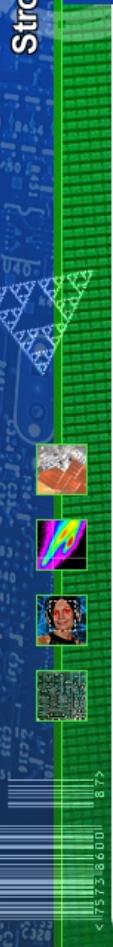
(Papoulis, 1991) a (Cover a Thomas, 1991) ukázali, že pro vratnou lineární transformaci  $\mathbf{y} = \mathbf{W}\mathbf{x}$  platí:

$$I(y_1, y_2, \dots, y_n) = \sum_i H(y_i) - H(\mathbf{x}) - \log |\det \mathbf{W}|$$

z čehož lze (poměrně složitě) odvodit základní vztah mezi vzájemnou informací a negentropií:

$$I(y_1, y_2, \dots, y_n) = C - \sum_i J(y_i)$$

kde  $C$  je konstanta nezávislá na  $\mathbf{W}$ .

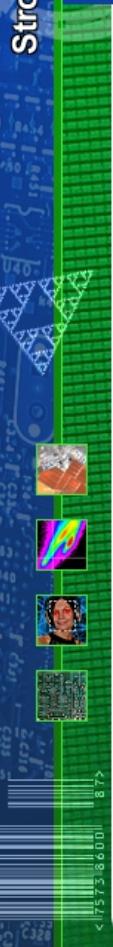




# Další možnosti ICA

## Některé další odhady vzájemné závislosti

- **Maximum Likelihood Estimation (MLE)** – v podstatě ekvivalent minimalizace vzájemné informace...
- **Princip Infomax (*The Infomax Principle*)** – pův. použit v neuronových sítích za účelem maximalizace entropie výstupní vrstvy, pro potřeby ICA rozpracován v roce 1995 Bellem a Sejnowskim...
- zřejmě je možné vyjádřit nezávislost náhodných proměnných/signálů ještě řadou dalších postupů, mnohé jsou adaptované na konkrétní charakter signálů, atp.





# Předzpracování dat pro ICA

## Ustředění (*Centering*)

**Signál nesmí mít tzv. *offset*, tzn. jeho střední hodnota musí být nulová.**

Toho dosáhneme tím, že od pozorované směsi signálů  $\mathbf{x}(t)$  odečteme střední hodnotu  $E(\mathbf{x}(t))$ :

MATLAB

$$x_i(t) = x_i(t) - E(x_i(t))$$

```
x(:, 1) = x(:, 1) - mean(X(:, 1));  
x(:, 2) = x(:, 2) - mean(X(:, 2));
```

Smyslem ustředění je zjednodušit algoritmus ICA – neznamená to, že by nebylo možné offset výpočtem ICA odhadnout...

Pokud je v datech offset významný (což např. u audiosignálů **není**), pak je třeba k výslednému odhadu „rozmíchaných“ signálů jejich offsety získané při předzpracování opět přičíst...



# Předzpracování dat pro ICA Bělení (*Whitening*)

Lineární transformace pozorované směsi signálů  $\mathbf{x}(t)$  taková, že složky transformované směsi jsou nekorelované a jejich rozptyl je jednotkový, tzn. kovarianční matice  $\bar{\mathbf{x}}(t)$  se rovná jednotkové, tj.  $E\{\bar{\mathbf{x}}(t) \bar{\mathbf{x}}(t)^T\} = \mathbf{I}$ :

MATLAB

$$x_i(t) = x_i(t) / \sqrt{D(x_i(t))}$$

$$\begin{aligned} x(:, 1) &= x(:, 1) / \text{std}(x(:, 1)); \\ x(:, 2) &= x(:, 2) / \text{std}(x(:, 2)); \end{aligned}$$

Provádí se **po** ustředění signálu, **před** výpočtem ICA. Nejsnazší postup bělení je vydělení složek jejich směrodatnými odchylkami...





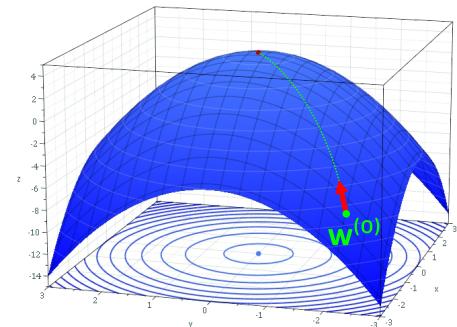
# Jednoduchý algoritmus ICA

## Gradientní metoda odhadu pomocí excesu

### Algoritmus:

- (1) inicializace váhového vektoru  $w$  (náhodně)
- (2) *sphering*, tj. SVD matice směsi  $X = USV^T$
- (3) **for**  $i \leftarrow 1 ..$  maximální zvolený počet iterací
  - (a) odhad approximace „rozmíchaného“ signálu  $y \leftarrow Uw^T$
  - (b) výpočet gradientu  $g$  z odhadu excesu  $y$
  - (c) oprava váhového vektoru  $w$ :  $w \leftarrow w + \delta g$
  - (d) normalizace váhového vektoru  $w$ :  $w \leftarrow w / |w|$

**Gradientní metoda –**  
iterační algoritmus, další kroky  
se konají ve směru gradientu  
(detailly viz MA či NM)  
(obrázek z Wikimedia Commons)





# Jednoduchý algoritmus ICA

## Zápis algoritmu v MATLABu

```
% spherizing data
[U D V] = svd(X, 0);      % "ekonomická" dekompozice (viz ML>> help svd)
Z = U;
Z = Z ./ repmat(std(Z, 1), n, 1);

%
%
% ICA
%
%

w = randn(1, m);          % "rozmichávací" vektor inicializovaný náhodně
w = w / norm(w);          % normalizovaný
y = Z * w';                % počáteční odhad approximace zdrojového signálu

max_iters = 500;           % maximální počet iterací
delta = 2e-2;                % velikost kroku gradientní metody

for i = 1:max_iters
    y = Z * w';
    k = mean(y .^ 4) - 3;    % odhad koeficientu špičatosti (kurtosis)

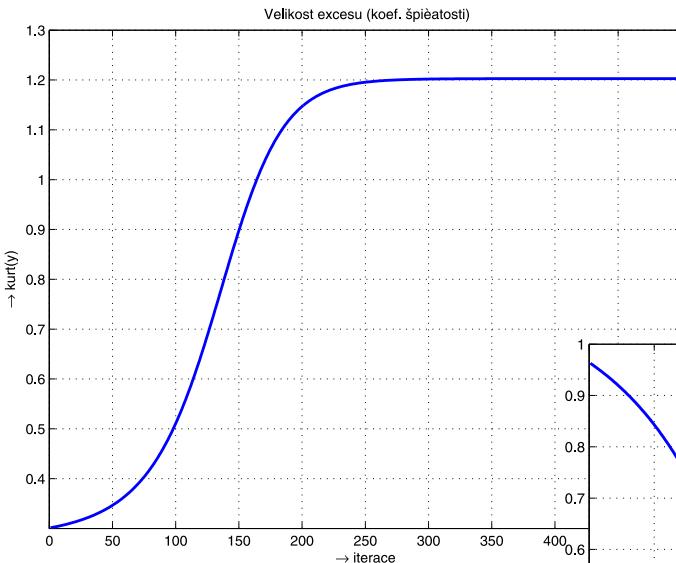
    % výpočet gradientu
    ycub = y .^ 3;
    ycubr = repmat(ycub, 1, 2);
    g = mean(ycubr .* Z);

    % oprava "rozmichávací" matici W tak, aby se zvýšil koef. špičatosti
    w = w + delta * g;
    w = w / norm(w);
end
```



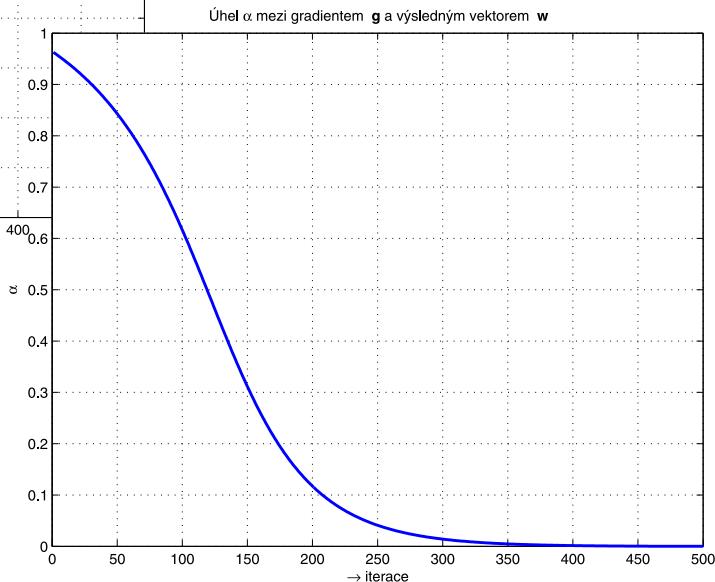
# Jednoduchý algoritmus ICA

## Volba počtu iterací



Velikost excesu by měla konvergovat k nějakému lokálnímu maximu...

Počet iterací volíme podle vývoje velikosti excesu a úhlu mezi gradientem a výsledným váhovým vektorem...





# Sofistikované algoritmy ICA

## Co lze využít při reálném nasazení?

- **FastICA** –

*H. Gävert, J. Hurri, J. Särelä, A. Hyvärinen (Helsinki UT),  
k dispozici pod GPL pro MATLAB, jako součást knihovny  
IT++ také pro C++, pro Javu knihovna FastICA for Java*

<http://research.ics.aalto.fi/ica/fastica/>  
<http://www.fastica.org/>

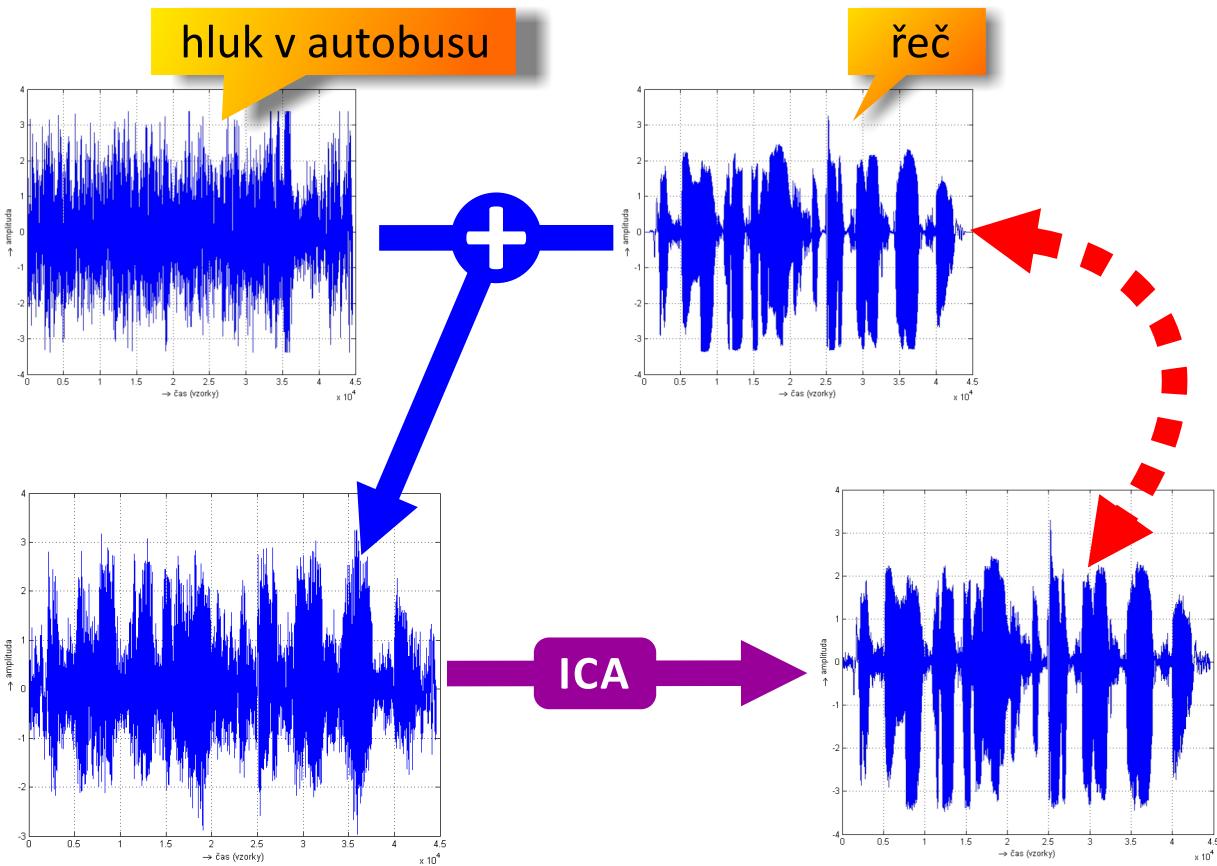
- **MILCA** (Mutual Information Least-dependent Comp. A.) –  
*H. Stögbauer, A. Kraskov, S. Astachov a P. Grassberger  
(Caltech),  
k dispozici pod GPL pro MATLAB a C*

<http://www.klab.caltech.edu/~kraskov/MILCA/>



# Ukázky použití ICA

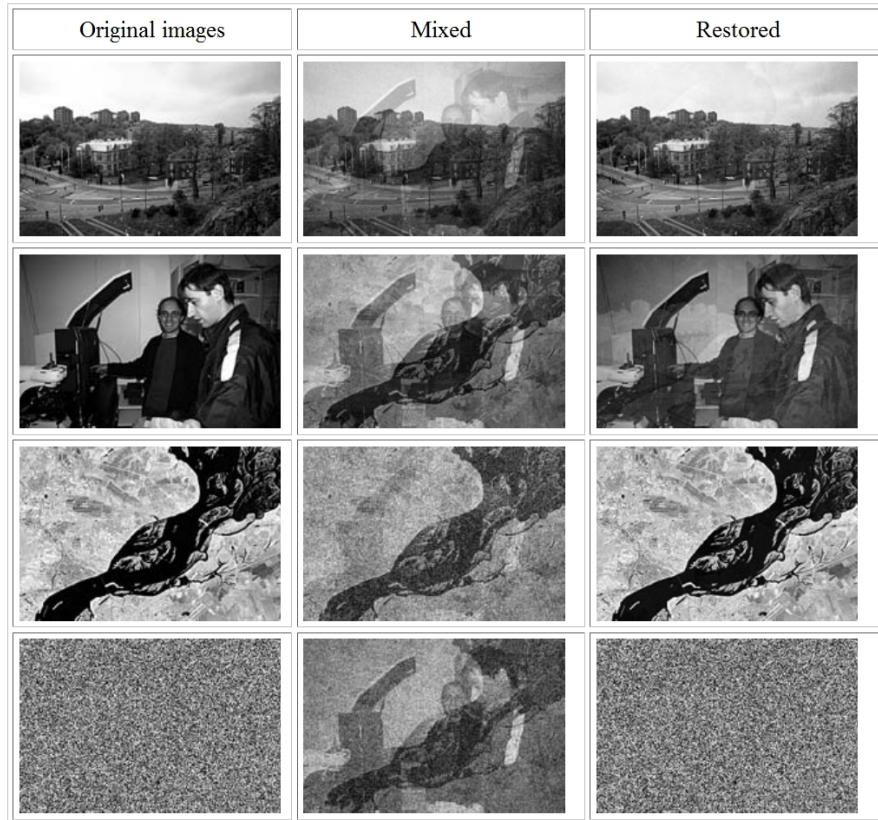
## Odstrannění hluku na pozadí audiosignálu





# Ukázky použití ICA

## Odstranění nežádoucího obsahu ze snímku

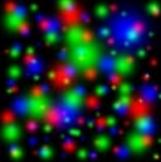
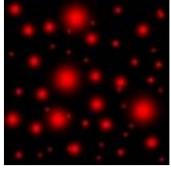
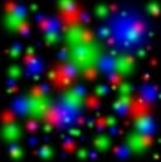
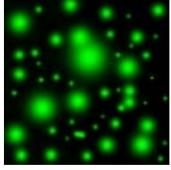
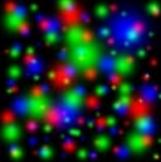
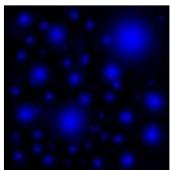


(obrázek z <http://www.klab.caltech.edu/~kraskov/MILCA/demo/demo.html>)



# Ukázky použití ICA

## Slepá separace spektrálních komponent

Grayscale-coded abundances	Mixture image (RGB)	Decomposed
red		
green		
blue		

(obrázek z <http://www.klab.caltech.edu/~kraskov/MILCA/demo/demo.html>)