



Strojové učení

2 Lineární regrese – I

- Lineární regrese jedné proměnné
- Odvození cenové funkce
- Minimalizace cenové funkce
- Odvození gradientní metody
- Algoritmus gradientního sestupu





Lineární regrese

Nejjednodušší algoritmus učení s učitelem

- myšlenky vychází z „předpočítáčového“ období statistiky
- nejjednodušší algoritmus → na praktické úlohy z oblasti UI obvykle nepoužitelný, ale představuje základní stavební prvek a **pochopitelným způsobem demonstruje fundamentální myšlenky techniky regrese**
- jednoduchá, tj. poskytuje snadno interpretovatelný popis toho, jak vstupní data ovlivňují data výstupní
- při predikci často překonává komplikovanější nelineární metody, zejména je-li málo trénovacích dat, jsou-li data znehodnocená šumem nebo velmi řídká
- lineární regresi lze aplikovat na transformace vstupních dat, což značně rozšiřuje možnosti využití → **metody bázových funkcí (Basis-Function Methods)**, např. RBF, GRBF, ...

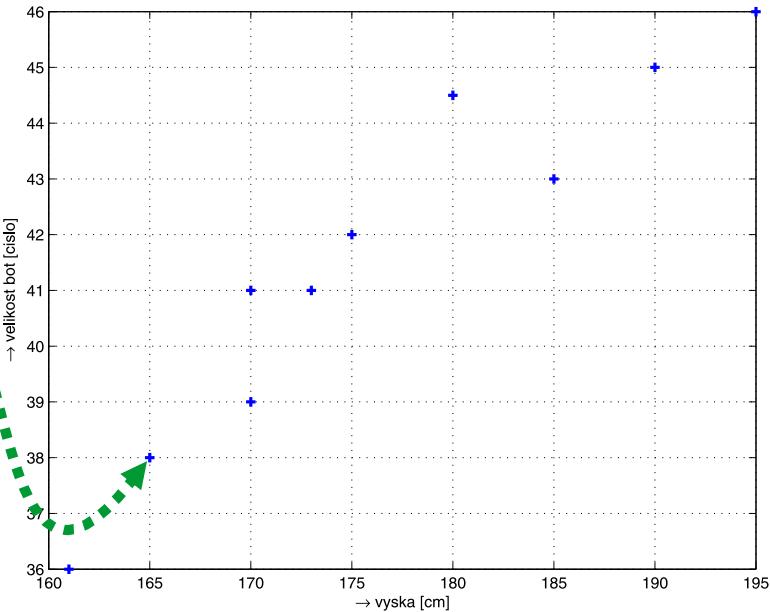


Lineární regrese

Motivační příklad

Závislost čísla bot
na výšce osoby

- **učení s učitelem**
(známe „správné“ odpovědi v trénovací množině)
- **regresní úloha**
(odhadovaný výstup je spojitý)

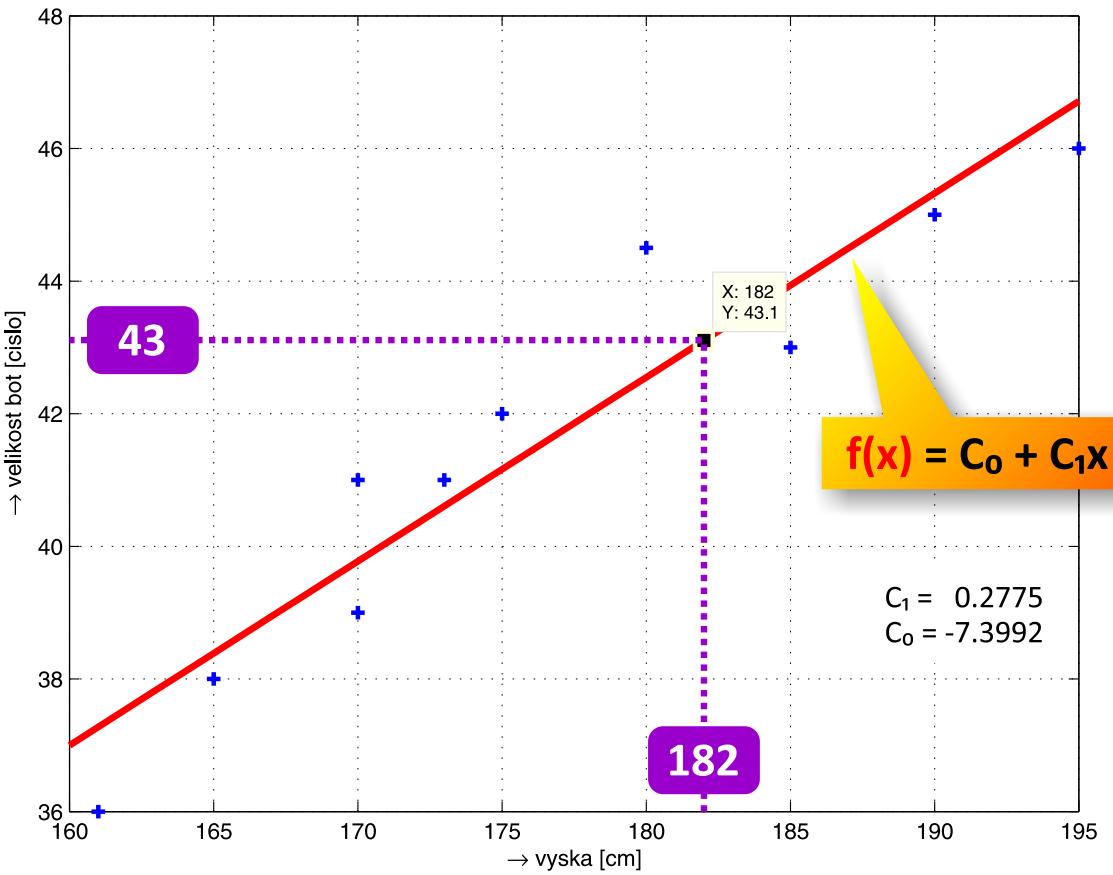


➔ potřebujeme data proložit **lineární funkcí** tak, abychom mohli pro libovolnou hodnotu vstupu (tj. výšky osoby na ose x) předpovědět velikost obuvi...



Lineární regrese

Motivační příklad





Lineární regrese

Motivační příklad – trénovací množina

Trénovací množina – pozorované páry (výška osoby, velikost obuvi)

Trénovací vzorek – např. $(x^{(5)}, y^{(5)})$

Značení:

m – celkový počet trénovacích vzorků (tj. velikost trénovací množiny čili počet řádek)

x – vstup (proměnná, obecně vektor příznaků)

y – výstup (proměnná, obvykle skalární výsledná predikovaná hodnota)

shoes <10x2 double>

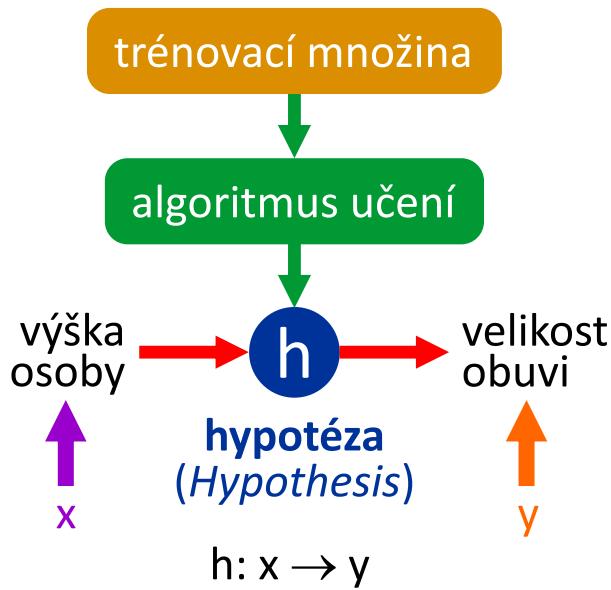
	1	2
1	161	36
2	165	38
3	170	39
4	170	41
5	173	41
6	175	42
7	180	44.5000
8	185	43
9	190	45
10	195	46

↑ $x^{(i)}$ ↑ $y^{(i)}$



Lineární regrese

Schéma učení s učitelem



Reprezentace hypotézy h :

$$h_{\Theta}(x) = \Theta_0 + \Theta_1 x \\ (\text{nebo krátce } h(x))$$

Lineární regrese jedné proměnné (*Univariate Linear Regression*)

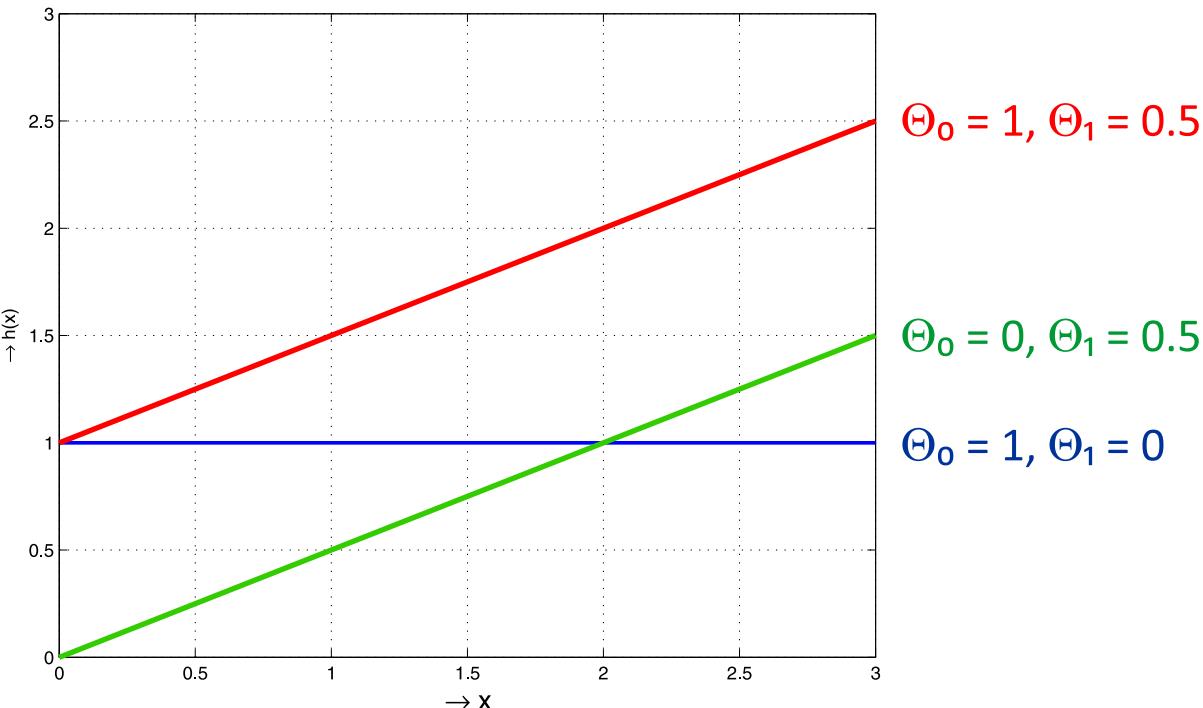
Matematický model hypotézy závisí na 2 parametrech Θ_0, Θ_1



Cenová funkce

Jak nastavit parametry hypotézy?

Hypotéza $h_{\Theta}(x)$ má tvar lineární funkce $h_{\Theta}(x) = \Theta_0 + \Theta_1 x$, tj.:





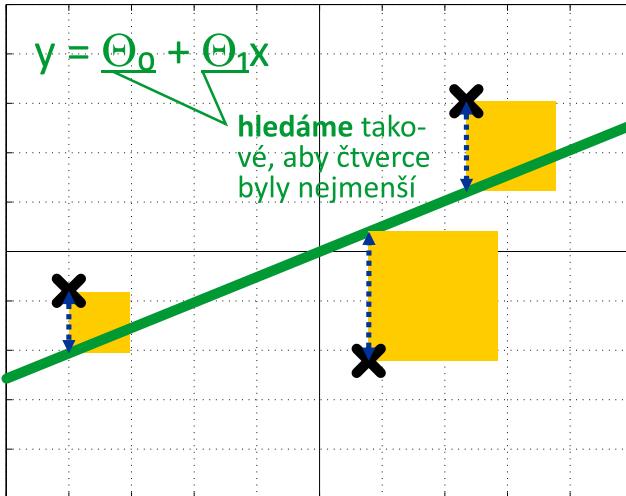
Cenová funkce

Jak nastavit parametry hypotézy?

Základní myšlenka: stanovit Θ_0, Θ_1 tak, aby hodnoty predikované hypotézou $h_{\Theta}(x)$ pro $x^{(i)}$ z trénovací množiny byly **co nejblíže** hodnotám $y^{(i)}$

z trénovací množiny:

$$\arg \min_{\Theta_0, \Theta_1} \left(\frac{1}{2m} \sum_{i=1}^m (h_{\Theta}(x^{(i)}) - y^{(i)})^2 \right)$$



$$J(\Theta_0, \Theta_1)$$

**cenová/pokutová funkce
(Cost Function)**

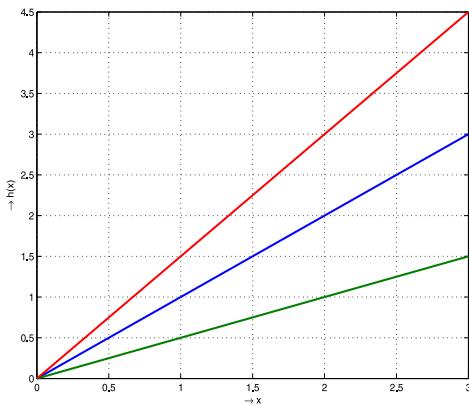
→ hledáme takové parametry Θ_0 a Θ_1 , pro které nabývá $J(\Theta_0, \Theta_1)$ minima...



Cenová funkce

Odvození – zjednodušená varianta

Pro získání představy o fungování cenové funkce zjednodušíme hypotézu na tvar $h_{\Theta}(x) = \Theta_1 x$ (bude procházet počátkem s. s.):



Cenová funkce bude pak mít tento tvar:

$$\begin{aligned} J(\Theta_1) &= \frac{1}{2m} \sum_{i=1}^m (h_{\Theta}(x^{(i)}) - y^{(i)})^2 \\ &= \frac{1}{2m} \sum_{i=1}^m (\Theta_1 x^{(i)} - y^{(i)})^2 \end{aligned}$$

Tuto cenovou funkci budeme minimalizovat, abychom našli optimální nastavení parametru Θ_1 ...

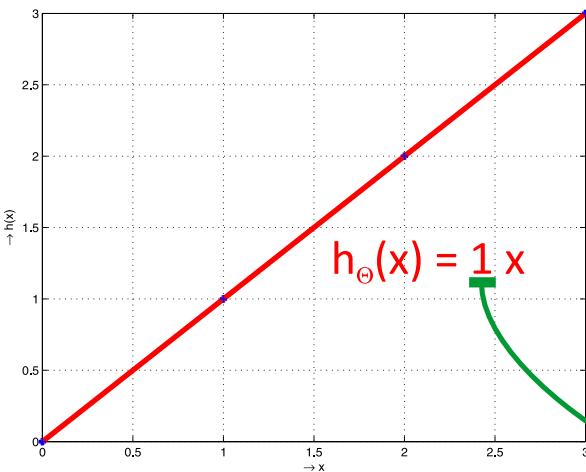


Cenová funkce

Odvození – zjednodušená varianta

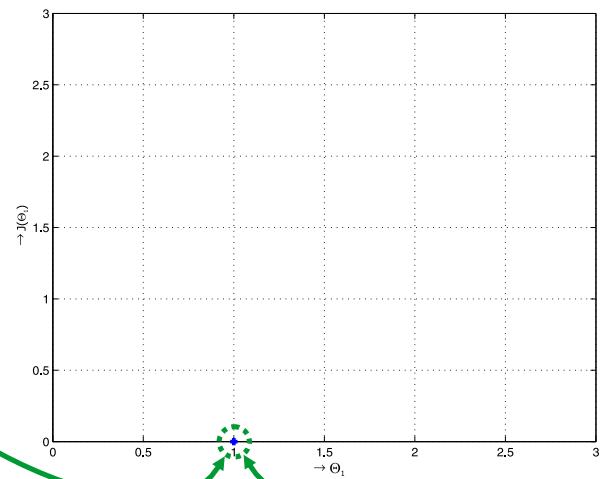
$$h_{\Theta}(x)$$

(pro dané Θ_1 je funkcí x)



$$J(\Theta_1)$$

(funkce parametru Θ_1)



$$J(\Theta_1) = \frac{1}{2m} \sum_{i=1}^m (\Theta_1 x^{(i)} - y^{(i)})^2 = \frac{1}{2 \cdot 3} (0^2 + 0^2 + 0^2) = 0$$

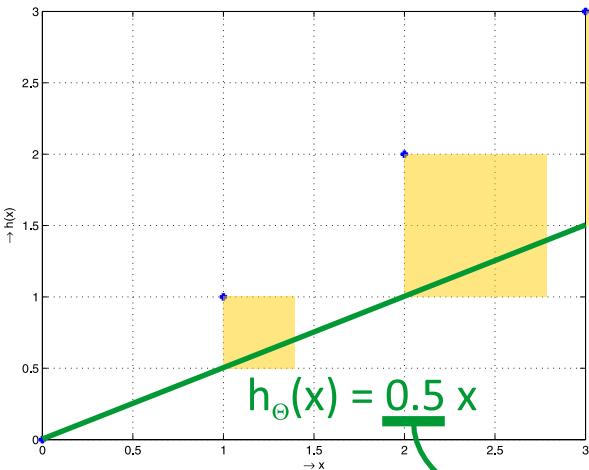


Cenová funkce

Odvození – zjednodušená varianta

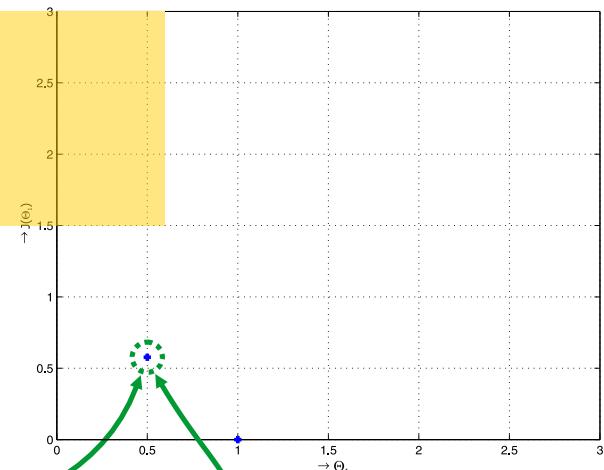
$$h_{\Theta}(x)$$

(pro dané Θ_1 je funkcí x)



$$J(\Theta_1)$$

(funkce parametru Θ_1)



$$J(\Theta_1) = \frac{1}{2 \cdot 3} \left(\left(\frac{1}{2} \right)^2 + 1^2 + \left(\frac{3}{2} \right)^2 \right) = 0.583$$

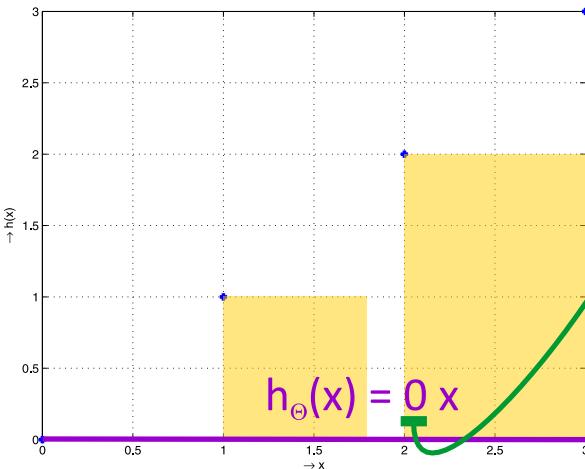


Cenová funkce

Odvození – zjednodušená varianta

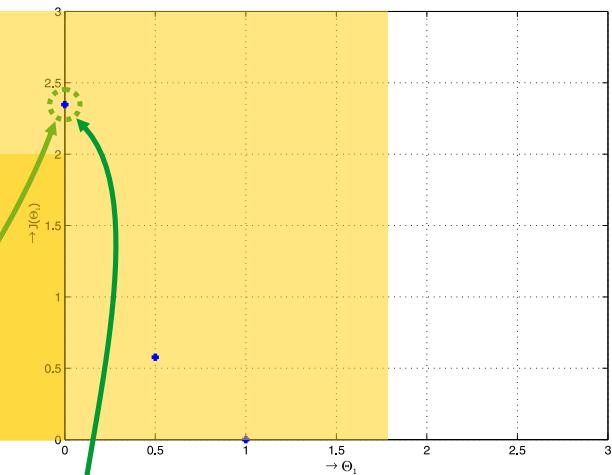
$$h_{\Theta}(x)$$

(pro dané Θ_1 je funkcí x)



$$J(\Theta_1)$$

(funkce parametru Θ_1)



$$J(\Theta_1) = \frac{1}{2 \cdot 3} (1^2 + 2^2 + 3^2) = 2.\overline{3}$$

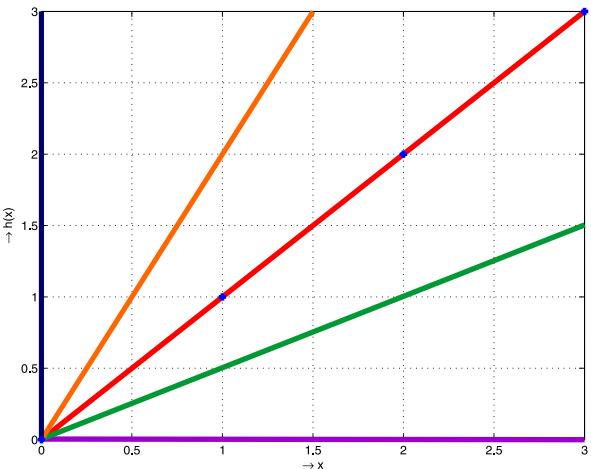


Cenová funkce

Odvození – zjednodušená varianta

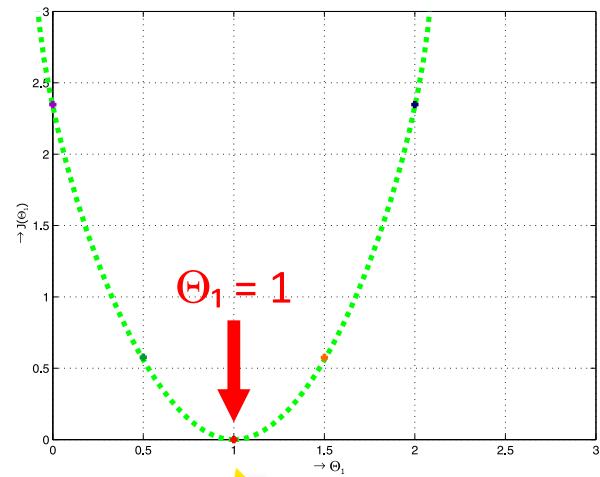
$$h_{\Theta}(x)$$

(pro dané Θ_1 je funkcí x)



$$J(\Theta_1)$$

(funkce parametru Θ_1)



$$\arg \min_{\Theta_1} J(\Theta_1) = 1$$



Cenová funkce

Odvození – varianta pro příklad s obuví

- **hypotéza** má tvar $h_{\Theta}(x) = \Theta_0 + \Theta_1 x$
- **parametry** jsou tedy Θ_0, Θ_1
- **cenová funkce** je $J(\Theta_0, \Theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\Theta}(x^{(i)}) - y^{(i)})^2$
- cílem **optimalizace** je nalézt takové argumenty Θ_0, Θ_1 cenové funkce $J(\Theta_0, \Theta_1)$, aby pro ně funkce nabývala minima, tj. minimalizace funkce $J(\Theta_0, \Theta_1)$, neboli:

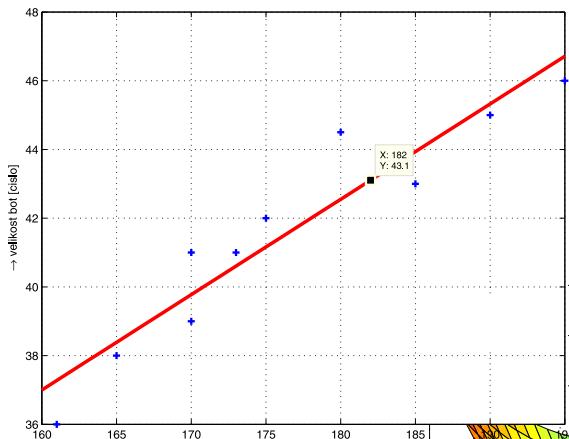
$$\arg \min_{\Theta_0, \Theta_1} \left(\frac{1}{2m} \sum_{i=1}^m (h_{\Theta}(x^{(i)}) - y^{(i)})^2 \right)$$





Cenová funkce

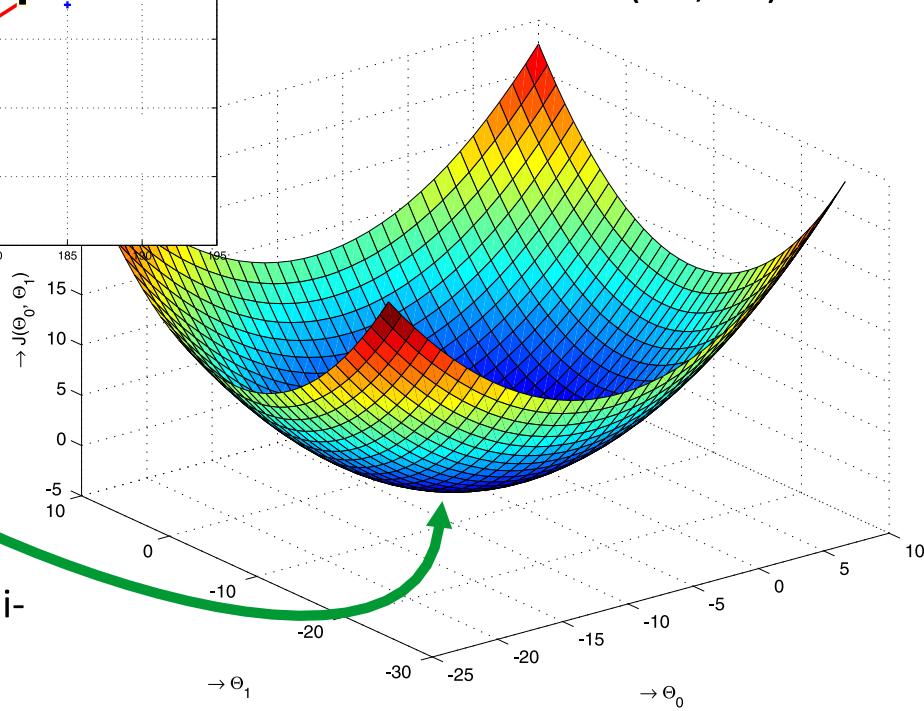
Odvození – varianta pro příklad s obuví



$$\Theta_0 = -7.3992$$
$$\Theta_1 = 0.2775$$

cenová funkce nabývá minima na souřadných (-7.3992, 0.2775)

cenová funkce $J(\Theta_0, \Theta_1)$



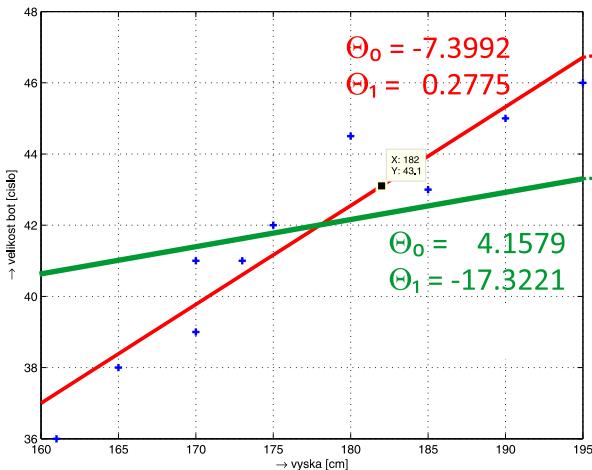


Cenová funkce

Odvození – varianta pro příklad s obuví

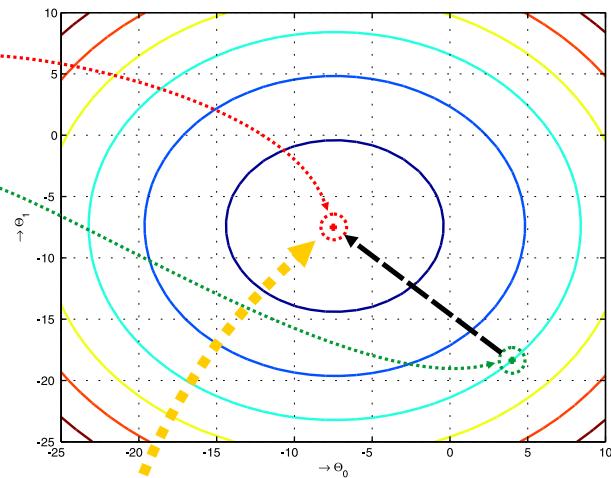
$$h_{\Theta}(x)$$

(pro dané Θ_0, Θ_1 je funkcí x)



$$J(\Theta_0, \Theta_1)$$

(funkce parametrů Θ_0, Θ_1)



Jak nalézt (numericky) minimum cenové funkce $J(\Theta_0, \Theta_1)$?

Pomocí techniky gradientního sestupu (Gradient Descent)...



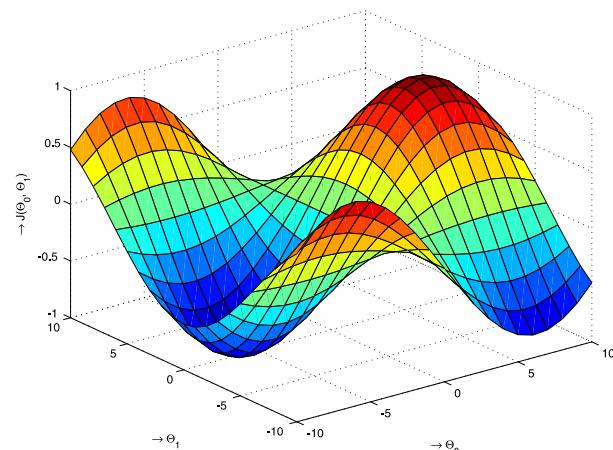
Gradientní sestup (*Gradient Descent*)

Nástin algoritmu

Je **dána** cenová funkce $J(\Theta_0, \Theta_1)$ nebo obecně $J(\Theta_0, \dots, \Theta_n)$. Chceme najít hodnoty Θ_i , pro které **nabývá minima**.

Postup:

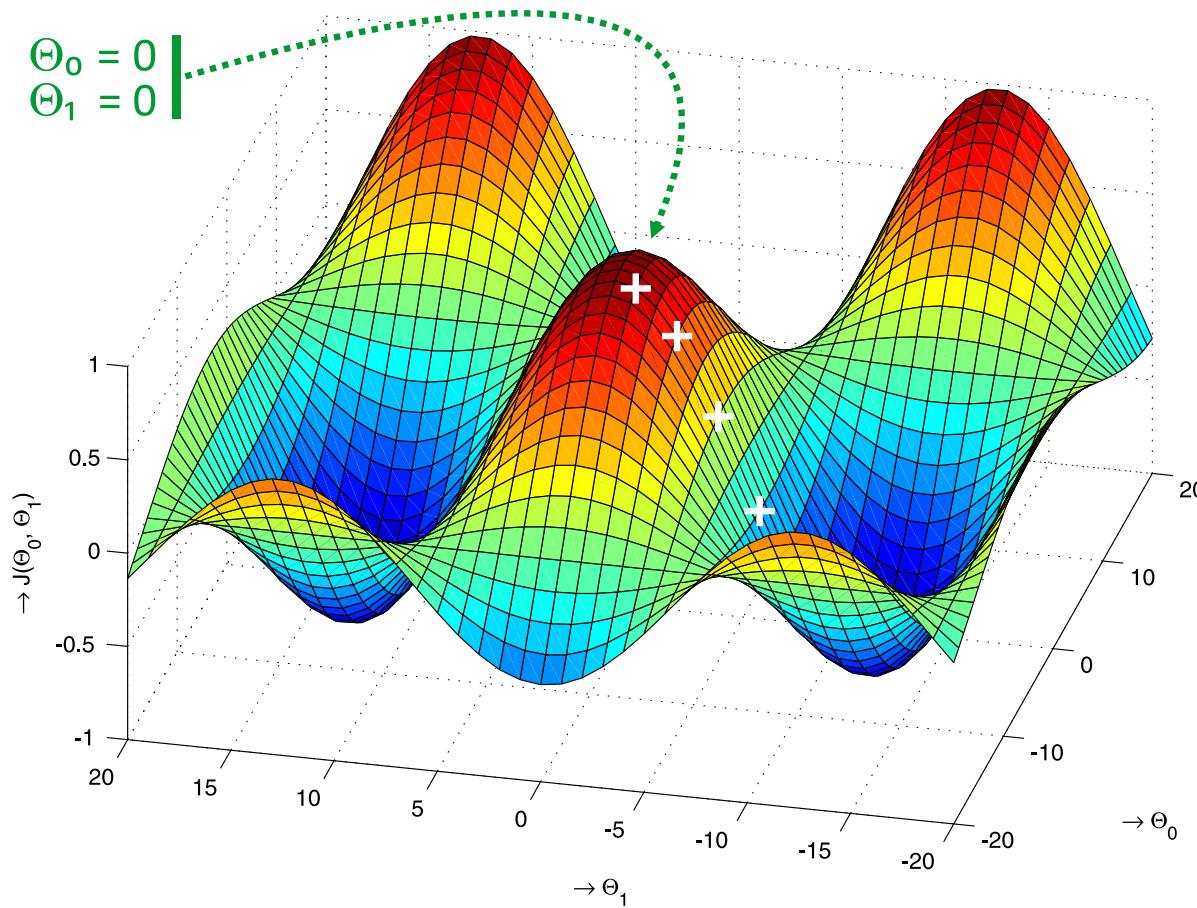
- začneme s nějakými hodnotami Θ_i , např. 0 nebo náhodnými
- měníme hodnoty Θ_i tak, aby se snižovala funkční hodnota cenové funkce $J(\Theta_0, \dots, \Theta_n)$, dokud nenalezneme její **minimum** (snad)





Gradientní sestup (Gradient Descent)

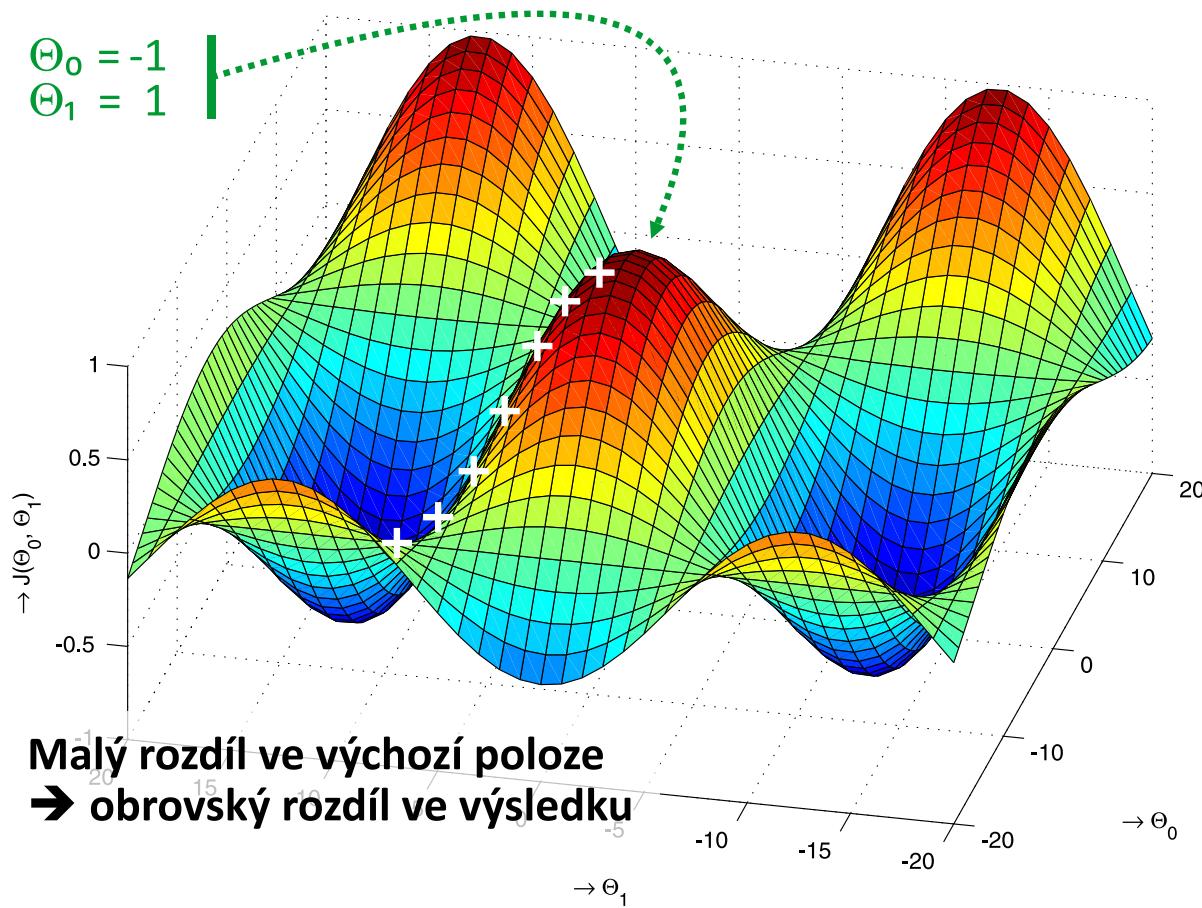
Problém algoritmu – lokalita extrému





Gradientní sestup (Gradient Descent)

Problém algoritmu – lokalita extrému



Malý rozdíl ve výchozí poloze
→ obrovský rozdíl ve výsledku



Algoritmus gradientního sestupu v pseudokódu

```
while not converged() do {
```

```
    for i = 1 .. n do  $\Theta_i \leftarrow \Theta_i - \alpha \frac{\partial J(\Theta_0, \dots, \Theta_n)}{\partial \Theta_i}$ 
```

```
}
```



úprava hodnot Θ_i musí proběhnout „současně“ (výpočtem ze stejných hodnot parametrů funkce J)

✓ $\text{temp}[0] = \Theta_0 - \alpha \frac{\partial J(\Theta_0, \dots, \Theta_n)}{\partial \Theta_0}$

⋮

$\text{temp}[n] = \Theta_n - \alpha \frac{\partial J(\Theta_0, \dots, \Theta_n)}{\partial \Theta_n}$

$\Theta_0 = \text{temp}[0]$

⋮

$\Theta_n = \text{temp}[n]$

✗ $\text{temp}[0] = \Theta_0 - \alpha \frac{\partial J(\Theta_0, \dots, \Theta_n)}{\partial \Theta_0}$

$\Theta_0 = \text{temp}[0]$

⋮

$\text{temp}[n] = \Theta_n - \alpha \frac{\partial J(\Theta_0, \dots, \Theta_n)}{\partial \Theta_n}$

$\Theta_n = \text{temp}[n]$



Algoritmus gradientního sestupu

Matematický rozbor

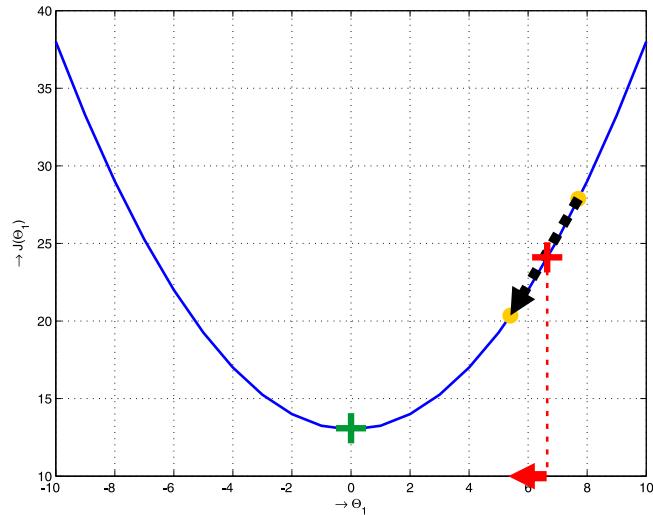
Úprava hodnot parametrů Θ_i :

$$\Theta_i \leftarrow \Theta_i - \frac{\partial J(\Theta_0, \dots, \Theta_n)}{\partial \Theta_i} \cdot \alpha$$

míra učení
(*Learning Rate*)

parciální derivace
(*Partial Derivative*)

Geometrická interpretace
derivace funkce v bodě:





Algoritmus gradientního sestupu

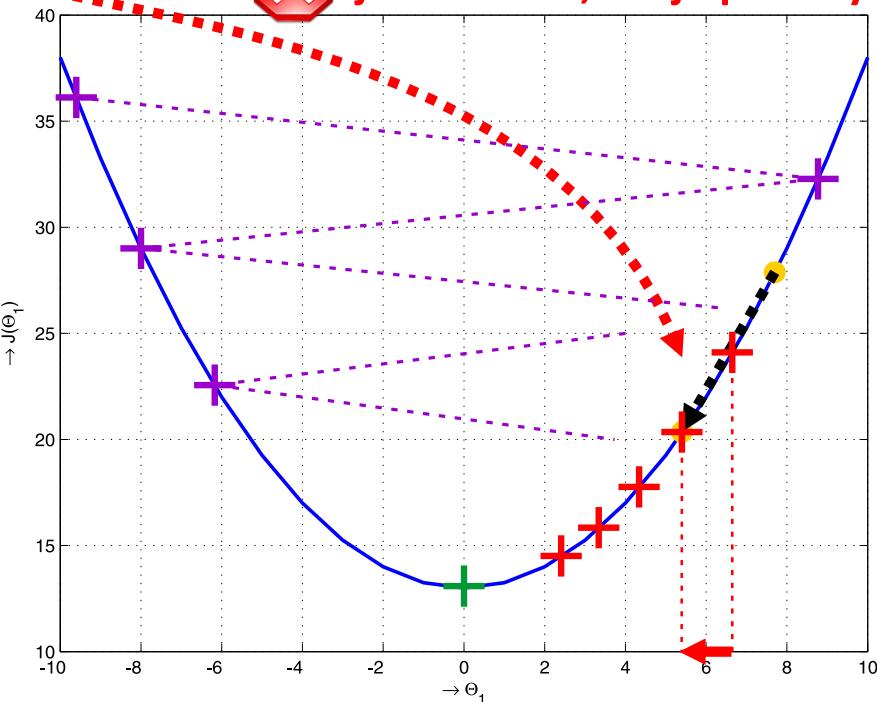
Matematický rozbor

$$\Theta_i \leftarrow \Theta_i - \alpha \frac{\partial J(\Theta_0, \dots, \Theta_n)}{\partial \Theta_i}$$

X je-li α malé, GS je pomalý



**je-li α velké,
GS „přestře-
luje“ správnou
pozici extrému
– může diver-
govat...**

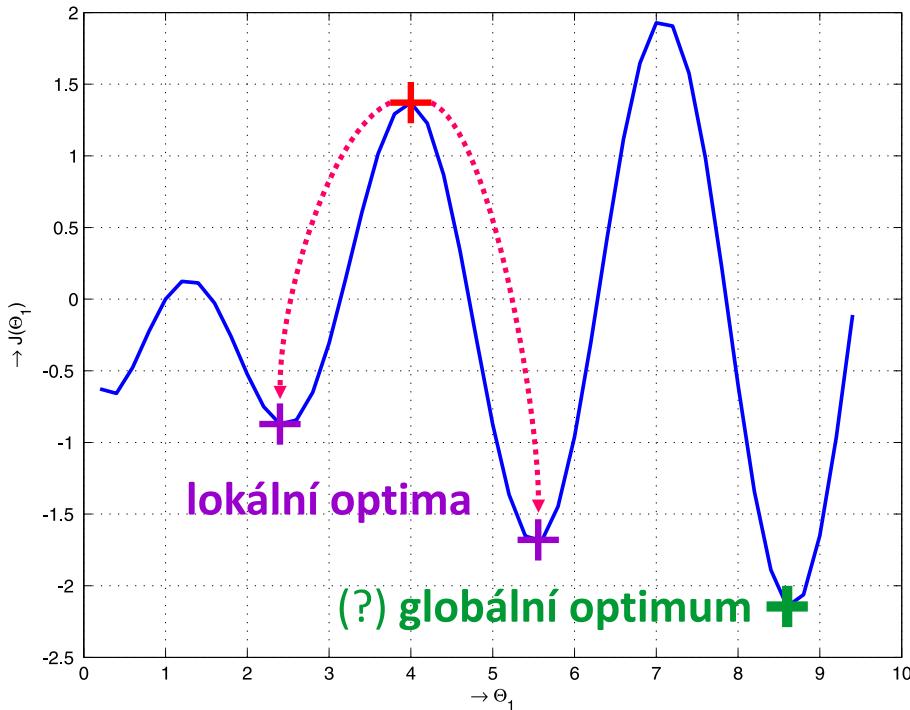




Algoritmus gradientního sestupu

Matematický rozbor – lokalita extrému

$$\Theta_i \leftarrow \Theta_i - \alpha \frac{\partial J(\Theta_0, \dots, \Theta_n)}{\partial \Theta_i}$$





Algoritmus gradientního sestupu

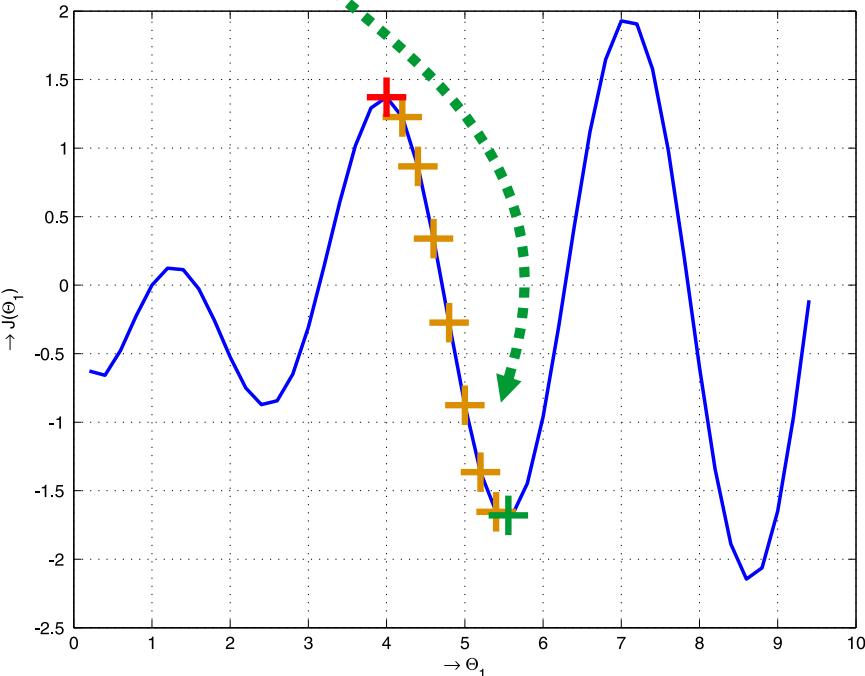
Matematický rozbor – konvergence

$$\Theta_i \leftarrow \Theta_i - \alpha \frac{\partial J(\Theta_0, \dots, \Theta_n)}{\partial \Theta_i}$$

vlastnost derivace

GS konverguje k lokálnímu minimu i tehdy, je-li $\alpha = C...$

Jak se blížíme k lokálnímu minimu, krok GS se zmenšuje, tj. není nutné α adaptivně upravovat...





Gradientní sestup pro potřeby lineární regrese

$$\Theta_i \leftarrow \Theta_i - \alpha \frac{\partial J(\Theta_0, \dots, \Theta_n)}{\partial \Theta_i}$$

je třeba vyjádřit a spočítat tuto derivaci...

derivace složené funkce!

$$\begin{aligned} \frac{\partial J(\Theta_0, \Theta_1)}{\partial \Theta_{0\dots 1}} &= \frac{\partial}{\partial \Theta_{0\dots 1}} \frac{1}{2m} \sum_{i=1}^m \left(h_\Theta(x^{(i)}) - y^{(i)} \right)^2 \\ &= \frac{\partial}{\partial \Theta_{0\dots 1}} \frac{1}{2m} \sum_{i=1}^m \left(\Theta_0 + \Theta_1 x^{(i)} - y^{(i)} \right)^2 \end{aligned}$$

pro Θ_0 :

$$\frac{\partial J(\Theta_0, \Theta_1)}{\partial \Theta_0} = \frac{1}{m} \sum_{i=1}^m \left(h_\Theta(x^{(i)}) - y^{(i)} \right)$$

pro Θ_1 :

$$\frac{\partial J(\Theta_0, \Theta_1)}{\partial \Theta_1} = \frac{1}{m} \sum_{i=1}^m \left(h_\Theta(x^{(i)}) - y^{(i)} \right) \cdot x^{(i)}$$



Gradientní sestup

pro potřeby lineární regrese – algoritmus

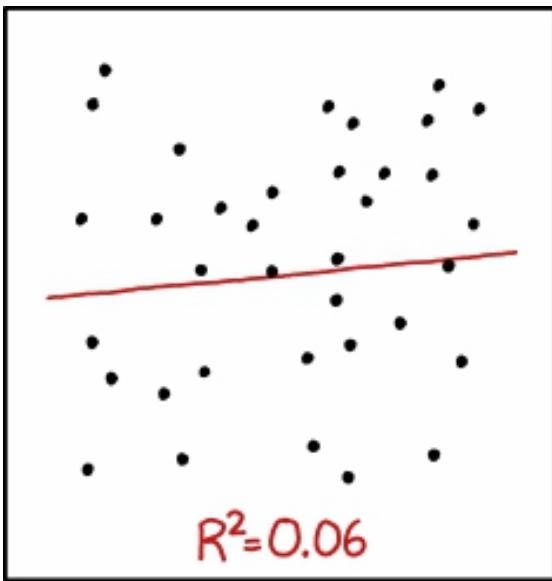
```
while not converged() do {  
    temp[0] ← Θ₀ - α  $\frac{1}{m} \sum_{i=1}^m (h_\Theta(x^{(i)}) - y^{(i)})$   
    temp[1] ← Θ₁ - α  $\frac{1}{m} \sum_{i=1}^m (h_\Theta(x^{(i)}) - y^{(i)}) \cdot x^{(i)}$   
    Θ₀ ← temp[0]  
    Θ₁ ← temp[1]  
}
```

Dávkový gradientní sestup (Batch Gradient Descent) –
v každém kroku sestupu se výpočet provádí se všemi dostupnými trénovacími vzorky...



Lineární regrese

Hluboká myšlenka na závěr



I DON'T TRUST LINEAR REGRESSIONS WHEN IT'S HARDER
TO GUESS THE DIRECTION OF THE CORRELATION FROM THE
SCATTER PLOT THAN TO FIND NEW CONSTELLATIONS ON IT.