

# 11., 12. Správa I/O Správa souborů

ZOS 2014, L. Pešička



### Doplnění

- Alokace paměti pro procesy
  - explicitní správa paměti
  - čítání referencí
  - garbage collection

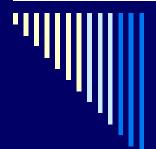
viz pdf s dodatkem – přečíst (!)

pamatuj!!

v C o paměť žádáme malloc() a máme ji uvolnit free()

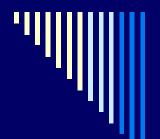
paměť nám přidělí knihovna – alokátor paměti, která spravuje volnou paměť

pokud paměť nemá alokátor k dispozici, požádá operační systém systémovým voláním o přidělení další části paměti (další stránky)



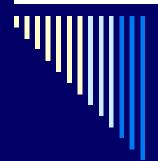
#### malloc, brk, sbrk

- malloc není systémové volání, ale knihovní funkce viz man 3 malloc x man 2 fork
- malloc alokuje pamět z haldy
- velikost haldy se nastaví dle potřeby systémovým voláním sbrk
- brk syscall nastaví adresu konce datového segmentu procesu
- sbrk syscall zvětší velikost datového segmentu o zadaný počet bytů (0 – jen zjistím současnou adresu)



# používané vs. nepoužívané objekty

```
Object x = new Foo();
Object y = new Bar();
x = new Quux();
/* víme, že Foo object původně přiřazený x nebude nikdy dostupný,
jde o syntactic garbage */
if (x.check_something())
   { x.do_something(y); }
System.exit(0);
/* y může být semantic garbage, ale nevíme, dokud
x.check_something() nevrátí návratovou hodnotu */
```

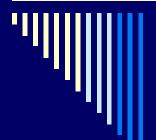


# Velikost stránky v OS

Standardní velikost je 4096 bytů (4KB)

huge page size: 4MB

large page size: 1GB



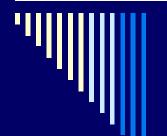
#### Zjištění velikosti stránky - Linux

```
#include <stdio.h>
#include <unistd.h>
int main(void) {
 printf("Velikost stranky je %ld bytu.\n",
  sysconf(_SC_PAGESIZE) );
 return 0;
```

příkazem na konzoli: getconf PAGESIZE

man sysconf

eryx.zcu.cz: 4096 ares.fav.zcu.cz: 4096



# Zjištění velikosti stránky - WIN

```
#include "stdafx.h"
                                        c:\users\pesicka\documents\visual studio 2010\Projects\ZOS Ve
                                        Velikost stranky je 4096 bytu.
#include <stdio.h>
                                        Pocet procesoru: 4
#include <Windows.h>
int _tmain(int argc, _TCHAR* argv[])
SYSTEM_INFO si;
GetSystemInfo(&si);
printf("Velikost stranky je %u bytu.\n", si.dwPageSize);
printf("Pocet procesoru: %u\n", si.dwNumberOfProcessors);
getchar(); return 0;
```

zdroj: http://en.wikipedia.org/wiki/Page\_size#Page\_size\_trade-off



- Modul pro správu procesů
- Modul pro správu paměti
- □ Správa i/o
- □ Správa souborů
- □ síťování



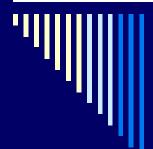
# Vývoj rozhraní mezi CPU a zařízeními

- 1. CPU řídí přímo periferii
- 2. CPU řadič periferie aktivní čekání CPU na dokončení operace
- 3. řadič umí vyvolat přerušení
- 4. řadič umí DMA
- 5. I/O modul
- 6. I/O modul s vlastní pamětí



# 1. CPU řídí přímo periferii

- CPU přímo vydává potřebné signály
- CPU dekóduje signály poskytovaném zařízením
- Nejjednoduší HW
- Nejméně efektivní využití ČPU
- Jen v jednoduchých mikroprocesorem řízených zařízeních (dálkové ovládání televize)



### 2. CPU – řadič - periférie

#### **Řadič (device controller)**

- Převádí příkazy CPU na elektrické impulzy pro zařízení
- Poskytuje CPU info o stavu zařízení
- Komunikace s CPU pomocí registrů řadiče na známých I/O adresách
- HW buffer pro alespoň 1 záznam (blok, znak, řádka)
- Rozhraní řadič-periférie může být standardizováno (SCSI, IDE, ...)



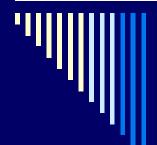
# 2. řadič – příklad operace zápisu

- CPU zapíše data do bufferu, Informuje řadič o požadované operaci
- Po dokončení výstupu zařízení nastaví příznak, který může CPU otestovat
- □ if přenos == OK, může vložit další data
- CPU musí dělat všechno (programové I/O)
- Významnou část času stráví CPU čekáním na dokončení I/O operace



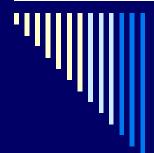
# 3. Řadič umí vyvolat přerušení

- CPU nemusí testovat příznak dokončení
- Při dokončení I/O vyvolá řadič přerušení
- CPU začne obsluhovat přerušení
  - Provádí instrukce na předdefinovaném místě
  - Obslužná procedura přerušení
  - Určí co dál
- Postačuje pro pomalá zařízení, např. sériové I/O



# 4. Řadič může přistupovat k paměti pomocí DMA

- DMA přenosy mezi pamětí a buffery
- CPU vysílá příkazy,při přerušení analyzuje status zařízení
- CPU inicializuje přenos, ale sám ho nevykonává
- Bus mastering zařízení převezme kontrolu nad sběrnicí a přenos provede samo (PCI sběrnice)
- Vhodné pro rychlá zařízení řadič disků, síťová karta, zvuková karta, grafická karta atd.



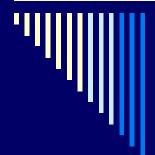
# 5. I/O modul umí interpretovat speciální I/O programy

- □ I/O procesor
- Interpretuje programy v hlavní paměti
- CPU spustí I/O procesor
   I/O procesor provádí své instrukce samostatně



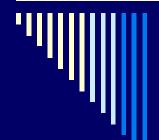
# 6. I/O modul s vlastní pamětí

- I/O modul provádí programy
- Má vlastní paměť(!)
  - Je vlastně samostatným počítačem
- □ Složité a časově náročné operace grafika, šifrování, ...



#### Komunikace CPU s řadičem

- Odlišné adresní prostory
  - CPU zapisuje do registrů řadiče pomocí speciálních I/O instrukcí
  - Vstup: N R, port
  - Výstup: OUT R, port
- □ 1 adresní prostor
- □ Hybridní schéma



# Ad – 1 adresní prostor

- Používá vyhrazené adresy
- Nazývá se paměťově mapované I/O
- HW musí pro dané adresy umět vypnout cachování
- Danou oblast můžeme namapovat do virtuálního adresního prostoru nějakého procesu (zpřístupnění I/O zařízení)

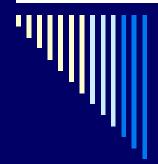


# Ad – hybridní schéma

- Řídící registry
  - Přístup pomocí I/O instrukcí
- HW buffer
  - Mapován do paměti
- □ Např. PC (buffery mapovány do oblasti 640K až 1MB)



- pevný disk
  - elektronická část + mechanická
  - náchylost k poruchám
  - cena dat >> cena hw
- odstávka při výměně zařízení
  - náhrada hw, přenos dat ze zálohy prostoje
  - SLA 24/7
- větší disková kapacita než 1 disk
- RAID
  - Redundant Array of Independent (Inexpensive) disks

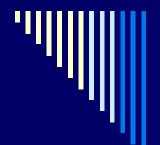


### Disk

Rotační disky doba vystavení + rotační zpoždění

SSD disky dražší, menší kapacita

Mix SSD disk v kombinaci s rotačním diskem



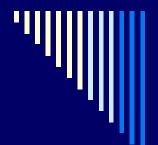
## RAID – používané úrovně

- □ RAID 0, 1, 5
- RAID 10 .. kombinace 0 a 1
- RAID 6 .. zdvojená parita
- pojmy:
  - SW nebo HW RAID
  - hot plug
  - hot spare
  - Degradovaný režim jeden (či více dle typu RAIDu) z disků v poli je porouchaný, ale RAID stále funguje



Dva režimy RAID 0: zřetězení a prokládání

- není redundantní, neposkytuje ochranu dat
- ztráta 1 disku ztráta celého pole nebo části (dle režimu)
- důvod použití může být výkon při režimu prokládání (např. střih videa)
- Dva režimy zřetězení nebo prokládání (stripping)

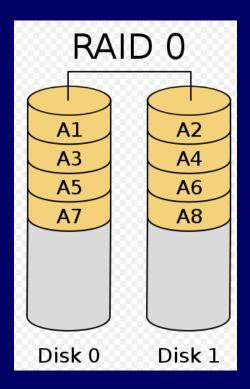


#### Zřetězení

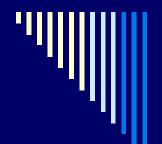
- Data postupně ukládána na několik disků
- Zaplní se první disk, pak druhý, atd.
- Snadné zvětšení kapacity, při poruše disku ztratíme jen část dat

#### Prokládání

- Data ukládána na disky cyklicky po blocích (stripy)
- Při poruše jednoho z disků přijdeme o data
- Větší rychlost čtení / zápisu
  - Jeden blok z jednoho disku, druhý blok z druhého disku

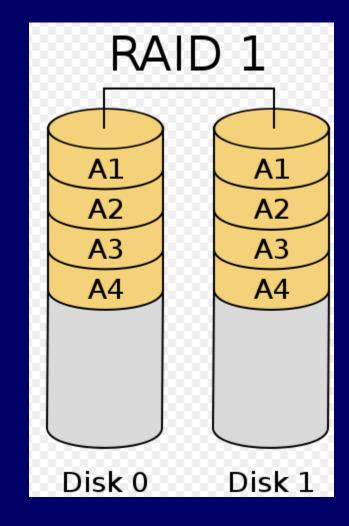


Na obrázku je režim prokládání, zdroj: wikipedia (i u dalších obrázků)



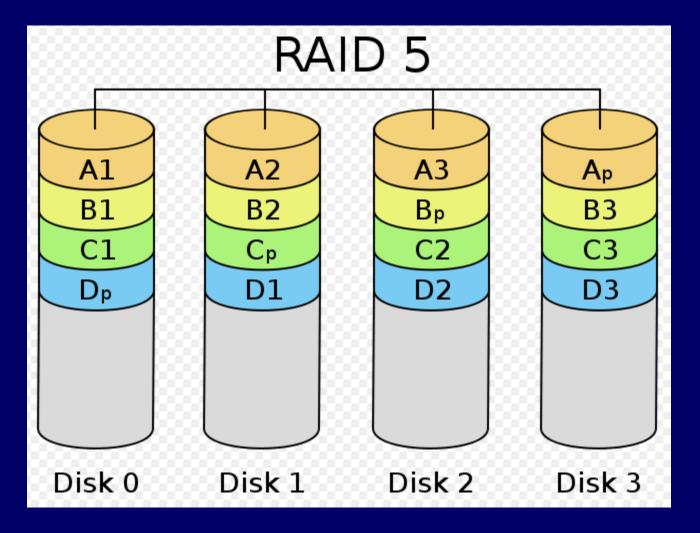
- mirroring .. zrcadlení
- na 2 disky stejných kapacit totožné informace
- výpadek 1 disku nevadí
- jednoduchá implementace často čistě sw
- nevýhoda využijeme jen polovinu kapacity
- zápis pomalejší (stejná data na 2 disky)
   ovlivněn diskem, na němž bude trvat déle
- čtení rychlejší (řadič - lze střídat požadavky mezi disky)





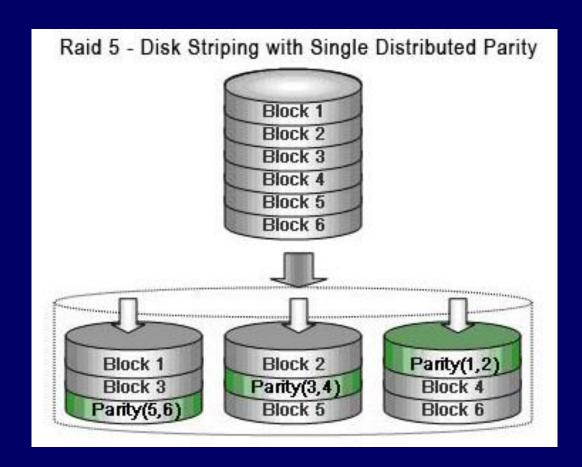


- redundantní pole s distribuovanou paritou
- minimálně 3 disky
- režie: 1 disk z pole n disků
  - 5 disků 100GB : 400GB pro data
- výpadek 1 disku nevadí
- □ čtení výkon ok
- zápis pomalejší
   1 zápis čtení starých dat, čtení staré parity, výpočet nové parity, zápis nových dat, zápis nové parity



Např. RAID 5 z 4 disků 1TB, výsledná kapacita: 3 TB Může vypadnout 1 z disků a o data nepřijdeme





Zdroj:

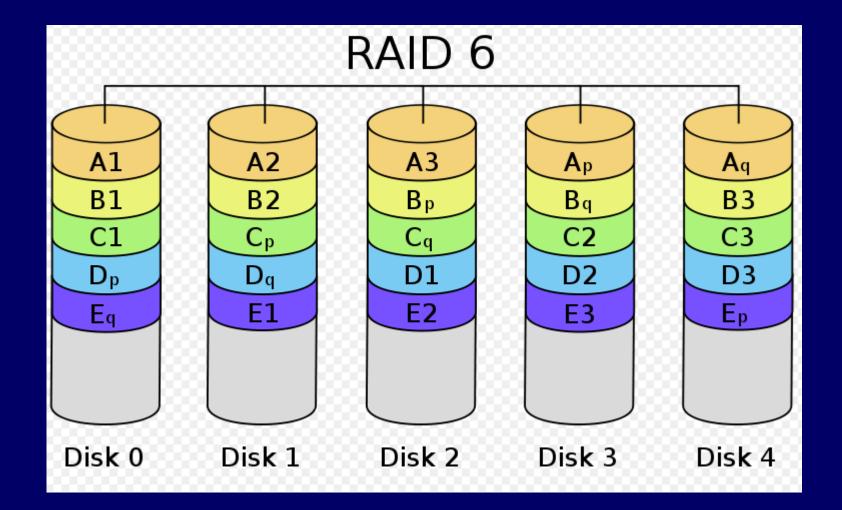
http://www.partitionwizard.com/resize-partition/resize-raid5.html



- nejpoužívanější
- detekce poruchy v diskovém poli
- hot spare disk
- použití hot plug disků

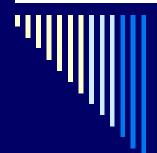


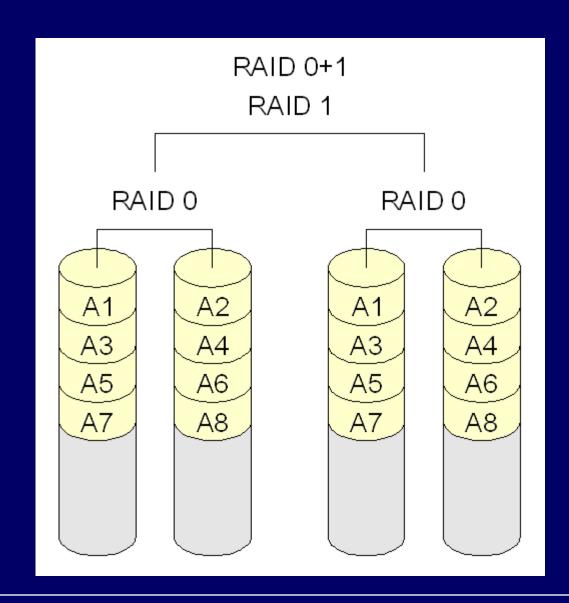
- RAID 5 + navíc další paritní disk
- odolné proti výpadku dvou disků
- Rychlost čtení srovnatelná s RAID 5
- Zápis pomalejší

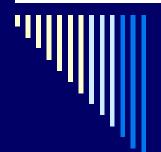


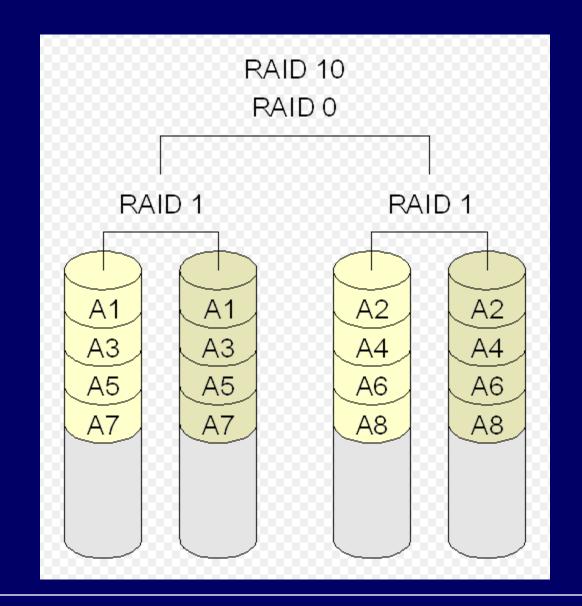


- kombinace RAID 0 (stripe) a RAID 1 (zrcadlo)
- min. počet disků 4
- režie 100% diskové kapacity navíc
- nejvyšší výkon v bezpečných typech polích
- podstatně rychlejší než RAID 5, při zápisu
- odolnost proti ztrátě až 50% disků x RAID 5

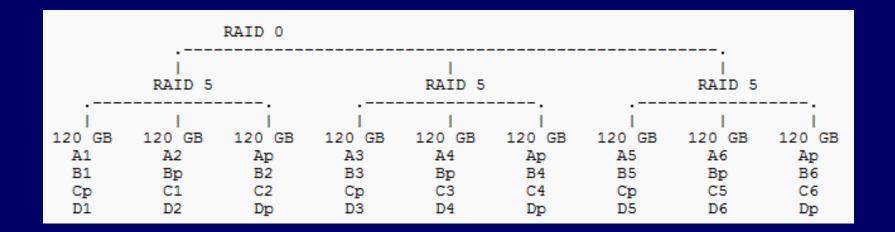




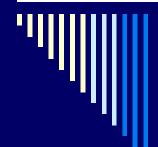






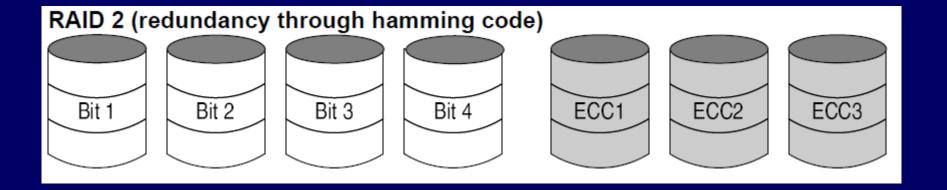


Zdroj obrázků a doporučená literatura: <a href="http://cs.wikipedia.org/wiki/Raid">http://cs.wikipedia.org/wiki/Raid</a>



- Data po bitech stripována mezi jednotlivé disky
- □ Rotačně synchronizované disky
- Zabezpečení Hammingovým kódem
- □ Např. 7 disků
  - 4 bity datové
  - 3 bity Hammingův kód

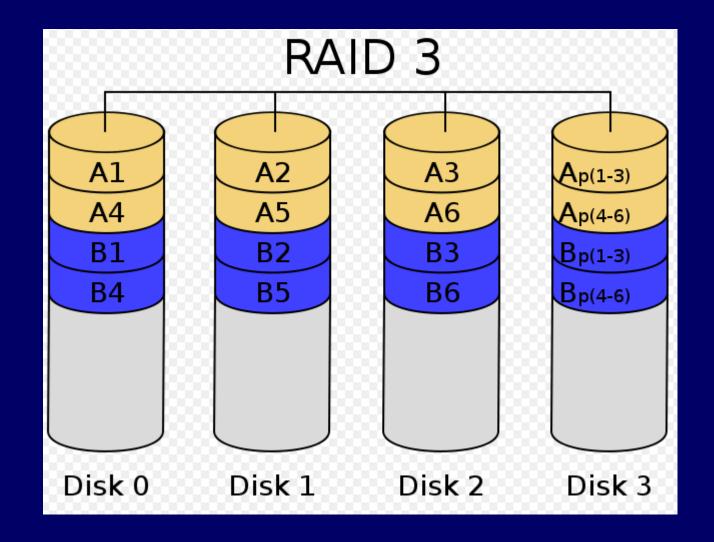


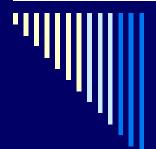




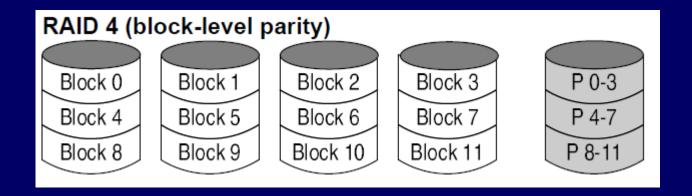
- □ N+1 disků, bitové prokládání
- Rotačně synchronizované disky
- Na N data, poslední disk XOR parita
- Jen 1 disk navíc
- Paritní disk vytížen při zápisu na libovolný disk – vyšší opotřebení

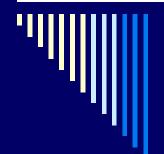


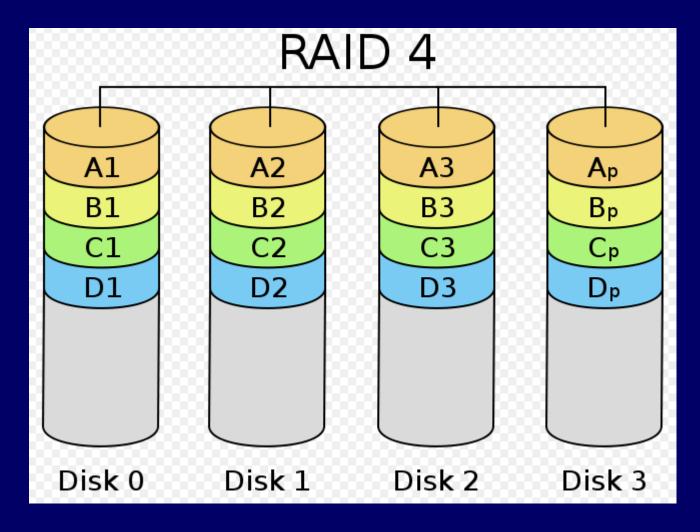




- Disky stripovány po blocích, ne po bitech
- □ Parita je opět po blocích









# Problém rekonstrukce pole

- □ rekonstrukce pole při výpadku trvá dlouho
  - po dobu rekonstrukce není pole chráněno proti výpadku dalšího disku
  - náročná činnost může se objevit další chyba,
     řadič disk odpojí a ... přijdeme o data...



# HOT SPARE DISK

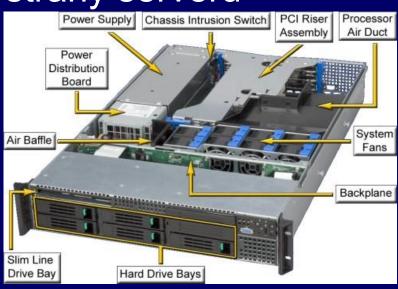
- záložní disk okamžitě připravený k nahrazení vadného disku
- při výpadku disku v poli automaticky aktivován hot spare disk a dopočítána data
- minimalizace rizika (časové okno)
  - Pole je degradované a je třeba vyměnit disk
  - Administrátor nemusí být poblíž
- hot spare disk lze sdílet mezi více RAIDy (někdy)



## HOT PLUG

- Snadná výměna disku za běhu systému
- Není třeba vypnout server pro výměnu disku
- "šuplík z přední strany serveru"







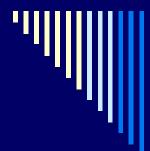


# Ukládání dat

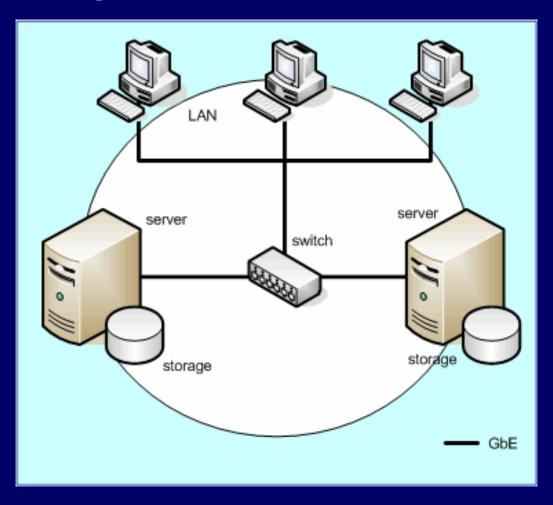
- DAS
- SAN
- □ iSCSI



- Directly attached storage
- ukládací zařízení přímo u serveru
- nevýhody
  - porucha serveru data nedostupná
  - některé servery prázdné, jiné dat.prostor skoro plný
  - rozšiřitelnost diskové kapacity
- disky přímo v serveru
- externí diskové pole přes SCSII (vedle serveru)



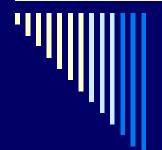
# DAS



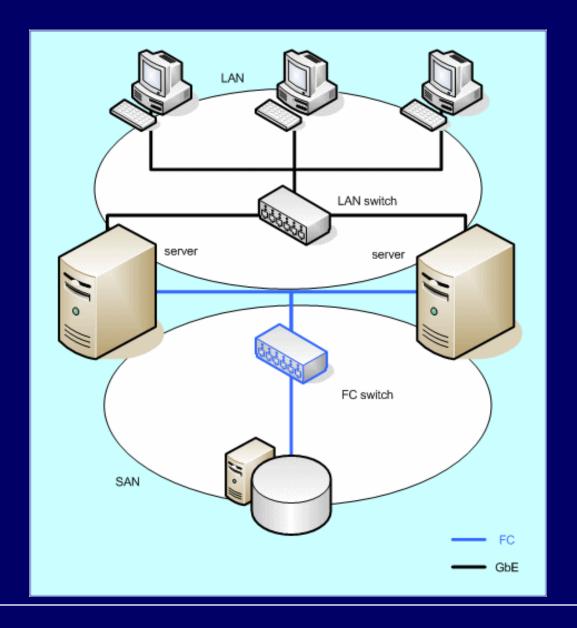


- Storage Area Network
- oddělení storage a serverů
- Fibre Channel propojení, optický kabel

- např. clustery, společná datová oblast
- high availability solution

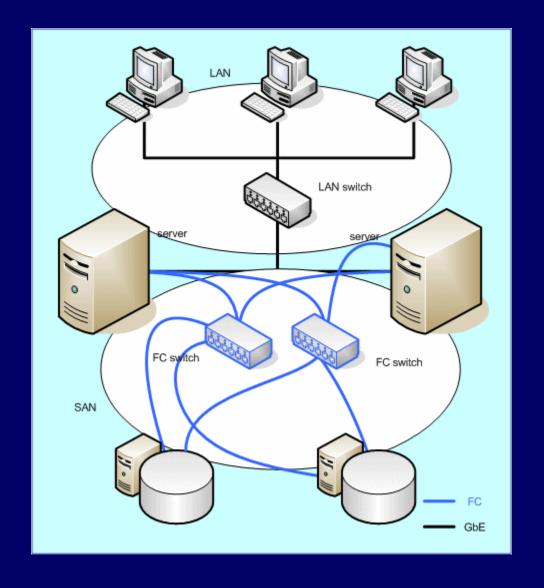


# SAN





# SAN



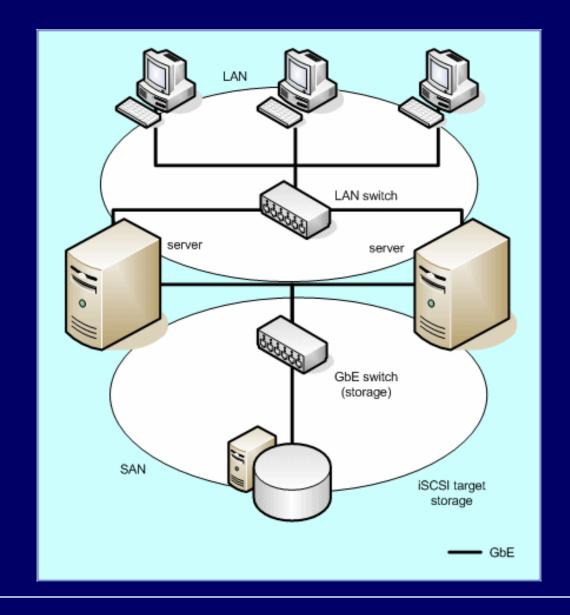


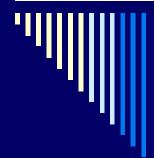
# iSCSI

- SCSI + TCP/IP
- □ SCSI
  - protokol, bez fyzické vrstvy (kabely, konektory)
  - zapouzdření do protokolů TCP/IP
- gigabitový Ethernet vs. drahý Fibre Channel
- SCSI adaptér, disk
- □ iSCSI initiator (adapter), target (cílové zař. disk/pole)



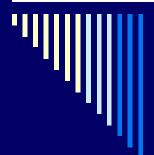
# **iSCSI**





# Použité odkazy a další informace

□ <a href="http://www.vahal.cz/cz/podpora/technicke-okenko/ukladani-dat-iscsi.html">http://www.vahal.cz/cz/podpora/technicke-okenko/ukladani-dat-iscsi.html</a>

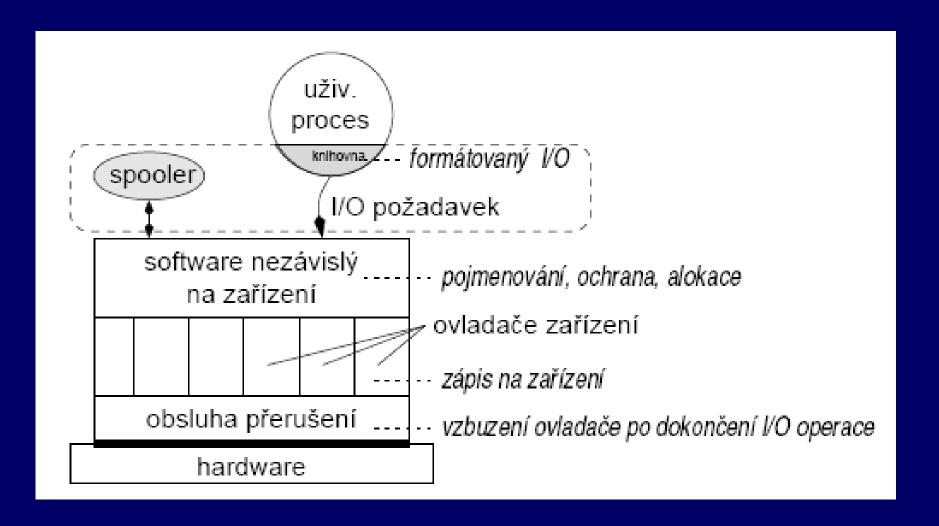


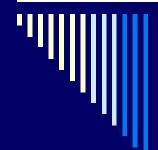
# Principy I/O software (!!!!)

typicky strukturován do 4 úrovní:

- 1. obsluha přerušení (nejnižší úroveň v OS)
- ovladač zařízení
- 3. SW vrstva OS nezávislá na zařízení
- 4. uživatelský I/O SW

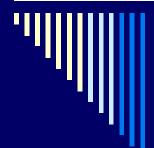
Toto je potřeba znát!!





## 1. Obsluha přerušení

- řadič vyvolá přerušení ve chvíli dokončení I/O požadavku
- snaha, aby se přerušením nemusely zabývat vyšší vrstvy
- ovladač zadá I/O požadavek, usne P(sem)
- po příchodu přerušení ho obsluha přerušení vzbudí -V(sem)
- časově kritická obsluha přerušení co nejkratší



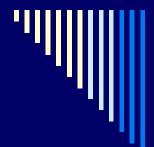
#### 2. Ovladače zařízení

- obsahují veškerý kód závislý na konkrétním I/O zařízení (např. zvukovka od daného výrobce)
- ovladač zná jediný hw podrobnosti
  - způsob komunikace s řadičem zařízení
  - zná detaily např. ví o sektorech a stopách na disku, pohybech diskového raménka, start & stop motoru
- může ovládat všechna zařízení daného druhu nebo třídu příbuzných zařízení
  - např. ovladač SCSI disků všechny SCSI disky



#### Funkce ovladače zařízení

- ovladači předán příkaz od vyšší vrstvy
  - např. zapiš data do bloku n
- nový požadavek zařazen do fronty
  - může ještě obsluhovat předchozí
- ovladač zadá příkazy řadiči (požadavek přijde na řadu)
  - např. nastavení hlavy, přečtení sektoru
- zablokuje se do vykonání požadavku
  - neblokuje při rychlých operacích např. zápis do registru
- vzbuzení obsluhou přerušení (dokončení operace) zkontroluje, zda nenastala chyba



## Funkce ovladače zařízení – pokrač.

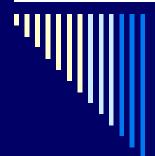
- pokud OK, předá výsledek (status + data) vyšší vrstvě
  - status datová struktura pro hlášení chyb
- Zpracuje další požadavky ve frontě
  - jeden vybere a spustí
- ovladače často vytvářejí výrobci HW
  - dobře definované rozhraní mezi OS a ovladači
- ovladače podobných zařízení stejná rozhraní
  - např. sítové karty, zvukové karty, ...



# Problémy s ovladači



- □ Chyba ovladače pád systému
  - Běh v privilegovaném režimu (jádře)
  - Chyba v ovladači může způsobit pád systému
- Ovladač pro určitý HW i určitý OS
  - Můžete mít starší kameru s ovladačem pro Windows XP, ale třeba nebude použitelná ve Windows 8.1



# 3. SW vrstva OS nezávislá na zařízení

- I/O funkce společné pro všechna zařízení daného druhu
  - např. společné fce pro všechna bloková zařízení
- definuje rozhraní s ovladači
- poskytuje jednotné rozhraní uživatelskému SW
- 🗖 viz další slide...



## Poskytované funkce (!)

- pojmenování zařízení
  - LPT1 x /dev/lp0
- ochrana zařízení (přístupová práva)
- alokace a uvolnění vyhrazených zařízení
  - v 1 chvíli použitelná pouze jedním procesem
  - např. tiskárna, plotter, magnetická páska
- vyrovnávací paměti
  - bloková zařízení bloky pevné délky
  - pomalá zařízení čtení / zápis s využitím bufferu



## Poskytované funkce – pokračování

- □ hlášení chyb
- jednotná velikost bloku pro bloková zařízení

v moderních OS se zařízení jeví jako objekty v souborovém systému (v mnoha OS je tato vrstva součástí logického souborového systému)

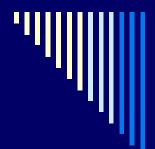


### 4. I/O sw v uživatelském režimu

- programátor používá v programech I/O funkce nebo příkazy jazyka
  - např. printf v C, writeln v Pascalu
  - knihovny sestavené s programem
  - formátování printf("%.2d:%.2d\n", hodin, minut)
  - často vlastní vyrovnávací paměť na jeden blok

#### spooling

- implementován pomocí procesů běžících v uživ. režimu
- způsob obsluhy vyhrazených I/O zařízení (multiprogram.)
- např. proces by alokoval zařízení a pak hodinu nic nedělal

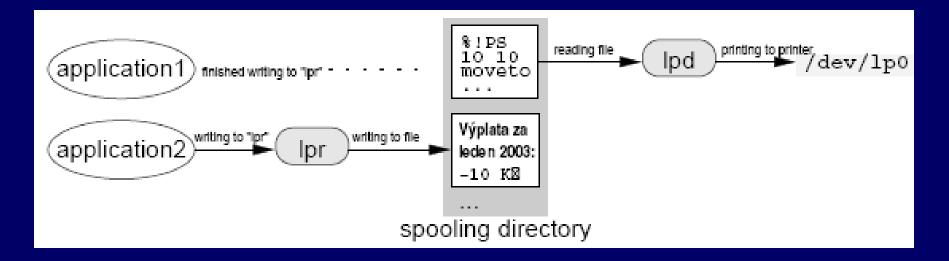


## Příklad spoolingu – tisk Unix

- □ k fyzické tiskárně přístup pouze 1 speciální proces
  - daemon lpd
- proces vygeneruje celý soubor, lpd ho vytiskne
  - proces chce tisknout, spustí lpr a naváže s ním komunikaci
  - proces předává tisknutá data programu lpr
  - Ipr zapíše data do souboru v určeném adresáři
    - spooling directory přístup jen lpr a lpd
  - dokončení zápisu lpr oznámí lpd, že soubor je připraven k vytisknutí, lpd soubor vytiskne a zruší



## tisk Unix

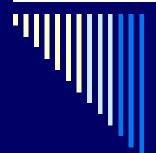


lpd – démon (služba) čte ze spoolovacího adresáře a přistupuje k tiskárně
 lpr – data, která chce aplikace vytisknout se zapisují do spoolovacího adresáře
 Poznámka - spooling lze použít např. i pro přenos elektronické pošty



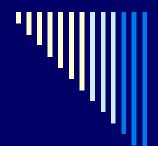
# Souborové systémy

- potřeba aplikací trvale uchovávat data
- hlavní požadavky
  - možnost uložit velké množství dat
  - informace zachována i po ukončení procesu
  - data přístupná více procesům
- společné problémy při přístupu k zařízení
  - alokace prostoru na disku
  - pojmenování dat
  - ochrana dat před neoprávněným přístupem
  - zotavení po havárii (výpadek napájení)



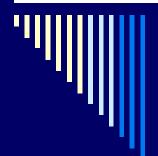
#### Soubor

- OS pro přístup k médiím poskytuje abstrakci od fyzických vlastností média – soubor
- soubor = pojmenovaná množina souvisejících informací
- souborový systém (file system, fs)
  - konvence pro ukládání a přístup k souborům
    - datové struktury a algoritmy
  - část OS, poskytuje mechanismus pro ukládání a přístup k datům, implementuje danou konvenci



## File systém (fs)

- □ Současné OS implementují více fs
  - kompatibilita (starší verze, ostatní OS)
- Windows XP, Vista, 7, 8, 8.1, 10:
  - základní je NTFS
  - ostatní: FAT12, FAT16, FAT32, ISO 9660 (CD-ROM)
- Linux
  - ext2, ext3, ext4, ReiserFS, JFS, XFS
  - ostatní: FAT12 až 32, ISO 9660, Minix, VxFS, OS/2 HPFS, SysV fs, UFS, NTFS



## Základní znalosti

V PC můžeme mít více pevných disků, např. dva:

Linux: /dev/sda, /dev/sdb

Každý disk se může dělit na několik oddílů:

/dev/sda1, /dev/sda2, /dev/sda3 (1. disk)

/dev/sdb1, /dev/sdb2 (2. disk)

Každý oddíl (partition) – nějaký filesystém:

/dev/sda1 ext4

/dev/sda1 swap

/dev/sda1 ntfs

/dev/sdb1 fat32

Formátování disku: /sbin/mkfs.ext4 /dev/sda1



# Základní znalosti

#### fdisk /dev/sda

- Zobrazení rozdělení disku na oddíly (partitions)
- Možnost toto rozdělení změnit

#### /sbin/mkfs.ext4 /dev/sda1

Zformátování oddílu na vybraný filesystém (zde ext4)



## Počet oddílů

### 2 způsoby dělení

- Master Partition Table (MPT)
  - Master Boot Record (MBR) na počátku disku
  - Umožňuje 4 oddíly primární
  - Chceme-li více, 3 primární a 1 extended, který lze dělit na další oddíly
- GUID Partition Table (GPT)
  - Nelimituje na 4 oddíly, např. Microsoft 124 oddílů
  - Používá např. Mac OS



# Struktura MBR

Struktura MBR					
Adresa					Délka
Hex	Oct	Dec		Popis	v bajtech
0000	0000	0	Kód zavad	děče 13 10 S	<b>440</b> (max 446)
01B8	0670	440	Volitelná signatura disku		4
01BC	0674	444	Obvykle n	2	
01BE	0676	446	Tabulka r (4 položky oddílů)	64	
01FE	0776	510	55h	Signatura MBR;	2
01FF	0777	511	AAh	0xAA55 <sup>[1]</sup>	2
Celková délka MBR: 446 + 64 + 2 =					512

Zdroj obr.: wikipedia

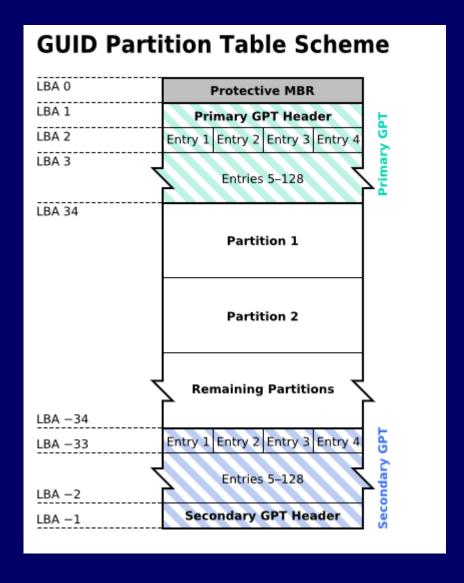
Na začátku disku je MBR record, který obsahuje:

#### Kód zavaděče

(pokud se z disku bootuje, tak tento kód je puštěn z BIOSu)

Tabulka rozdělení disku (4 partitions)

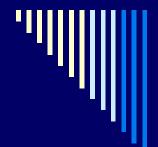
# GUID Partition Table (GPT)



Nejsme omezeni na 4 primární oblasti

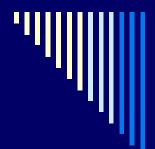
Součástí standardu
UEFI, který by měl
nahradit klasický
BIOS (umožňuje např.
secure boot)

Zdroj obr.: wikipedia



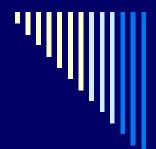
# Historický vývoj

- první systémy
  - vstup děrné štítky, výstup tiskárna
  - soubor = množina děrných štítků
- později magnetické pásky
  - vstup i výstup pásky
  - soubor = množina záznamů na magnetické pásce



# Historický vývoj - pokračování

- nyní data na magnetických a optických discích
  - ISO 2382-4:1987
  - soubor pojmenovaná množina záznamů, které lze zpracovávat jako celek
  - záznam strukturovaný datový objekt tvořený konečným počtem pojmenovaných položek



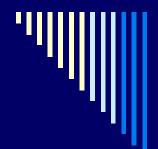
### Uživatelské rozhraní fs

- vlastnosti fs z pohledu uživatele
  - konvence pro pojmenování souborů
  - vnitřní struktura souboru
  - typy souborů
  - způsob přístupu
  - atributy a přístupová práva
  - služby OS pro práci se soubory



# Konvence pro pojmenování souborů

- vytvoření souboru proces určuje jméno souboru
- □ různá pravidla pro vytváření jmen různé OS
- Windows NT, XP x Unix a Linux
- rozlišuje systém malá a velká písmena?
  - Win32API nerozlišuje: ahoj, Ahoj, AHOJ stejná
  - UNIX rozlišuje: ahoj, Ahoj, AHOJ rozdílná jména



## Pojmenování souborů

- jaká může být délka názvu souboru?
  - WinNT 256 znaků NTFS
  - UNIX obvykle alespoň 256 znaků (dle typu fs)
- množina znaků?
  - všechny běžné názvy písmena a číslice
  - WinNT znaková sada UNICODE
    - βετα legální jméno souboru
  - Linux všechny 8bitové znaky kromě / a char(0)



# Pojmenování souborů

- přípony?
  - MS DOS jméno souboru 8 znaků + 3 znaky přípona
  - Winows NT a výše, Unix i více přípon
- další omezení?
  - WinNT mezera nesmí být první a poslední znak



# Typy souborů

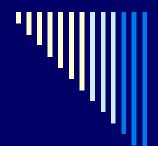
### OS podporují více typů souborů:

- obyčejné soubory převážně dále rozebírány
  - data zapsaná aplikacemi
  - obvykle rozlišení textové x binární
  - textové řádky textu ukončené CR (MAC), LF(UNIX), nebo CR+LF (MS DOS, Windows)
  - binární všechny ostatní
  - OS rozumí struktuře spustitelných souborů



# Typy souborů

- adresáře
  - systémové soubory, udržují strukturu fs
- □ Linux , UNIX ještě:
  - znakové speciální soubory (/dev/tty)
  - blokové speciální soubory
    - □ rozhraní pro I/O zařízení, /dev/lp0 tiskárna
  - pojmenované roury
    - pro komunikaci mezi procesy
  - symbolické odkazy



# Vnitřní struktura (obyčejného) souboru

- □ 3 časté způsoby
  - nestrukturovaná posloupnost bytů
  - posloupnost záznamů
  - strom záznamů
- nestrukturovaná posloupnost bytů (nejčastěji)
  - OS obsah souboru nezajímá, interpretace je na aplikacích
  - maximální flexibilita
    - programy mohou strukturovat, jak chtějí



# Vnitřní struktura (obyčejného) souboru – pokrač.

- posloupnost záznamů pevné délky
  - každý záznam má vnitřní strukturu
  - operace čtení –vrátí záznam, zápis změní / přidá záznam
  - v historických systémech
  - záznamy 80 znaků obsahovaly obraz děrných štítků
  - v současných systémech se téměř nepoužívá



# Vnitřní struktura (obyčejného) souboru – pokrač.

- strom záznamů
  - záznamy nemusejí mít stejnou délku
  - záznam obsahuje pole klíč (na pevné pozici v záznamu)
  - záznamy seřazeny podle klíče, aby bylo možné vyhledat záznam s požadovaným klíčem
  - mainframy pro komerční zpracování dat



# Způsob přístupu k souboru

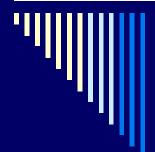
### sekvenční přístup

- procesy mohou číst data pouze v pořadí, v jakém jsou uloženy v souboru
- tj. od prvního záznamu, nemohou přeskakovat
- možnost přetočit a číst opět od začátku, rewind()
- v prvních OS, kde data na magnetických páskách



### Způsob přístupu k souboru

- přímý přístup (random access file)
  - čtení v libovolném pořadí nebo podle klíče
  - přímý přístup je nutný např. pro databáze
  - uživatel např. přeskakování děje filmu
  - určení začátku čtení
    - každá operace určuje pozici
    - OS udržuje pozici čtení / zápisu, novou pozici lze nastavit speciální operací "seek"



# Způsob přístupu k souboru

- v některých OS pro mainframy
  - při vytvoření souboru se určilo, zda je sekvenční nebo s přímým přístupem
    - OS mohl používat rozdílné strategie uložení souboru
- všechny současné OS soubory s přímým přístupem



# Atributy

- □ informace sdružená se souborem
- některé atributy interpretuje OS, jiné systémové programy a aplikace
- významně se liší mezi jednotlivými OS
- ochrana souboru
  - kdo je vlastníkem, množina přístupových práv, heslo, ...

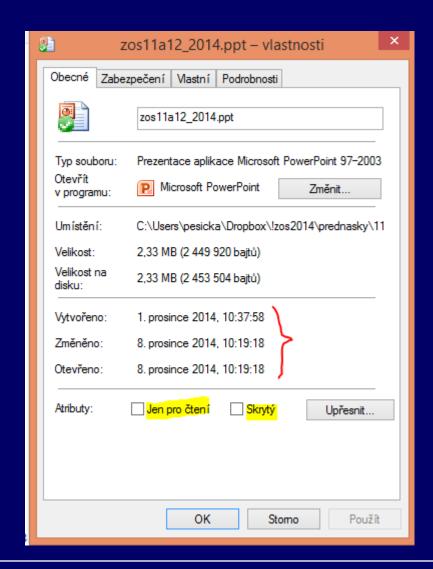


## Atributy - pokračování

- příznaky
  - určují vlastnosti souboru
  - hidden neobjeví se při výpisu
  - archive soubor nebyl zálohován
  - temporary soubor bude automaticky zrušen
  - read-only, text/binary, random access
- přístup k záznamu pomocí klíče
  - délka záznamu, pozice a délka klíče
- velikost, datum vytvoření, poslední modifikace, poslední přístup



# Atributy





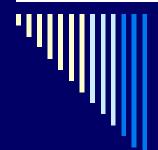
# Služby OS pro práci se soubory

- většina současných základní model dle UNIXu
- □ základní filozofie UNIXu méně je někdy více



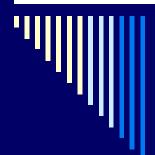
## Několik jednoduchých pravidel

- veškerý I/O prováděn pouze pomocí souborů
  - obyčejné soubory data, spustitelné programy
  - zařízení disky, tiskárny
  - se všemi typy zacházení pomocí stejných služeb systému
- obyčejný soubor uspořádaná posloupnost bytů
  - význam znají pouze programy, které s ním pracují
  - interní struktura souboru OS nezajímá
- jeden typ souboru seznam souborů adresář
  - adresář je také soubor
  - soubory a adresáře koncepčně umístěny v adresáři



## Jednotný přístup nebyl vždy

- speciální soubory pro přístup k zařízením
  - DOS PRN:, COM1:
- Poznámka před příchodem UNIXu toto samozřejné nebylo
- □ většina systémů před UNIXem samostatné služby pro čtení / zápis terminálu, na tiskárnu do souboru
- mnoho systémů před i po UNIXu mnoho různých druhů souborů s různou strukturou a metodami přístupu

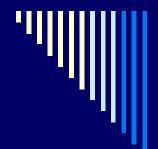


# Poznámky

- systémy poskytovaly "více služeb" x model podle
   UNIXu podstatně menší složitost
- téměř všechny moderní systémy základní rysy modelu převzaly



- otevření souboru
  - než s ním začneme pracovat
  - úspěšné vrátí služba pro otevření souboru popisovač souboru (file descriptor) – malé celé číslo
  - popisovač souboru používáme v dalších službách
    - čtení apod.



#### otevření souboru:

- □ fd = open (jmeno, způsob)
  - jméno řetězec pojmenovávající soubor
  - způsob pouze pro čtení, zápis, obojí
  - fd vrácený popisovač souboru
- otevření souboru nalezne informace o souboru na disku a vytvoří pro soubor potřebné datové struktury
- □ popisovač souboru index to tabulky souborů uvnitř OS



### vytvoření souboru:

- □ fd=creat(jméno, práva)
  - vytvoří nový soubor s daným jménem a otevře pro zápis
  - pokud soubor existoval zkrátí na nulovou délku
  - fd vrácený popisovač souboru

Opravdu creat nikoliv create



- operace čtení ze souboru:
- □ read(fd, buffer, počet\_bytů)
  - přečte počet\_bytů ze souboru fd do bufferu
  - může přečíst méně zbývá v souboru méně
  - přečte 0 bytů konec souboru



- operace zápisu do souboru
- write (fd, buffer, počet\_bytů)
  - význam parametrů jako u read
  - Uprostřed souboru přepíše, konec prodlouží
- read() a write()
  - vrací počet skutečně zpracovaných bytů
  - jediné operace pro čtení a zápis
  - samy o sobě poskytují sekvenční přístup k souboru



- nastavení pozice v souboru:
- □ Iseek (fd, offset, odkud)
- nastaví offset příští čtené/zapisované slabiky souboru
- odkud
  - od začátku souboru
  - od konce souboru (záporný offset)
  - od aktuální pozice
- poskytuje přímý přístup k souboru ("přeskakování děje filmu")



- **zavření** souboru
- □ close (fd)
- uvolní datové struktury alokované OS pro soubor



# Příklad použití rozhraní – kopírování souboru

```
int src, dst, in;
src = open("puvodni", O_RDONLY);
                                               /* otevreni zdrojoveho */
dst = creat("novy", MODE);
                                               /* vytvoreni ciloveho */
while (1)
in = read(src, buffer, sizeof(buffer));
                                                /* cteme */
if (in == 0)
                                               /* konec souboru? */
   close(src);
                                               /* zavreme soubory */
   close(dst);
                                               /* ukončení */
   return;
write(dst, buffer, in);
                                               /* zapiseme prectena data */
```



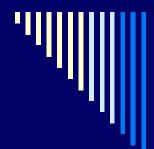
# Další služby pro práci se soubory

- 🗖 změna přístupových práv, zamykání, ...
- závislé na konkrétních mechanismech ochrany
- □ např. UNIX
  - zamykání fcntl (fd, cmd)
  - zjištění informací o souboru (typ, příst. práva, velikost)
  - stat (file\_name, buf), fstat (fd, buf)
  - man stat, man fstat



# Paměťově mapované soubory (!!)

- někdy se může zdát open/read/write/close nepohodlné
- možnost mapování souboru do adresního prostoru procesu
- služby systému mmap(), munmap()
- mapovat je možné i jen část souboru
- k souboru pak přistupujeme např. přes pointery v C



# Paměťově mapované soubory - příklad

- délka stránky 4KB
- soubor délky 64KB
- chceme mapovat do adresního prostoru od 512KB
- □ 512 \* 1024 = 524 288 .. od této adresy mapujeme
- □ 0 až 4KB souboru bude mapováno na 512KB 516KB
- □ čtení z 524 288 čte byte 0 souboru atd.



# Implementace paměťově mapovaných souborů

- □ OS použije soubor jako odkládací prostor (swapping area) pro určenou část virtuálního adresního prostoru
- čtení / zápis na adr. 524 288 způsobí výpadek stránky
- do rámce se načte obsah první stránky souboru
- pokud je modifikovaná stránka vyhozena (nedostatek volných rámců), zapíše se do souboru
- po skončení práce se souborem se zapíší všechny modifikované stránky



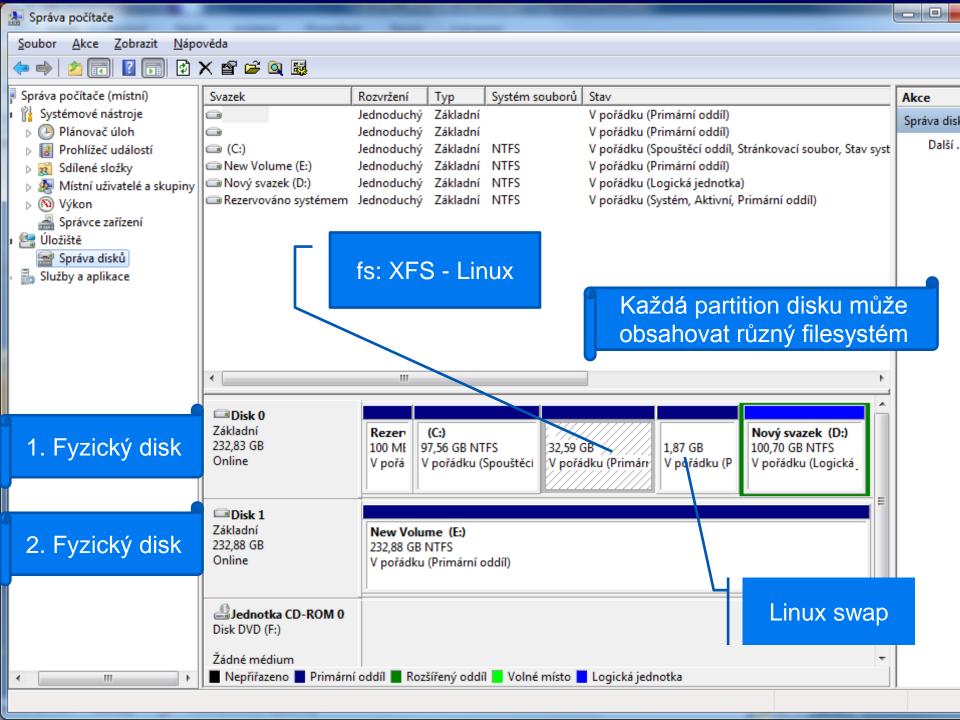
### Problémy pam. map. souborů

- není známa přesná velikost souboru, nejmenší jednotka je stránka
- problém nekonzistence pohledů na soubor, pokud je zároveň mapován a zároveň se k němu přistupuje klasickým způsobem



### Adresářová struktura

- Jeden oddíl (partition) disku obsahuje jeden fs
- ☐ fs 2 součásti:
  - množina souborů, obsahujících data
  - adresářová struktura udržuje informace o všech souborech v daném fs
- adresář překládá jméno souboru na informace o souboru (umístění, velikost, typ ...)





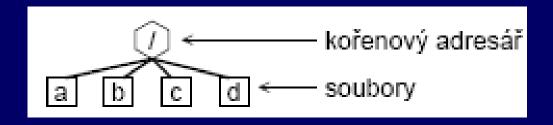
### Základní požadavky na adresář

- procházení souborovým systémem (cd)
- □ výpis adresáře (Is)
- vytvoření a zrušení souboru (rm, rmdir)
- přejmenování souboru (mv)
- dále schémata logické struktury adresářů
  - odpovídá historickému vývoji OS

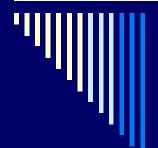


### Schémata logické struktury adresářů

- jednoúrovňový adresář
- původní verze MS DOSu
- všechny soubory jsou v jediném adresáři
- všechny soubory musejí mít jedinečná jména
- problém zejména pokud více uživatelů



nelze mít dva soubory priklad.c

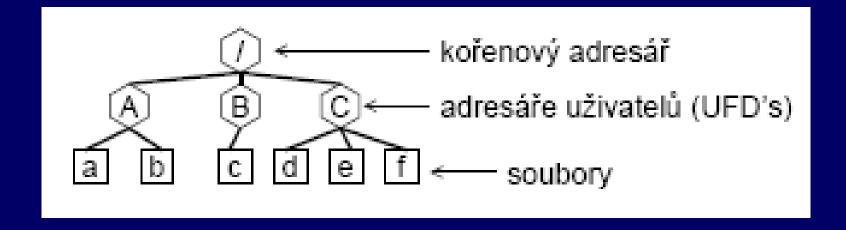


### Dvouúrovňový adresář

- adresář pro každého uživatele (User File Directory, UFD)
- OS prohledává pouze UFD , nebo pokud specifikováno adresář jiného uživatele [user] file
- systémové příkazy spustitelné soubory speciální adresář
  - příkaz se hledá v adresáři uživatele
  - pokud zde není, vyhledá se v systémovém adresáři



# Dvouúrovňový adresář – pokr.

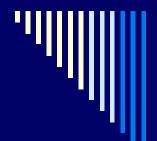


každý uživatel může být nanejvýš jeden soubor nazvaný priklad.c



### Adresářový strom

- zobecnění předchozího
- dnes nejčastější, MS DOS, Windows NT
- adresář množina souborů a adresářů
- souborový systém začíná kořenovým adresářem "/"
- MS DOS "\", znak / se používal pro volby
- cesta k souboru jméno v open, creat
  - absolutní
  - relativní



#### Cesta k souboru

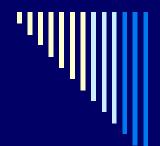
absolutní cesta začíná: / (Linux) C:\ (windows)

#### absolutní

- kořenový adresář a adresáře, kudy je třeba projít, název souboru
- oddělovače adresářů znak "/"
- např. /home/user/data/v1/data12.txt

#### relativní

- aplikace většinou přistupují k souborům v jednom adresáři
- defaultní prefix = pracovní adresář
- cesta nezačíná znakem /
- př. data12.txt , data/v1/data12.txt

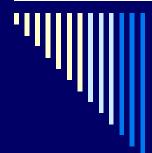


### Acyklický graf adresářů

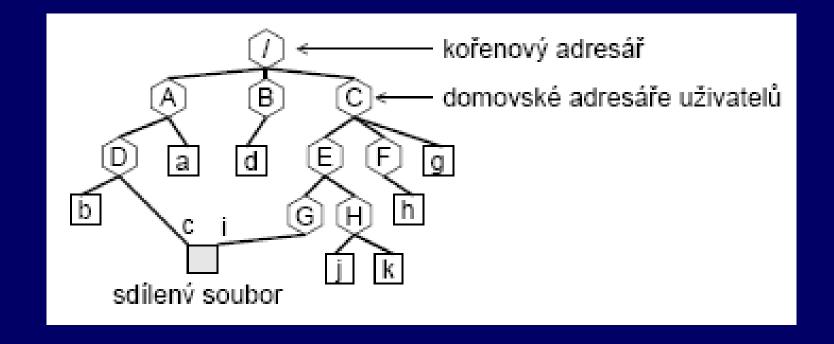
- např. týmová spolupráce na určitém projektu
- sdílení společného souboru nebo podadresáře



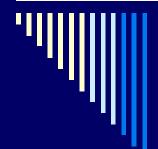
- stejný soubor (adr.) může být viděn ve dvou různých adresářích
- flexibilnější než strom, komplikovanější
- rušení souborů / adresářů kdy můžeme zrušit?
  - se souborem sdružen počet odkazů na soubor z adresářů
  - každé remove sníží o 1, 0 = není odkazován
- jak zajistit aby byl graf acyklický?
  - algoritmy pro zjištění, drahé pro fs



### Acyklický graf adresářů

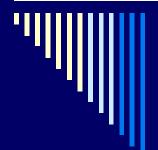


stejný soubor viděný v různých cestách



### Obecný graf adresářů

- obtížné zajistit, aby graf byl acyklický
- prohledávání grafu
  - omezení počtu prošlých adresářů (Linux)
- rušení souboru
  - pokud cyklus, může být počet odkazů > 0 i když je soubor již není přístupný
  - garbage collection projít celý fs, označit všechny přístupné soubory; zrušit nepřístupné; (drahé, zřídka používáno)



### Nejčastější použití

- nejčastěji adresářový strom (MS DOS)
- UNIX od původních verzí acyklický graf hard links – sdílení pouze souborů – nemohou vzniknout cykly

#### POZOR!

Je nutné si uvědomit rozdíl mezi pojmy adresářový strom a acyklický graf.



### Základní služby pro práci s adresáři

- téměř všechny systémy dle UNIXu
- pracovní adresář služby:
- chdir (adresář)
  - nastavení pracovního adresáře
- getcwd (buffer, počet\_znaků)
  - zjištění pracovního adresáře



### Práce s adresářovou strukturou

- vytváření a rušení adresářů
  - mkdir (adresář, přístupová\_práva)
  - rmdir (adresář) musí být prázdný
- zrušení souboru
  - remove (jméno\_souboru)
- přejmenování souboru
  - rename (jméno\_souboru, nové\_jméno)
  - provádí také přesun mezi adresáři



### Práce s adresářovou strukturou

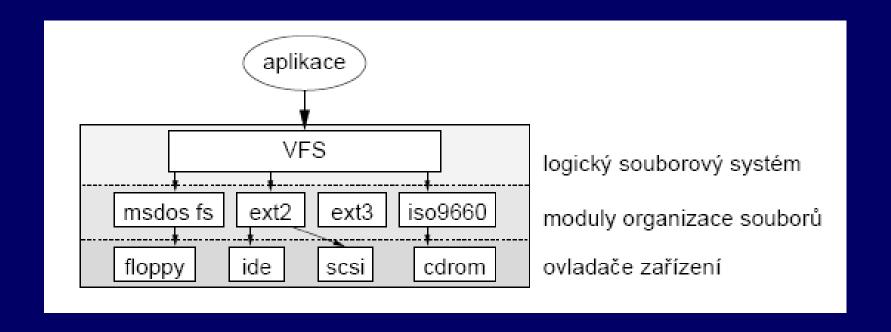
- □ čtení adresářů UNIX / POSIX
  - DIRp = opendir (adresář)
    - otevře adresář
  - položka = readdir (DIRp)
    - čte jednotlivé položky adresáře
  - closedir (DIRp)
    - zavře adresář
  - stat (jméno\_souboru, statbuf)
    - □ info o souboru, viz man 2 stat
- př. DOS: findfirst / findnext

ke všem uvedeným voláním získáte v Linuxu podrobnosti pomocí:

man 2 opendir man 2 readdir man 2 stat



# Implementace souborových systémů (!!!)





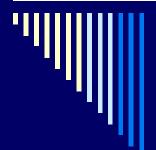
### Implementace fs - vrstvy

- 1. Logický (virtuální) souborový systém
  - Volán aplikacemi
- 2. Modul organizace souborů
  - Konkrétní souborový systém (např. ext3)
- 3. Ovladače zařízení
  - Pracuje s daným zařízením
  - Přečte/zapíše logický blok



### Ad 1 – virtuální fs

- Volán aplikacemi
- Rozhraní s moduly organizace souborů,
- Obsahuje kód společný pro všechny typy fs
- Převádí jméno souboru na informaci o souboru
- Udržuje informaci o otevřeném souboru
  - Pro čtení / zápis (režim)
  - Pozice v souboru
- Ochrana a bezpečnost (ověřování přístupových práv)



# Ad 2 – modul organizace souborů

- Implementuje konkrétní souborový systém
  - ext3, xfs, ntfs, fat, ...
- □ Čte/zapisuje datové bloky souboru
  - Číslovány O až N-1
  - Převod čísla bloku na diskovou adresu
  - Volání ovladače pro čtení zápis bloku
- Správa volného prostoru + alokace volných bloků
- Údržba datových struktur filesystému



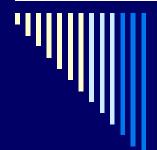
# Ad 3 – ovladače zařízení

- Nejnižší úroveň
- Floppy, ide, scsi, cdrom
- Interpretují požadavky: přečti logický blok 6456 ze zařízení 3



### Jak VFS pracuje s konkrétním fs? (!)

- Nový filesystém, který chceme používat se nejprve v systému zaregistruje
- Díky registrací VFS ví, jak zavolat jeho metody open, read, write pro konkrétní soubor
- Při požadavku na soubor VFS napřed zjistí, na kterém filesystému leží:
  - Viz např. příkaz mount
  - /bin/ls může ležet na ext4, /home/pesi/f1.txt na xfs
  - Pro čtení /bin/ls zavolá VFS->ext4->read
  - Pro čtení /home/pesi/f1.txt zavolá VFS->xfs->read



### Implementace souborů

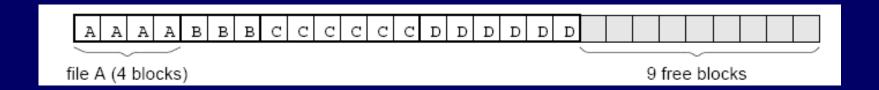
□ Nejdůležitější: které diskové bloky patří kterému souboru ☺

Předpokládáme: fs je umístěn v nějaké disk partition bloky v oblasti jsou očíslovány od 0



### Kontinuální alokace

- Soubor jako kontinuální posloupnost diskových bloků.
- □ Př.: bloky velikosti 1KB, soubor A (4KB) by zabíral 4 po sobě následující bloky
- Implementace
  - Potřebujeme znát číslo prvního bloku
  - Znát celkový počet bloků souboru (např. v adresáři)
- Velmi rychlé čtení
  - Hlavičku disku na začátek souboru, čtené bloky jsou za sebou





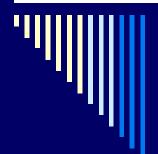
### Kontinuální alokace

- Problém dynamičnost OS– soubory vznikají, zanikají, mění velikost
- Nejprve zapisovat sériově do volného místa na konci
- Po zaplnění využít volné místo po zrušených souborech
- Pro výběr vhodné díry potřebujeme znát konečnou délku souboru většinou nevíme..



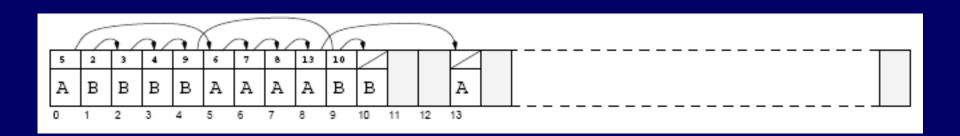
# Lze dnes využít kontinuální alokaci?

- Dnes se používá pouze na read-only a write-once médiích
- Např. v ISO 9660 pro CD ROM



# Seznam diskových bloků

- Svázat diskové bloky do seznamu nebude vnější fragmentace
- □ Na začátku diskového bloku je uložen odkaz na další blok souboru, zbytek bloku obsahuje data souboru
- Pro přístup k souboru stačí znát pouze číslo prvního bloku souboru (může být v adresáři)



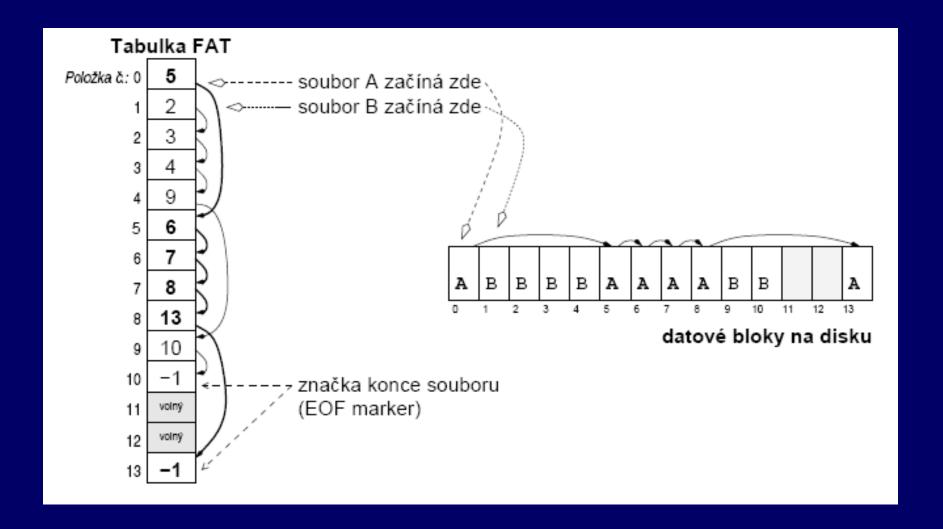


# Seznam diskových bloků

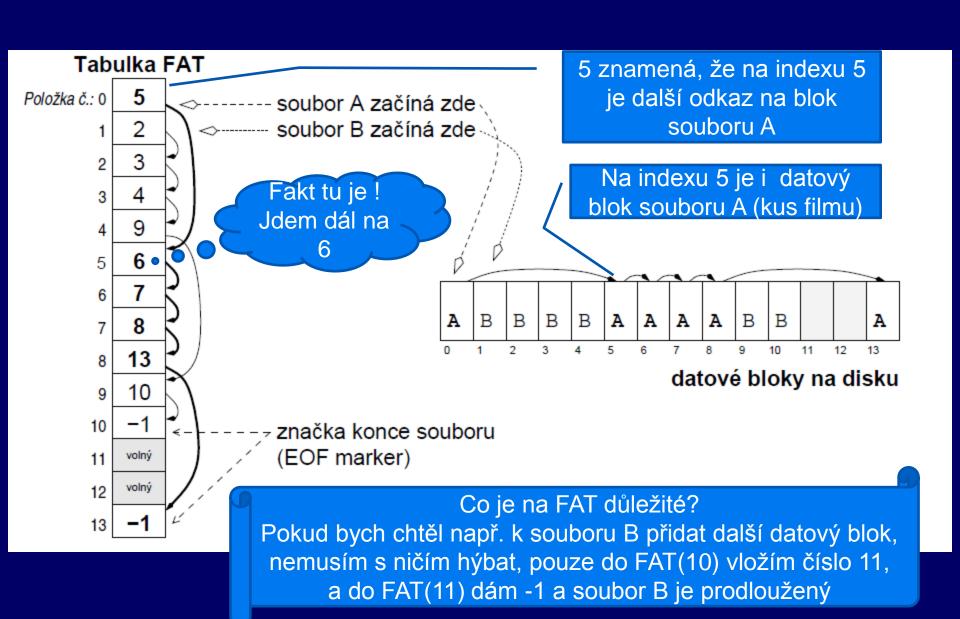
- Sekvenční čtení bez potíží
- Přímý přístup simulován sekvenčním, pomalé (musí dojít ke správnému bloku)
- Velikost dat v bloku není mocnina dvou
  - Část bloku je zabraná odkazem na další blok
  - Někdy může být nevýhodou

# 

- Přesunutí odkazů do samostatné tabulky FAT
- □ FAT (File Allocation Table)
  - Každému diskovému bloku odpovídá jedna položka ve FAT tabulce
  - Položka FAT obsahuje číslo dalšího bloku souboru (je zároveň odkazem na další položku FAT!)
  - Řetězec odkazů je ukončen speciální značkou, která není platným číslem bloku



Položce číslo X ve FAT odpovídá datový blok X na disku Položka ve FAT obsahuje odkaz na další datový blok na disku a tedy i na další položku ve FAT tabulce





- □ FAT je ukázka implementace souborového systému, kde v druhé části máme datové bloky (obsahující např. části jednoho filmu) a v první části máme indexy, které nám říkají, pod jakým číslem se nalézá další odkaz
- Výhodou je, že s určitým souborem můžeme manipulovat, zrušit ho, prodloužit, atd., aniž bychom ovlivnili pozici ostatních souborů na disku



- máme pevný disk (/dev/sda)
- např. druhá oblast disku (/dev/sda2)
- tato oblast disku je rozdělena:
  - boot block
  - FAT1 tabulka
  - FAT2 tabulka (záložní kopie)
  - datové bloky obsahující části souborů
    - první je adresář: jména souborů, velikost, kde začíná



### Diskový oddíl s FAT

Partition Boot Sector

FAT#1

FAT#2

Root Folder

Data Section

Diskový oddíl, který je naformátován na FAT (např. FAT32)

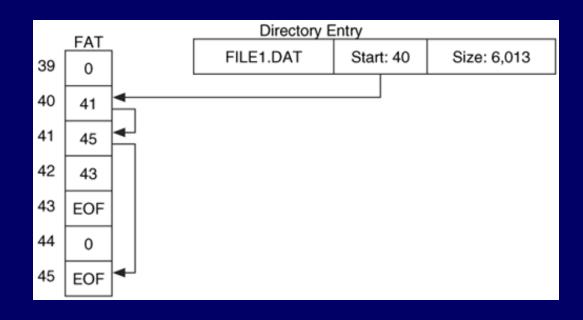
- boot sektor (pokud se z daného oddílu bootuje)
- 2. 2 kopie FAT tabulky
- 3. hlavní adresář daného oddílu
- 4. data

Zdroj obrázku:

http://yliqepyh.keep.pl/fat-file-systemspecifications.php



# FAT – jak poznáme, kde soubor začíná?

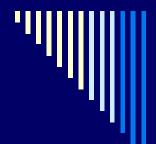


V tomto obrázku by velikost bloku byla cca 2KB – 2048B

#### Z adresáře poznáme:

- Jméno souboru
- Kde začíná (40)
- Velikost (6013 bytů)

Víme tedy, kde začíná soubor (40) a umíme určit, jaká část posledního přiděleného bloku je využita daty souboru (zbytek po dělení 6013 velikostí bloku)



#### Vlastnosti FAT

- Nevýhodou je velikost tabulky FAT
  - 80GB disk, bloky 4KB => 20 mil. položek
  - Každá položka alespoň 3 byty => 60MB FAT
  - Výkonnostní důsledky (část FAT chceme v keši v RAM)
- Použití
  - DOS, Windows 98, ME, podporují Win NT/2000/XP
  - FAT12, 12 bitů, 2^12 = 4096 bloků, diskety
  - FAT16, 16 bitů, 2^16 = 65536 bloků
  - FAT32, 2 ^28 bloků, blok 4-32KB, cca 8TB
  - ExFAT používá B+ strom místo tabulky



## Příklady filesystémů (!!!)

#### □ FAT

- Starší verze Windows, paměťové karty
- Nepoužívá ACL u souborů není žádná info o přístupových právech
- snadná přenositelnost dat mezi různými OS

#### ■ NTFS

- Používá se ve Windows XP/Vista/7
- Používají ACL: k souboru je přiřazen seznam uživatelů, skupin a jaká mají oprávnění k souboru (!!!!)

#### □ Ext2

- Použití v Linuxu, nemá žurnálování
- Nepoužívá ACL jen standardní nastavení (vlastní,skupina, others), což ale není ACL (to je komplexnější)

#### □ Ext3

 Použití v Linuxu, má žurnál (rychlejší obnova konzistence po výpadku)

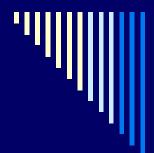


## Příklady filesystémů

- □ ext4
  - stejně jako ext2, ext3 používá inody
  - extenty souvislé logické bloky
     může být až 128MB oproti velkému počtu 4KB bloků
  - nanosekundová časová razítka
- □ xfs
- □ jfs

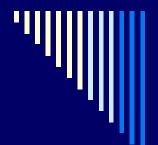


- nativní fs Windows od NT výše
- žurnálování všechny zápisy na disk se zapisují do žurnálu, pokud uprostřed zápisu systém havaruje, je možné dle stavu žurnálu zápis dokončit nebo anulovat => konzistentní stav
- access control listpřidělování práv k souborům ( x FAT)
- komprese na úrovni fs lze soubor nastavit jako komprimovaný

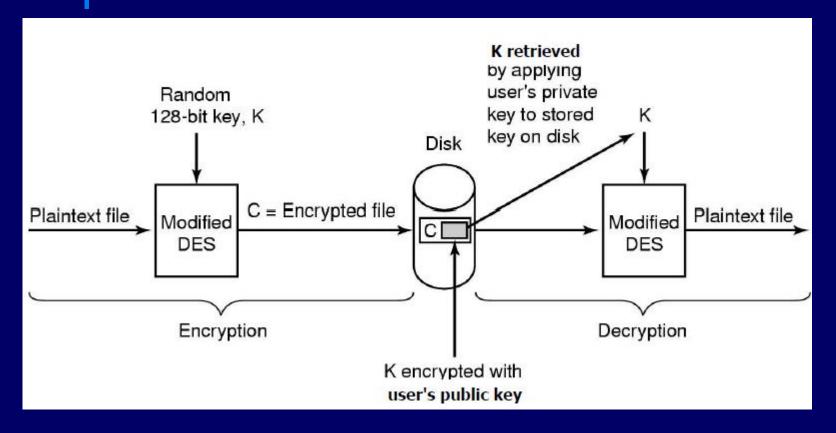


## NTFS pokračování

- šifrování
  - EFS (encrypting file system), transparentní – otevřu ahoj.txt, nestarám se, zda je šifrovaný
- diskové kvóty
  max. velikost pro uživatele na daném oddíle
  dle reálné velikosti (ne komprimované)
- pevné a symbolické linky



#### šifrování



Při přístupu k souboru si odšifruji klíč K, a jeho pomocí získám zpět plaintext



#### NTFS struktura

- □ 64bitové adresy klusterů .. cca 16EB
- systém jako obří databáze záznam odpovídá souboru
- základ 11 systémových souborů metadat hned po formátování svazku
- \$Logfile žurnálování
- \$MFT (Master File Table) záznamy o všech souborech, adresářích, metadatech hned za boot sektorem, za ním se udržuje zóna volného místa



#### NTFS struktura

- \$MFTMirr uprostřed disku, obsahuje část záznamů \$MFT, při poškození se použije tato kopii
- \$Badclus seznam vadných clusterů
- \$Bitmap sledování volného místa0 volný

#### podrobnosti:

http://technet.microsoft.com/en-us/library/cc781134%28WS.10%29.aspx



### NTFS atributy souborů

- □ \$FILE\_NAME
  - jméno souboru
  - velikost
  - odkaz na nadřazený adresář
  - další
- \$SECURITY\_DESCRIPTOR
  - přístupová práva k souboru
- □ \$DATA
  - vlastní obsah souboru





- adresáře
  - speciální soubory
  - B-stromy se jmény souborů a odkazy na záznamy v MFT
- alternativní datové proudy (ADS)
  - notepad poznamky.txt:tajny.txt
  - často útočiště virů, škodlivého kódu
- zkopírováním souboru z NTFS na FAT
  - ztratíme přístupová práva a alternativní datové proudy



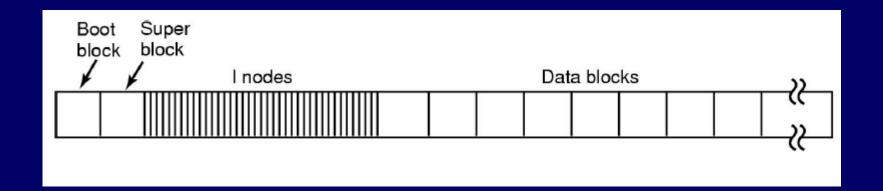
#### NTFS – způsob uložení dat (!!!)

- kódování délkou běhu
- od pozice 0 máme např. uloženo:
   A1, A2, A3, B1, B2, A4, A5, C1, ...
- soubor A bude popsaný fragmenty
- fragment
  - index
  - počet bloků daného souboru
- v našem příkladě:
  - O, 3 (od indexu O patří tři bloky souboru A)
  - 5, 2 (od indexu 5 patří dva bloky souboru A)



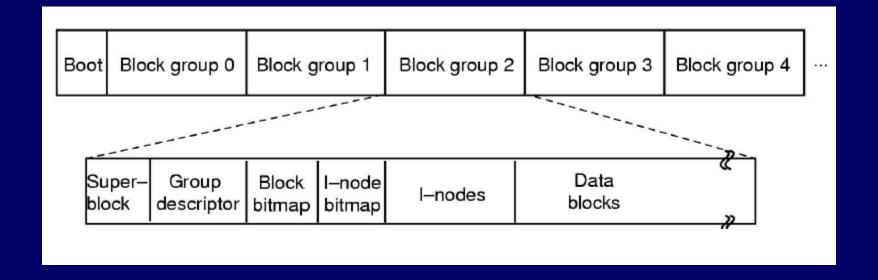
# Unixové systémy s využitím i-uzlů (původní)

takto vypadá parititon disku (např. /dev/sda1) původní rozdělení v Unixových systémech, v ext2 viz další slide superblock – příznak čistoty, verze, počet i-nodů, velikost alok. jednotky





# Unixové systémy s využitím i-uzlů (novější, např. ext2)

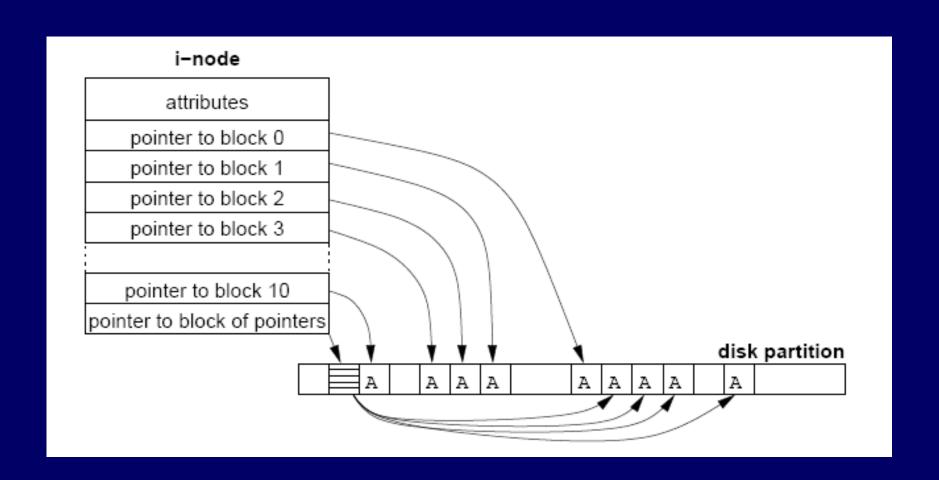


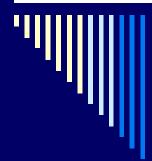
skupiny i-nodů a datových bloků v jednotlivých skupinách (block group) duplikace nejdůležitějších údajů v každé skupině (superblock, group descriptor)



# I-uzly (!!)

- □ S každým souborem sdružena datová struktura i-uzel (i-node, zkratka z index-node)
- □ i-uzel obsahuje
  - Atributy souboru
  - Diskové adresy prvních N bloků
  - 1 či více odkazů na diskové bloky obsahující další diskové adresy (případně obsahující odkazy na bloky obsahující adresy)
- Používá tradiční fs v Unixu UFS (Unix File System) a z něj vycházející v Linuxu, dnes např. ext2, ext3, ext4

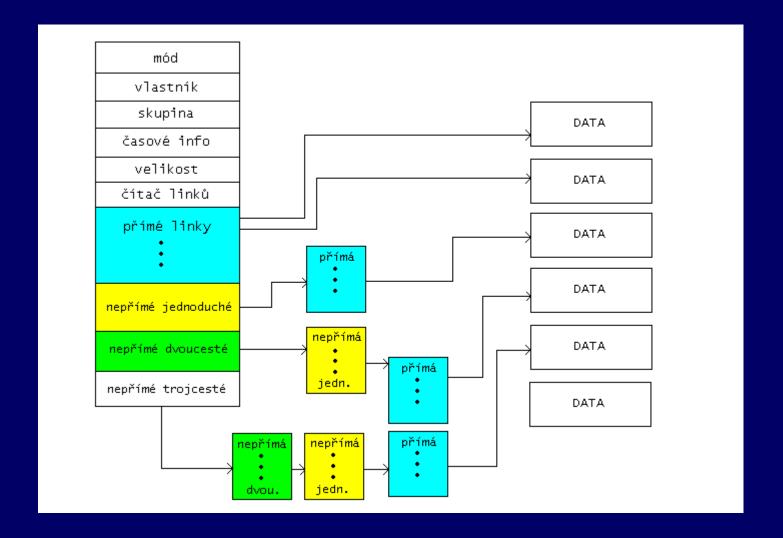


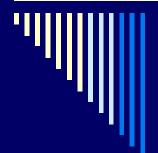


## I-uzly - výhoda

Po otevření souboru můžeme zavést i-uzel a případný blok obsahující další adresy do paměti => urychlení přístupu k souboru

# i-uzly dle normy POSIX





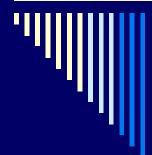
# i-uzly dle normy Posix

- MODE typ souboru, přístupová práva (u,g,o)
- □ REFERENCE COUNT počet odkazů na tento objekt (vytvoření hardlinku zvyšuje počet)
- OWNER ID vlastníka
- □ GROUP ID skupiny
- SIZE velikost objektu
- TIME STAMPS
  - atime čas posledního přístupu (čtení souboru, výpis adresáře)
  - mtime čas poslední změny
  - ctime čas poslední změny i-uzlu (metadat)

## i-uzly dle normy POSIX

- □ DIRECT BLOCKS 12 přímých odkazů na datové bloky (data v souboru)
- SINGLE INDIRECT 1 odkaz na datový blok, který místo dat obsahuje seznam přímých odkazů na datové bloky obsahující vlastní data souboru
- □ DOUBLE INDIRECT 1 odkaz 2. nepřímé úrovně
- □ TRIPLE INDIRECT 1 odkaz 3. nepřímé úrovně

v linuxových fs (ext\*) ještě FLAGS, počet použitých datových bloků a rezervovaná část – doplňující info (odkaz na rodičovský adresář, ACL, rozšířené atributy)



#### Implementace adresářů

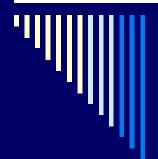
- Před čtením je třeba soubor otevřít
- 🗖 open (jméno, režim)
- Mapování jméno -> info o datech poskytují adresáře!
- Adresáře jsou často speciálním typem souboru
- Typicky pole datových struktur, 1 položka na soubor



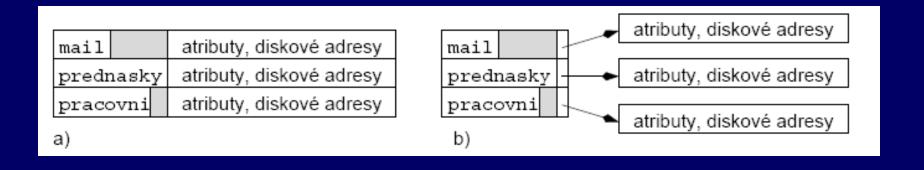
# 2 základní uspořádání adresáře (!!!)

- Adresář obsahuje jméno souboru, atributy, diskovou adresu souboru (např. adresa 1.bloku) (implementuje DOS, Windows)
- Adresář obsahuje pouze jméno + odkaz na jinou datovou strukturu obsahující další informace (např. i-uzel) (implementuje UNIX, Linux)

Běžné jsou oba dva způsoby i kombinace



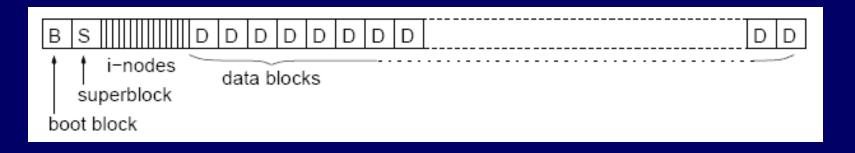
# 2 základní uspořádání adresáře (!!)





## Příklad fs (Unix v7)

- Struktura fs na disku
  - Boot blok může být kód pro zavedení OS
  - Superblok informace o fs (počet i-uzlů, datových bloků,..)
  - i-uzly tabulka pevné velikosti, číslovány od 1
  - Datové bloky všechny soubory a adresáře

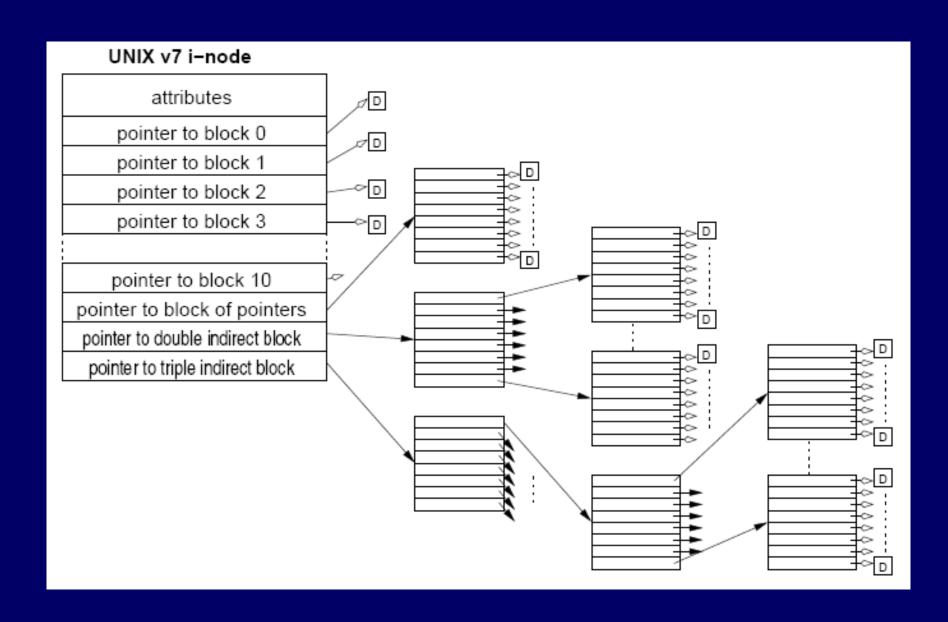


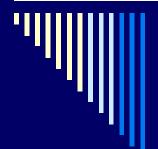


## Implementace souborů – i-uzly

#### i-uzel obsahuje:

- Atributy
- Odkaz na prvních 10(až 12) datových bloků souboru
- Odkaz na blok obsahující odkazy na datové bloky (nepřímý odkaz)
- Odkaz na blok obsahující odkazy na bloky obsahující odkazy na datové bloky (dvojitě nepřímý odkaz)
- Trojitě nepřímý odkaz





### Pokračování příkladu

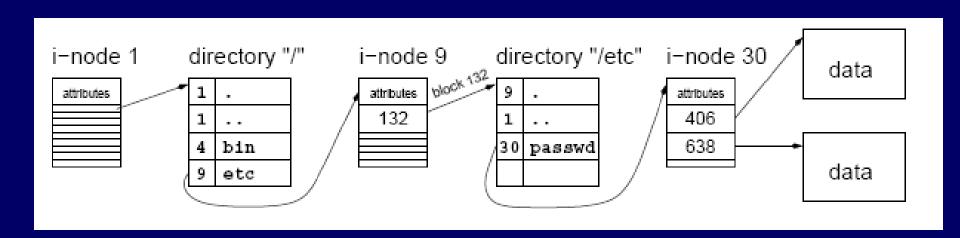
- Implementace adresářů:
   tabulka obsahující jméno souboru a číslo jeho i-uzlu
- Info o volných blocích seznam, jeho začátek je v superbloku
- Základní model, současné fs jsou na něm založeny



#### Adresáře v UNIX v7

- adresář: obsahuje jméno souboru a číslo i-uzlu
- Číslo i-uzlu je indexem do tabulky i-uzlů na disku
- Každý soubor a adresář: právě 1 i-uzel
- V i-uzlu: všechny atributy a čísla diskových bloků
- Kořenový adresář: číslo i-uzlu 1

- Nalezení cesty k souboru /etc/passwd
  - V kořenovém adresáři najdeme položku "etc"
  - i-uzel číslo 9 obsahuje adresy diskových bloků pro adresář etc
  - V adresáři etc (disk blok 132) najdeme položku passwd
  - i-uzel 30 obsahuje soubor /etc/passwd
  - (uzel, obsah uzlu, uzel, obsah uzlu)



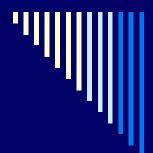


#### Příklad – adresář win 98

```
* položka adresáře obsahuje:
    - jméno souboru (8 bytů) + příponu (3 byty)
    - atributy (1)
    - NT (1) - Windows 98 nepoužívají (rezervováno pro WinNT)
    - datum a čas vytvoření (5)
    - čas posledního přístupu (2)
    - horních 16 bitů počátečního bloku souboru (2)
    - čas posledního čtení/zápisu
    - spodních 16 bitů počátečního bloku souboru (2)
    - velikost souboru (4)
* dlouhá jména mají pokračovací položky

* veškeré "podivnosti" této struktury jsou z důvodu kompatibility s MS DOSem
```

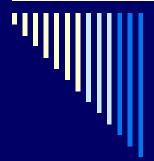
cd Progra~1 vs. cd Program Files



#### Sdílení souborů

- Soubor ve více podadresářích nebo pod více jmény
- □ Hard links (pevné odkazy)
  - Každý soubor má datovou strukturu, která ho popisuje (i-uzel), můžeme vytvořit v adresářích více odkazů na stejný soubor
  - Všechny odkazy (jména) jsou rovnocenné
  - V popisu souboru (i-uzlu) musí být počet odkazů
  - Soubor zanikne při zrušení posledního odkazu

Hard link v Linuxu: In stare\_jmeno nove\_jmeno

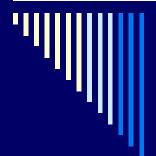


#### Sdílení souborů

#### Symbolický link

- Nový typ souboru, obsahuje jméno odkazovaného souboru
- OS místo symbolického odkazu otevře odkazovaný soubor
- Obecnější může obsahovat cokoliv
- Větší režie

Symbolický link v Linuxu: In -s stare\_jmeno nove\_jmeno



## Správa volného prostoru

- Info, které bloky jsou volné
- Nejčastěji bitová mapa nebo seznam

#### □ Bitová mapa

- Konstantní velikost
- Snažší vyhledávání volného bloku s určitými vlastnostmi
- Většina současných fs používá bitovou mapu



## Správa volného prostoru

- Seznam diskových bloků
  - Blok obsahuje odkazy na volné bloky a adresu dalšího bloku ...
  - Uvolnění bloků Přidáme adresy do seznamu, pokud není místo blok zapíšeme
  - Potřebujeme bloky pro soubor používáme adresy ze seznamu, pokud nejsou přečteme další blok adres volných bloků
  - Pokud není na disku volné místo, seznam volných bloků je prázdný a nezabírá místo
  - Problém najít volný blok s určitými vlastnostmi (např. ve stejném cylindru), prohledávat seznam, drahé,...



# Seznam diskových bloků

Jeden blok Další blok



#### Blok obsahuje:

- Odkazy na volné bloky
- Adresu dalšího bloku v seznamu



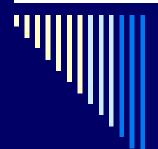
Účel – aby uživatel neobsadil celý disk a nechal místo i pro ostatní

- Maximální počet bloků obsazených soubory uživatele
- Ve víceuživatelských OS, na serverech
- □ Hard kvóta
  - Pevná mez, uživatel ji nepřekročí
- □ Soft kvóta
  - Po překročení uživatel dostane varování
  - Grace period po zadanou dobu může překročit soft kvótu, po uplynutí času už více neuloží



# Spolehlivost souborového systému

- Ztráta dat má často horší důsledky než zničení počítače
  - diplomová bakalářská práce
  - Fotografie za posledních 10 let
- Filesystém musí být jedna z nejspolehlivějších částí OS, snaha chránit data
  - Správa vadných bloků (hlavně dříve)
  - Rozprostřít a duplikovat důležité datové struktury, čitelnost i po částečném poškození povrchu



#### Konzistence fs

- □ Blokové zařízeníOS přečte blok souboru, změní ho, zapíše
- Nekonzistentní stav může nastat při havárii (např. výpadek napájení) předtím, než jsou všechny modifikované bloky zapsány
- □ Kontrola konzistence fs
  Windows: scandisk, chkdsk
  UNIX: fsck, fsck.ext3, e2fsck ... viz man
- Kontrolu spustí automaticky po startu, když detekuje nekorektní ukončení práce se systémem

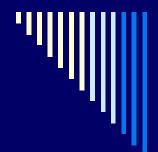


## Testy konzistence fs

- □ Konzistence informace o diskových blocích souborů
  - Blok (obvykle) patří jednomu souboru nebo je volný
- ☐ Konzistence adresářové struktury
  - Jsou všechny adresáře a soubory dostupné?

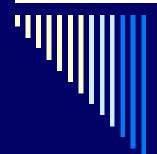
#### důležité pochopit rozdíl:

- -kontrola konzistence souboru
- -kontrola, zda je soubor dostupný z nějakého adresáře



# Konzistence informace o diskových blocích souborů

- □ Tabulka počtu výskytů bloku v souboru
- □ Tabulka počtu výskytů bloku v seznamu volných bloků
- Položky obou tabulek inicializovány na 0
- Procházíme informace o souborech (např. i-uzly),
   inkrementujeme položky odpovídající blokům souboru
   v první tabulce
- □ Procházíme seznam nebo bitmapu volných bloků a inkrementujeme příslušné položky ve druhé tabulce



#### Konzistentní fs

Číslo bloku	0	1	2	3	4	5	6	7	8
Výskyt v souborech	1	0	1	0	1	0	2	0	1
Volné bloky	0	1	0	0	1	2	0	1	0

Blok je buď volný, nebo patří nějakému souboru, tj. konzistentní hodnoty v daném sloupci jsou buď (0,1) nebo (1,0)

Vše ostatní jsou chyby různé závažnosti



## Možné chyby, závažnosti

- □ (0,0) blok se nevyskytuje v žádné tabulce
  - Missing blok
  - Není závažné, pouze redukuje kapacitu fs
  - Oprava: vložení do seznamu volných bloků
- (0,2) blok je dvakrát nebo vícekrát v seznamu volných
  - Problém blok by mohl být alokován vícekrát!
  - Opravíme seznam volných bloků, aby se vyskytoval pouze jednou



## Možné chyby, závažnosti

- □ (1,1) blok patří souboru a zároveň je na seznamu volných
  - Problém, blok by mohl být alokován podruhé!
  - Oprava: blok vyjmeme ze seznamu volných bloků
- □ (2,0) blok patří do dvou nebo více souborů
  - Nejzávažnější problém, nejspíš už došlo ke ztrátě dat
  - Snaha o opravu: alokujeme nový blok, problematický blok do něj zkopírujeme a upravíme i-uzel druhého souboru
  - Uživatel by měl být informován o problému



# Je zde nějaká chyba? A když tak jaká?

```
      číslo bloku:
      0
      1
      2
      3
      4
      5
      6
      7
      8
      9
      11
      12
      13
      14
      15

      výskyt
      v souborech:
      1
      2
      0
      0
      1
      0
      0
      1
      1
      1
      1
      1
      1
      1
      1
      0
      0

      volné bloky:
      0
      0
      1
      1
      0
      0
      0
      0
      0
      0
      0
      1
      1
```



# Kontrola konzistence adresářové struktury

- □ Tabulka čítačů, jedna položka pro každý soubor
- Program prochází rekurzivně celý adresářový strom
- Položku pro soubor program zvýší pro každý výskyt souboru v adresáři
- Zkontroluje, zda odpovídá počet odkazů v i-uzlu (i) s počtem výskytů v adresářích (a)
- □ i == a ② pro každý soubor



### Možné chyby

□ i > a

soubor by nebyl zrušen ani po zrušení všech odkazů v adresářích

není závažné, ale soubor by zbytečně zabíral místo

řešíme nastavením počtu odkazů v i-uzlu na správnou hodnotu (a)



## Možné chyby

#### □ i < a</p>

soubor by byl zrušen po zrušení i odkazů, ale v adresářích budou ještě jména

velký problém – adresáře by ukazovaly na neexistující soubory

řešíme nastavením počtu odkazů na správnou hodnotu



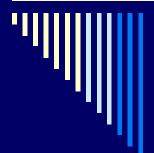
## Možné chyby

□ a=0 , i > 0 ztracený soubor, na který není v adresáři odkaz ve většině systémů program soubor zviditelní na předem určeném místě (např. adresář lost+found)



# Další heuristické kontroly

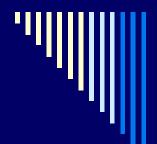
- Odpovídají jména souborů konvencím OS?
  - Když ne, soubor může být nepřístupný, změníme jméno
- □ Nejsou přístupová práva nesmyslná?
  - Např. vlastník nemá přístup k souboru,...
- Zde byly uvedeny jen základní obecné kontroly fs



#### Journaling fs

- Kontrola konzistence je časově náročná
- Journaling fs
  - Před každým zápisem na disk vytvoří na disku záznam popisující plánované operace, pak provede operace a záznam zruší
  - Výpadek na disku najdeme žurnál o všech operacích, které mohly být v době havárie rozpracované, zjednodušuje kontrolu konzistence fs

Příkladem fs s žurnálem je např. ext3, ext4



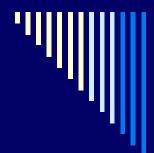
# Jak funguje žurnál (!!)

- 1. Zapíši do žurnálu
- Když je žurnál kompletní, zapíšeme značku ZURNAL\_KOMPLETNI
- 3. Začneme zapisovat datové bloky
- 4. Je-li hotovo, smažeme žurnál



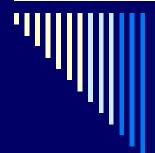
# Žurnál – ošetření výpadku (!!)

- Dojde-li k výpadku elektřiny –> nebyl korektně odmontovaný oddíl se souborovým systémem –> pozná
- □ Podívá se do žurnálu:
  - a) Je prázdný
    - -> není třeba nic dělat
  - b) Je tam nějaký zápis, ale není značka ZURNAL\_KOMPLETNI
    - -> jen smažeme žurnál
  - c) V žurnálu je zápis včetně značky ZURNAL\_KOMPLETNI
    - -> přepíšeme obsah žurnálu do datových bloků



#### Co žurnálovat?

- Všechny zápisy, tj. i do souborů
  - Zapisují se metadata i data
  - pomalejší
- Zápisy metadat
  - Rychlejší
  - Může dojít ke ztrátě obsahu souboru, ale nerozpadne se struktura adresářů



#### Výkonnost fs

- Přístup k tradičnímu disku řádově pomalejší než přístup do paměti
  - Seek 5-10 ms
  - Rotační zpoždění až bude požadovaný blok pod hlavičkou disku
  - Rychlost čtení (x rychlost přístupu do paměti)
- Použití SSD disků
  - Rychlé, lehké, malá spotřeba (výdrž notebooků)
  - menší kapacita, drahé
  - 256GB cca 3-4 tisíce Kč



#### Výkonnost fs, cachování

- Cachování diskových bloků v paměti
- □ Přednačítání (read-ahead) do cache se předem načítají bloky, které se budou potřebovat při sekvenčním čtení souboru:

čtu blok A10 a rovnou nakešuji i blok A11

Redukce pohybu diskového raménka pro po sobě následující bloky souboru,...



#### Mechanismy ochrany

- Chránit soubor před neoprávněným přístupem
- Chránit i další objekty
  - HW (segmenty paměti, I/O zařízení)
  - SW (procesy, semafory, ...)
- Subjekt entita schopná přistupovat k objektům (většinou proces)
- Objekt cokoliv, k čemu je potřeba omezovat přístup pomocí přístupových práv (např. soubor)
- Systém uchovává informace o přístupových právech subjektů k objektům



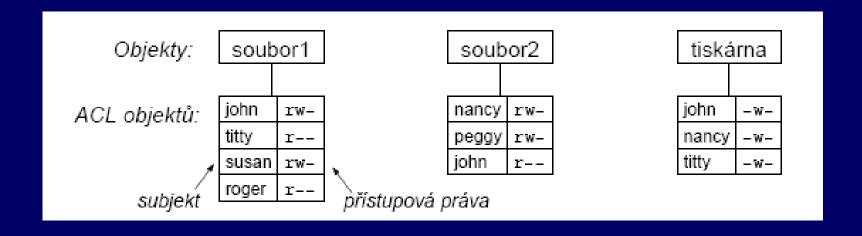
# ACL x capability list

- Dvě různé podoby
- □ ACL s objektem je sdružen seznam subjektů a jejich přístupových práv
- Capability list [kejpa-] se subjektem je sdružen seznam objektů a přístupových práv k nim



# ACL (Access Control Lists)

- S objektem je sdružen seznam subjektů, které mohou k objektu přistupovat
- Pro každý uvedený subjekt je v ACL množina přístupových práv k objektu





- Sdružování subjektů do tříd nebo do skupin
  - Studenti
  - Zamestnanci
- Skupiny mohou být uvedeny na místě subjektu v ACL
- Zjednodušuje administraci
  - Nemusíme uvádět všechny studenty jmenovitě
- □ ACL používá mnoho moderních filesystémů (ntfs, xfs, …)



# ACL – příklad (!)

#### Např v NTFS:

Se souborem data1.txt je spojena následující ACL tabulka, která určuje, kdo smí co s daným souborem dělat. Počet řádek tabulky záleží na tom, pro kolik uživatelů skupin budeme práva nastavovat.

Klasická unixová práva (u,g,o) jsou příliš limitovaná – když chceme více skupin, více uživatelů atd. potřebujeme ACL.

uživatel / skupina	id uživatele	práva
0	505 (Pepa)	rw
1	101 (Studenti)	r
1	102 (Zamestnanci)	rw



- getfacl soubor
- setfacl –m user:pepa:rw s1.txt

Přečtěte si článek:

http://www.abclinuxu.cz/clanky/bezpecnost/aclprakticky



#### Klasická unixová práva

- chmod 777 s1.txt
  - Práva pro vlastníka (u)
  - Práva pro skupinu (g)
  - Práva pro ostatní (o)
  - Typ práv: r, w, x, (s, t)
- Oproti ACL jsou omezující:
  - Chceme pro více skupin různá nastavení
  - Chceme pro více uživatelů různá nastavení

Klasická unixová
práva u,g,o nejsou
považována za
ACL,
Naopak systémy
které je využívají
se o ACL rozšiřují



### Klasická práva vs. ACL

ACL má přednost před klasickými unixovými právy (nastavenými chmod)

Tj. nastavením chmod 777 nezrušíme ACLka ©



# Úloha: jak doimplementovat ACL do i-uzlu?

- V i-uzlu by byla část tabulky ACL, pokud by se nevešla celá do i-uzlu, tak odkaz na diskový blok obsahující zbytek ACL
- Každá položka ACL
  - Subjekt: id uživatele či id skupiny + 1 bit rozlišení uživatel/skupina
  - Přístupové právo Nbitovým slovem
     1 právo přiděleno, 0 právo odejmuto

i-uzel	ACL			
atributy	0	hynek	rwx	
	0	vilém	r-x	
	0	jarmila	x	
	1	studenti	x	



# Mechanismus capability lists (C-seznamy)

- S každým subjektem (procesem) sdružen seznam objektů, kterým může přistupovat a jakým způsobem (tj. přístupová práva)
- Seznam se nazývá capability list (C-list)
- Jednotlivé položky capabilities



### Struktura capability

- Struktura capability
  - Typ objektu
  - Práva obvykle bitová mapa popisující dovolené operace nad objektem
  - Odkaz na objekt, např. číslo uzlu, segmentu, atd..

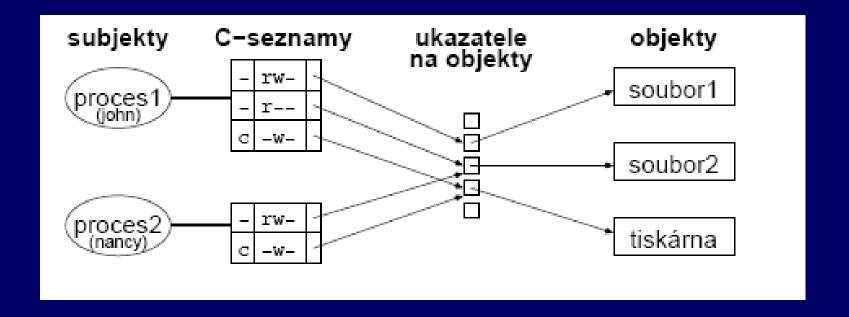


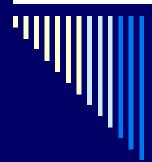
# Capability

- Problém zjištění, kdo všechno má k objektu přístup
- Zrušení přístupu velmi obtížné najít pro objekt všechny capability + odejmout práva
- Řešení: odkaz neukazuje na objekt, ale na nepřímý objekt
  - systém může zrušit nepřímý objekt, tím zneplatní odkazy na objekt ze všech C-seznamů



# Capability list





#### Capability list

Pokud jsou jediný způsob odkazu na objekt (bezpečný ukazatel, capability-based addressing):

- Ruší rozdíl mezi objekty na disku, v paměti (segmenty) nebo na jiném stroji (objekty by šlo přesouvat za běhu)
- Mechanismus C-seznamů v některých distribuovaných systémech (Hydra, Mach,...)



### Přístupová práva

- □ FAT žádná
- ext2
  - klasická unixová práva (není to ACL)
  - vlastník, skupina, ostatní (r,w,x,s,...)
  - Ize přidat ACL
- NTFS
  - ACL
  - Ize měnit přes grafické UI, příkaz icacls, ...
  - explicitně udělit / odepřít práva
  - zdědit práva, zakázat dědění

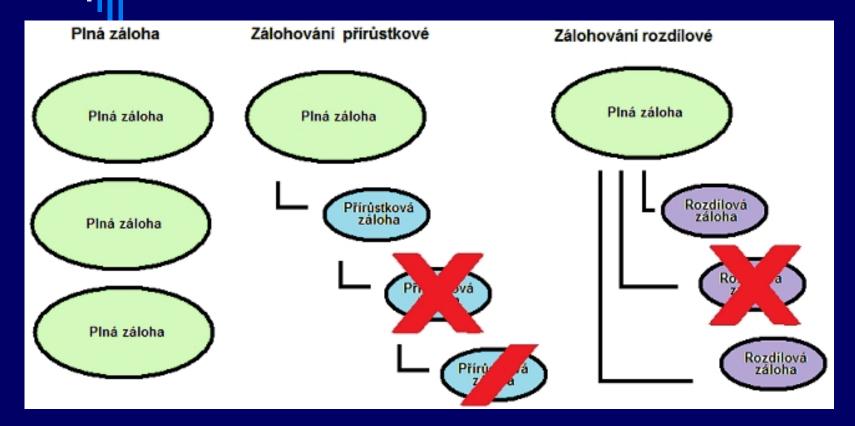
# Typy záloh

manipulací s atributech archive

- normální
  - zálohuje, označí soubory jako "zazálohované"
- copy
  - zálohuje, ale neoznačí jako "zazálohované"
- incremental
  - zálohuje pouze vybrané soubory, tj. pokud nebyly "zazálohované" nebo byli změněny a označí je jako "zazálohované"
- diferential
  - viz předchozí, ale neoznačuje jako "zazálohované"
  - změny, které proběhly od plné zálohy
  - diferenciální zálohy nejsou na sobě závislé
- daily
  - zálohuje soubory změněné dnes, ale neoznačuje je jako "zazálohované"



# Typy záloh



zdroj a dobrý materiál k přečtení: http://www.acronis.cz/kb/diferencialni-zaloha/



# Co se děje při spuštění PC?

01. Pustíme proud

02. Power on self-test (řízen BIOSem)
test operační paměti, grafické karty, procesoru
test pevných disků, dalších ATA/SATA/USB zařízení

03. spustí z ROM paměti BIOSu bootstrap loader prohledá boot sektor botovacího zařízení (dle CMOS) boot sektor - první sektor na disku, je zde umístěn zavaděč systému (boot loader)

http://cs.wikipedia.org/wiki/Power\_On\_Self\_Test



# Co se děje při spuštění PC?

04. pustí se zavaděč (GRUB, GRUB2, LILO, ...)
může se skládat z více stupnů (stage), v boot sektoru je stage1
možnost zvolit si jaký systém nabootuje (Linux, Windows)

05. zavaděč nahraje jádro do paměti a spustí ho jádro píše na obrazovku info zprávy
- můžeme prozkoumat příkazem dmesg

06. první proces init /sbin/init , načte /etc/inittab , spouštění a vypínání služeb /etc/rc.d/rcX.d



# Co se děje při spuštění PC?

07. spustí program getty na virtuálních terminálech zadáme uživatelské jméno

08. spustí se login vyžádá si heslo, zkontroluje v /etc/passwd, /etc/shadow či jinde